

ระบบตรวจวัดความเครียดโดยใช้เทคโนโลยีปัญญาประดิษฐ์ร่วมกับสัญญาณทางสรีระวิทยา

An AI-driven Stress Detection System using Physiological Signals

กฤตพร รักนุ้ย

Krittaporn Ruknui

สุรพัศ แซ่ตั้น

Surapat Saetan

สุรพัศ หกหนู

Surapat Hoknoo

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต

สาขาวิศวกรรมคอมพิวเตอร์และปัญญาประดิษฐ์

สำนักวิชาวิศวกรรมศาสตร์และเทคโนโลยี มหาวิทยาลัยวลัยลักษณ์

ปีการศึกษา 2568



ระบบตรวจวัดความเครียดโดยใช้เทคโนโลยีปัญญาประดิษฐ์ร่วมกับสัญญาณทางสรีระวิทยา

An AI-driven Stress Detection System using Physiological Signals

กฤตพร รักนุ้ย

Krittaporn Ruknui

สุรพัศ แซ่ตั้น

Surapat Saetan

สุรพัศ หกหนู

Surapat Hoknoo

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต

สาขาวิศวกรรมคอมพิวเตอร์และปัญญาประดิษฐ์

สำนักวิชาวิศวกรรมศาสตร์และเทคโนโลยี มหาวิทยาลัยวลัยลักษณ์

ปีการศึกษา 2568

หน้าอนุมัติ

ชื่อโครงงาน	ระบบตรวจวัดความเครียดโดยใช้เทคโนโลยีปัญญาประดิษฐ์ ร่วมกับสัญญาณทางสรีระวิทยา
ชื่อผู้เขียน	นางสาว กฤตพร รักนุ้ย นาย สุรพัศ แซ่ตั้น นาย สุรพัศ หกหนู
สาขาวิชา	วิศวกรรมคอมพิวเตอร์และปัญญาประดิษฐ์

คณะกรรมการที่ปรึกษา

.....Mallika K..... (อาจารย์ที่ปรึกษา)

(ผศ. ดร.มัลลิกา เกลี้ยงเคล้า)

คณะกรรมการปริญญานิพนธ์

.....Mallika K..... (อาจารย์ที่ปรึกษา)

(ผศ. ดร.มัลลิกา เกลี้ยงเคล้า)

.....ฐิมาพร..... (กรรมการ)

(ผศ. ดร.ฐิมาพร เพชรแก้ว)

..... (กรรมการ)

(ดร.อาสาฬห์ชัย สุขเกื้อ)

ชื่อโครงงาน	ระบบตรวจวัดความเครียดโดยใช้เทคโนโลยีปัญญาประดิษฐ์ ร่วมกับสัญญาณทางสรีระวิทยา
ชื่อผู้เขียน	นางสาว กฤตพร รักนุ้ย นาย สุรพัศ แซ่ตั้น นาย สุรพัศ หกหนู
อาจารย์ที่ปรึกษา	ผู้ช่วยศาสตราจารย์ ดร.มัลลิกา เกลี้ยงเคล้า
ปริญญาและสาขาวิชา	หลักสูตรวิศวกรรมศาสตร์บัณฑิต สาขาวิศวกรรมคอมพิวเตอร์และปัญญาประดิษฐ์
ปีการศึกษา	2568

บทคัดย่อ

การวิจัยนี้มีวัตถุประสงค์เพื่อพัฒนาระบบต้นแบบสำหรับตรวจวัดภาวะความเครียดในมนุษย์แบบเรียลไทม์ โดยใช้เทคโนโลยีปัญญาประดิษฐ์ร่วมกับสัญญาณทางสรีรวิทยา ได้แก่ สัญญาณคลื่นกิจกรรมไฟฟ้าบนผิวหนัง (Electrodermal Activity : EDA) และความแปรปรวนของอัตราการเต้นของหัวใจ (Heart Rate Variability : HRV) ซึ่งเป็นตัวชี้วัดการตอบสนองต่อความเครียดของระบบประสาทอัตโนมัติ ระบบที่พัฒนาขึ้นประกอบด้วยอุปกรณ์สวมใส่ที่เชื่อมต่อกับเซนเซอร์ชีวภาพ โมเดลการเรียนรู้ของเครื่องที่ใช้ Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM) และ Gated Recurrent Unit (GRU) ในการจำแนกระดับความเครียด และเว็บแอปพลิเคชันสำหรับแสดงผลและแจ้งเตือนข้อมูล กลุ่มตัวอย่างในการเก็บข้อมูลประกอบด้วยอาสาสมัครจำนวน 25 คน โดยทำการเก็บข้อมูลผ่านอุปกรณ์สวมใส่ภายใต้สภาวะกระตุ้นความเครียดที่จำลองขึ้น ผลการวิเคราะห์พบว่าโมเดลสามารถจำแนกระดับความเครียดได้ 4 ระดับ ได้แก่ ปกติ, ต่ำ, ปานกลาง, และสูง ด้วยความแม่นยำเฉลี่ยมากกว่า 85% ระบบสามารถแจ้งเตือนผู้ดูแลเมื่อพบค่าความเครียดในระดับสูงต่อเนื่องกัน และแสดงผลแนวโน้มความเครียดในรูปแบบกราฟและรายงาน ระบบต้นแบบนี้มีศักยภาพในการนำไปประยุกต์ใช้จริงในงานเฝ้าระวังสุขภาพจิต เช่น กลุ่มผู้ป่วยในโรงพยาบาลหรือผู้ป่วยในระบบสาธารณสุข

Title	An AI-driven Stress Detection System using Physiological Signals
Student's Name	Ms. Krittaporn Ruknui
	Mr. Surapat Saetan
	Mr. Surapat Hoknoo
Adviser	Assistant Professor Dr. Mallika Kliangkhlao
Degree and Program	Bachelor of Engineering Program in Computer Engineering
	Artificial Intelligence
Academic Year	2025

Abstract

This research aims to develop a prototype system for real-time stress detection in humans using artificial intelligence integrated with physiological signals, specifically Electrodermal Activity (EDA) and Heart Rate Variability (HRV), which are key indicators of stress response in the autonomic nervous system. The developed system consists of a wearable device connected to biosensors, machine learning models namely Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM), and Gated Recurrent Unit (GRU) for stress level classification, and a web application for data visualization and alert notifications. Data collection was conducted with 25 volunteer participants, using the wearable device under simulated stress-inducing conditions. The analysis results show that the model can classify stress into four levels: normal, low, moderate, and high, with an average accuracy exceeding 85%. The system is capable of issuing alerts when high stress levels are detected consecutively and provides graphical and report-based summaries of stress trends. This prototype demonstrates strong potential for real-world applications in mental health monitoring, particularly for hospital patients and within public healthcare systems.

กิตติกรรมประกาศ

โครงงานวิจัยนี้สำเร็จลุล่วงได้ด้วยความอนุเคราะห์และความเมตตาจาก ผู้ช่วยศาสตราจารย์ ดร.มัลลิกา เกลี้ยงเคล้า อาจารย์ที่ปรึกษาโครงงาน ผู้ซึ่งได้ให้คำปรึกษา คำแนะนำ ข้อคิดเห็น และข้อเสนอแนะที่เป็นประโยชน์อย่างยิ่ง รวมทั้งช่วยตรวจทานและแก้ไขข้อบกพร่องต่าง ๆ ด้วยความเอาใจใส่อย่างดียิ่ง จนทำให้โครงงานวิจัยฉบับนี้มีความสมบูรณ์ คณะผู้วิจัยขอกราบขอบพระคุณท่านมา ณ โอกาสนี้

นอกจากนี้ คณะผู้วิจัยขอขอบพระคุณอาสาสมัครทุกท่านที่ได้สละเวลาอันมีค่าเข้าร่วมการทดลอง และให้ความร่วมมือในการเก็บรวบรวมข้อมูลด้วยความเต็มใจ ส่งผลให้การดำเนินงานวิจัยเป็นไปตามวัตถุประสงค์ที่ตั้งไว้อย่างราบรื่นและสำเร็จลุล่วงตามแผนงานที่กำหนด

กฤตพร รักนุ้ย
สุรพัศ แซ่ตั้น
สุรพัศ หกหนู

สารบัญ

บทที่ 1_บทนำ 1
1.2 วัตถุประสงค์ 3
1.3 ขอบเขตของงาน 3
1.4 ประโยชน์ที่คาดว่าจะได้รับ 4
1.5 ผลที่คาดว่าจะได้รับเมื่อเสร็จสิ้นโครงการ 4
1.6 ขั้นตอนการดำเนินงาน 5
1.7 อุปกรณ์ที่ใช้ในการพัฒนา 6
1.7.1 ด้านซอฟต์แวร์ (Software) 6
1.7.2 ด้านฮาร์ดแวร์ (Hardware) 8
บทที่ 2_ทฤษฎีและเทคโนโลยีที่เกี่ยวข้อง 10
2.1 ทฤษฎีที่เกี่ยวข้อง 10
2.1.1 ภาวะความเครียด 10
2.1.2 สัญญาณทางชีวภาพ EDA และ HRV 11
2.1.3 Signal Processing 15
2.1.4 Algorithm ML 16
2.2 งานวิจัยหรือระบบที่ใกล้เคียง 21
2.3 เทคโนโลยีที่ใช้ในการพัฒนา 26
2.3.1 อุปกรณ์ชุดเซนเซอร์สำหรับวัดสัญญาณทางสรีรวิทยา 26
2.3.2 หน่วยควบคุมการประมวลผลขนาดเล็ก (MCU node) 27
2.3.3 บอร์ดไมโครคอนโทรลเลอร์ (Adafruit HUZZAH32 – ESP32 Feather Board) 28
บทที่ 3_เอกสารความต้องการของระบบ 30
3.1 ภาพรวมของการวิเคราะห์ระบบ 30

สารบัญ (ต่อ)

3.1.1 ขอบเขตงาน 30
3.1.2 กลุ่มผู้ใช้ระบบ 30
3.1.3 วิธีการเก็บข้อมูล 30
3.2 ความต้องการของระบบ 31
3.3 แผนภาพ 32
3.4 คุณลักษณะของระบบ 33
บทที่ 4 การออกแบบระบบ 36
4.1 สถาปัตยกรรมซอฟต์แวร์ของระบบ 36
4.2 การนำเข้าข้อมูล (Data Sensing) 38
4.2.1 กลุ่มตัวอย่างที่เข้ารับการศึกษา 38
4.2.2 สภาพแวดล้อมของห้องทดลอง 38
4.2.3 การติดตั้งอุปกรณ์ชุดเซนเซอร์ 39
4.2.4 การออกแบบการทดลองเก็บข้อมูล 39
4.3 การเตรียมข้อมูล (Data Preprocessing) 43
4.4 การพัฒนาตัวแบบการเรียนรู้ 51
4.5 Data Schema 52
บทที่ 5 การพัฒนา ติดตั้ง และทดสอบระบบ 59
5.1 การพัฒนาอุปกรณ์แบบสวมใส่ (Wearable Device) 59
5.1.1 เซนเซอร์ที่ใช้ในการพัฒนาอุปกรณ์แบบสวมใส่ 59
5.1.2 โครงสร้างการเชื่อมต่ออุปกรณ์ 60
5.1.3 ผลลัพธ์ของของอุปกรณ์ 61
5.2 การพัฒนาโมเดลการตรวจจับระดับความเครียด (Stress Detection Model) 62

สารบัญ (ต่อ)

5.2.1 การทดลองคัดเลือกอัลกอริทึมและการปรับไฮเปอร์พารามิเตอร์ 62
5.2.2 การทดลองความเสถียรของโมเดล 76
5.3 การพัฒนาระบบแสดงผลผ่านเว็บแอปพลิเคชัน (Web Application) 81
บทที่ 6_สรุปผลและข้อเสนอแนะ 86
6.1 สรุปผลการดำเนินงาน 86
6.2 ข้อเสนอแนะ 88
บรรณานุกรม 89
ภาคผนวก ก 94
แบบสอบถามประเมินความเครียดก่อนเข้าร่วมทดลอง 94
ภาคผนวก ข 96
แบบสอบถามข้อมูลทั่วไป 96
ภาคผนวก ค 98
เอกสารขอความยินยอมการเข้าร่วมโครงการวิจัย 98
ภาคผนวก ง 100
แบบทดสอบประเมินความเครียดระหว่างการทดลอง 100
ภาคผนวก จ 102
เอกสารรับรองโครงการวิจัยในมนุษย์ 102
ประวัติผู้เขียน คนที่ 1 104
ประวัติผู้เขียน คนที่ 2 105
ประวัติผู้เขียน คนที่ 3 106

สารบัญตาราง

ตาราง 1 แผนการดำเนินงาน 5
ตาราง 2 รายละเอียดอุปกรณ์ซอฟต์แวร์ (Software) ที่ใช้ในการพัฒนา 6
ตาราง 3 รายละเอียดอุปกรณ์ฮาร์ดแวร์ (Hardware) ที่ใช้ในการพัฒนา 8
ตาราง 4 การเปรียบเทียบงานวิจัยและนวัตกรรมที่เกี่ยวข้อง 23
ตาราง 5 แสดงคุณลักษณะของอุปกรณ์ชุดเซนเซอร์สำหรับวัดสัญญาณทางสรีรวิทยา 26
ตาราง 6 คุณสมบัติ ESP32 27
ตาราง 7 ความต้องการของระบบ 31
ตาราง 8 คุณลักษณะของระบบ 33
ตาราง 9 ตารางแสดงระดับความเครียดและนิยามของความเครียด 41
ตาราง 10 ตารางการเข้ารหัสคลาส (label encoding) 45
ตาราง 11 ข้อมูลที่ได้รับจากอุปกรณ์ก่อนเตรียมข้อมูล 47
ตาราง 12 ข้อมูลที่ได้รับจากอุปกรณ์หลังการเตรียมข้อมูล 47
ตาราง 13 ข้อมูลที่ได้จากแบบสอบถาม 49
ตาราง 14 ข้อมูลที่เลือกใช้สำหรับการพัฒนาตัวแบบการเรียนรู้ 49
ตาราง 15 คุณลักษณะของ Emotibit 59
ตาราง 16 Search Space ไฮเปอร์พารามิเตอร์ของแบบจำลองตระกูล RNN 65
ตาราง 17 ประสิทธิภาพการทดลองจากแบบจำลอง RNN ของ EDA 69
ตาราง 18 ประสิทธิภาพการทดลองจากแบบจำลอง RNN ของ HRV 69
ตาราง 19 ประสิทธิภาพการทดลองจากแบบจำลอง RNN ของ EDA และ HRV 70
ตาราง 20 ประสิทธิภาพการทดลองจากแบบจำลอง LSTM ของ EDA 71
ตาราง 21 ประสิทธิภาพการทดลองจากแบบจำลอง LSTM ของ HRV 72
ตาราง 22 ประสิทธิภาพการทดลองจากแบบจำลอง LSTM ของ EDA และ HRV 72
ตาราง 23 ประสิทธิภาพการทดลองจากแบบจำลอง GRU ของ EDA 74
ตาราง 24 ประสิทธิภาพการทดลองจากแบบจำลอง GRU ของ HRV 74
ตาราง 25 ประสิทธิภาพการทดลองจากแบบจำลอง GRU ของ EDA และ HRV 75
ตาราง 26 ตารางเปรียบเทียบประสิทธิภาพของโมเดลทั้ง 3 โมเดล 80

สารบัญภาพ

ภาพ 1 สัญญาณคลื่นกิจกรรมไฟฟ้าบนผิวหนัง ภาพนี้แสดงสัญญาณ EDA ดิบและที่ถูกกรองแล้ว .. 12
ภาพ 2 สัญญาณความแปรปรวนของอัตราการเต้นของหัวใจ HRV 14
ภาพ 3 ตัวอย่างอุปกรณ์ชุดเซนเซอร์และการติดตั้ง 27
ภาพ 4 บอร์ดไมโครคอนโทรลเลอร์ (Adafruit HUZZAH32 – ESP32 Feather Board)..... 29
ภาพ 5 Use case ภาพรวมของระบบ 33
ภาพ 6 กรอบแนวคิดระบบตรวจวัดความเครียดโดยใช้เทคโนโลยีปัญญาประดิษฐ์ร่วมกับสัญญาณทางสรีระวิทยา 36
ภาพ 7 แสดงตำแหน่งติดตั้งเซนเซอร์ในบริเวณต่าง ๆ ของผู้เข้าร่วมการทดลอง..... 39
ภาพ 8 แผนภาพแสดงขั้นตอนการทดลอง 42
ภาพ 9 แผนภาพแสดงขั้นตอนการเตรียมข้อมูล 43
ภาพ 10 โครงสร้างการเชื่อมต่อของสายสัญญาณ 60
ภาพ 11 ผลการฝึกโมเดลในด้านค่า Loss และ Accuracy ของแบบจำลอง RNN..... 79
ภาพ 12 ผลการฝึกโมเดลในด้านค่า Loss และ Accuracy ของแบบจำลอง LSTM 79
ภาพ 13 ผลการฝึกโมเดลในด้านค่า Loss และ Accuracy ของแบบจำลอง GRU..... 79
ภาพ 14 รูปแบบการแสดงผลหน้าจอ Web Application (Dashboard Page) 81
ภาพ 15 รูปแบบการแสดงผลหน้าจอ Web Application (Detail Page) 83
ภาพ 16 รูปแบบการแสดงผลหน้าจอ Web Application (New Patient Page)..... 84
ภาพ 17 รูปแบบการแสดงผลหน้าจอ Web Application การแก้ไขข้อมูลส่วนตัวของผู้ป่วย..... 85

บทที่ 1
บทนำ

1.1 ที่มาและความสำคัญ

ปัจจุบันปัญหาความท้าทายในด้านสาธารณสุขในการดูแลสุขภาพกายและสุขภาพจิต โดยเฉพาะอย่างยิ่งในด้านความเครียดและปัญหาภาวะซึมเศร้า ซึ่งความเครียดเป็นกลไกการตอบสนองตามธรรมชาติของร่างกายต่อการเปลี่ยนแปลงหรือภาวะกดดัน โดยความเครียดจะกระตุ้นการตอบสนองทางร่างกาย อารมณ์ และพฤติกรรมในหลากหลายรูปแบบอีกทั้งยังสามารถแสดงออกเป็นสัญญาณของปฏิกิริยาต่อโรคต่าง ๆ ได้ (Dhama และคณะ, 2019)

การศึกษาของสถาบันวิจัยระบบสาธารณสุข (สถาบันวิจัยระบบสาธารณสุข, 2563) พบว่ามีผู้ประสบปัญหาภาวะความเครียดถึงร้อยละ 30 แต่มีเพียงร้อยละ 15 เท่านั้นที่ได้รับการวินิจฉัยและการดูแลอย่างเหมาะสม เนื่องจากเครื่องมือในการตรวจสอบภาวะความเครียดในปัจจุบันยังคงพึ่งพาการใช้แบบสอบถามประเมินความเครียด (Questionnaires) ซึ่งการตอบแบบสอบถามที่ได้มักไม่ตรงความเป็นจริงเนื่องจากความกลัวที่จะป่วยและกลายเป็นภาระของญาติ ดังนั้นผู้ป่วยยังคงต้องพึ่งพาการสังเกตการณ์จากญาติ และการคัดกรองโดยระบบบริการสุขภาพจิตของภาครัฐ ซึ่งในประเทศไทยยังมีข้อจำกัดทั้งในแง่ของการขาดแคลนบุคลากรทางการแพทย์ที่เชี่ยวชาญเฉพาะด้านอีกทั้งยังมีการกระจายตัวของบริการที่ไม่ทั่วถึงโดยเฉพาะในพื้นที่ห่างไกล นอกจากนั้นการดูแลผู้ที่มีภาวะเครียดหรือปัญหาทางสุขภาพจิตยังต้องอาศัยการเอาใจใส่ เวลา และความเชี่ยวชาญ ซึ่งนับเป็นอุปสรรคสำคัญในการให้การดูแลและส่งผลให้เกิดข้อจำกัดในการให้ความสำคัญ การรับรู้ และจัดการกับภาวะความเครียดของผู้ป่วยได้อย่างมีประสิทธิภาพ (Shah & Tidy, 2024) เพื่อจัดการกับข้อจำกัดดังกล่าว สาธารณสุขของประเทศไทยจึงต้องการเทคโนโลยีด้านตรวจจับภาวะความเครียดแบบอัตโนมัติ ที่มีความสำคัญอย่างยิ่งในการลดภาระของผู้ดูแลและบุคลากรทางการแพทย์โดยทำหน้าที่คัดกรองและแจ้งเตือนเมื่อพบความเสี่ยงได้ตั้งแต่ระยะเริ่มต้น

การศึกษาด้านเทคโนโลยีทางการแพทย์ในปัจจุบันพบว่า การวัดอารมณ์และความเครียดของมนุษย์สามารถวัดได้ผ่านสัญญาณสรีรวิทยา (Physiological Signal) ได้แก่ คลื่นกิจกรรมไฟฟ้าผิวหนัง (Electrodermal Activity: EDA) สัญญาณไฟฟ้าหัวใจ (Electrocardiogram: ECG) และความแปรปรวนของอัตราการเต้นของหัวใจ (Heart Rate Variability: HRV) โดย Goumopoulus and Menti (Goumopoulos & Menti, 2019) ได้นำเสนอการตรวจวัดภาวะเครียดในมนุษย์โดยใช้อุปกรณ์ชิมเมอร์ (Shimmer Sensor) ซึ่งพิสูจน์ได้ว่าสัญญาณ EDA และ HRV มีประสิทธิภาพในการนำไปใช้ประเมินความเครียดได้ แต่ทว่าอุปกรณ์ดังกล่าวมีขนาดใหญ่ทำให้ไม่สนับสนุนการนำไปใช้งาน

จริง ในขณะที่ Yu และคณะ (Yu และคณะ, 2024) ได้นำเสนอการงานวิจัยเพื่อศึกษาปฏิกิริยาทางสรีรวิทยาที่เกิดจากความเครียดโดยใช้สัญญาณ EDA และ ECG โดยงานวิจัยนี้นำเสนอการทดลองในมนุษย์ที่ถูกกระตุ้นภาวะความเครียดด้วยการเร่งความเร็วแบบเฉื่อย (Passive Translational Acceleration: PTA) ด้วยอุปกรณ์ไร้สาย (BIOPAC MP150 System) โดยจากการวิจัยพบว่าสัญญาณ EDA และ ECG สามารถนำมาใช้ประเมินภาวะความเครียดของมนุษย์ที่เกิดการเร่งความเร็วแบบเฉื่อยได้อย่างมีนัยยะสำคัญ แต่ทว่าด้วยข้อจัดกัดของการวัดคลื่น ECG อุปกรณ์จำเป็นต้องติดตั้งตำแหน่งบริเวณหน้าอกของผู้ใช้งาน ส่งผลให้ไม่เอื้ออำนวยต่อการใช้งานจริงในชีวิตประจำวันได้ Ding และคณะ (Ding และคณะ, 2024) ได้ศึกษาและพัฒนาเซนเซอร์ตรวจวัดระดับฮอร์โมนคอร์ติซอลในเหงื่อ (Sweat Cortisol) ซึ่งเป็นฮอร์โมนที่ร่างกายมนุษย์จะสร้างขึ้นอย่างอัตโนมัติเมื่อร่างกายและอวัยวะต่าง ๆ มีภาวะความเครียด โดยผู้วิจัยได้มีสมมติฐานในการวัดฮอร์โมนดังกล่าวผ่านสัญญาณ HRV โดยการใช้สมาร์ทวอทช์ (Smartwatch) ที่สามารถตรวจสอบระดับความเครียดแบบเรียลไทม์และไม่รุกล้ำความเป็นส่วนตัว ซึ่งทดลองผ่านการวัดข้อมูลความเครียดของมนุษย์ขณะการนำเสนองาน จากผลการวิจัยพบว่าระดับคอร์ติซอลในเหงื่อและ HRV มีการตอบสนองของร่างกายต่อความเครียดได้ แต่ทว่างานวิจัยนี้ยังไม่มีการวัดผลความแม่นยำในการตรวจสอบและไม่ระบุระดับความเครียดที่สามารถนำไปใช้สนับสนุนการคัดกรองและแจ้งเตือนได้

จากงานศึกษาข้างต้นพบว่าการนำเทคโนโลยีด้านการแพทย์มาบูรณาการและพิสูจน์สมมติฐานว่าสัญญาณทางสรีรวิทยามีการเปลี่ยนแปลงตามระดับความเครียดของมนุษย์จริง แต่ทว่างานวิจัยดังกล่าวอาศัยการวัดผลด้วยค่าสหสัมพันธ์ (Correlation) และนัยยะสำคัญทางสถิติ ซึ่งยังไม่สามารถนำไปใช้พัฒนากลไกและระบบการตรวจจับภาวะความเครียดแบบอัตโนมัติ และยังคงต้องพึ่งพามนุษย์และผู้เชี่ยวชาญในการประเมินและวินิจฉัยข้อมูลสัญญาณซึ่งมีความแปรปรวนตามสรีรวิทยา เพศสภาพ อายุ และโรคประจำตัวของมนุษย์แต่ละคน ดังนั้นโครงการนี้จึงมีวัตถุประสงค์เพื่อพัฒนาระบบตรวจวัดความเครียดโดยใช้เทคโนโลยีปัญญาประดิษฐ์ร่วมกับสัญญาณทางสรีระวิทยาโดยใช้เทคโนโลยีการเรียนรู้ของเครื่อง (Machine Learning) ในการเรียนรู้ความสัมพันธ์และแพทเทิร์นระหว่างคุณลักษณะที่มีความหลากหลายของมนุษย์ต่อสภาวะความเครียดในระดับต่าง ๆ โดยโครงการนี้มีเป้าหมายเพื่อนำไปสู่การพัฒนาเทคโนโลยีในการสนับสนุนการดูแลผู้ป่วยและเพิ่มศักยภาพในการยกระดับคุณภาพชีวิตของผู้ป่วยได้ในระยะยาว โครงการนี้จึงเป็นก้าวสำคัญในการพัฒนาระบบสาธารณสุขของประเทศให้พร้อมรับมือกับสังคมได้อย่างสมบูรณ์

1.2 วัตถุประสงค์

1. เพื่อศึกษากรอบแนวคิดการนำเทคโนโลยีปัญญาประดิษฐ์และการวัดสัญญาณคลื่นกิจกรรมไฟฟ้าบนผิวหนัง และความแปรปรวนของอัตราการเต้นของหัวใจ เพื่อนำไปใช้ในการตรวจจับความเครียด
2. เพื่อพัฒนาตัวแบบการเรียนรู้สำหรับการจำแนกระดับความเครียดโดยใช้สัญญาณคลื่นกิจกรรมไฟฟ้าบนผิวหนังและความแปรปรวนของอัตราการเต้นของหัวใจ
3. เพื่อพัฒนาระบบต้นแบบการตรวจจับความเครียดแบบเรียลไทม์

1.3 ขอบเขตของงาน

ระบบการตรวจวัดความเครียดประกอบด้วยผู้ใช้งาน 2 กลุ่ม คือ ผู้ดูแล และผู้ป่วย โดยคำนึงถึงข้อจำกัดด้านการใช้เทคโนโลยี แต่ละกลุ่มมีการทำงานดังนี้

ผู้ดูแล

- สามารถลงทะเบียนและจัดการข้อมูลผู้ป่วยในความดูแล
- สามารถดูรายงานและแนวโน้มความเครียดของผู้ป่วย
- รับการแจ้งเตือนเมื่อระบบตรวจพบความเครียดในระดับที่กำหนด
- สามารถปรับแต่งการตั้งค่าการแจ้งเตือนตามความเหมาะสม
- รับคำแนะนำจากระบบในการดูแลและช่วยเหลือผู้ป่วยเมื่อเกิดภาวะเครียด

ระบบการตรวจวัดความเครียดประกอบด้วยระบบย่อย ดังนี้

1) ระบบจัดการข้อมูลสมาชิก
   - ผู้ดูแลระบบสามารถกำหนดชื่อผู้ใช้ (username) และรหัสผ่าน (password) ให้กับผู้ดูแลได้
   - ในการเข้าใช้งานระบบจะมีการยืนยันตัวตนของผู้ใช้ โดยเชื่อมต่อกับระบบ OAuth authenticate เพื่อความปลอดภัยของข้อมูล
2) ระบบจัดการการตรวจวัดความเครียด
   - ผู้ดูแลสามารถดูข้อมูลการตรวจวัดความเครียดของผู้ป่วยที่อยู่ในความดูแลได้
   - ผู้ดูแลสามารถดูข้อมูลการตรวจวัดความเครียดตามช่วงเวลาหรือระดับความเครียดได้
   - ผู้ดูแลสามารถดูข้อมูลผู้ป่วย และประวัติการตรวจวัดความเครียดที่ตนเองมีสิทธิ์เข้าถึงได้
3) ระบบตรวจวัดและแจ้งเตือนระดับความเครียด

- ระบบสามารถตรวจวัดระดับความเครียดจากสัญญาณทางสรีระวิทยาโดยการใช้เทคโนโลยีการเรียนรู้ของเครื่องเพื่อเพิ่มความแม่นยำในการตรวจจับความเครียด
- ระบบสามารถแจ้งเตือนผู้ดูแลเมื่อตรวจพบความเครียดของผู้ป่วยในระดับที่กำหนด

4) ระบบรายงานผล
   - ระบบสามารถสร้างรายงานสรุปภาวะความเครียดของผู้ป่วยสำหรับผู้ดูแล
   - ผู้ดูแลสามารถดูรายงานสรุปแนวโน้มความเครียดของผู้ป่วยได้
   - ระบบสามารถส่งออกข้อมูลการตรวจวัดความเครียดในรูปแบบเอกสาร PDF ได้

1.4 ประโยชน์ที่คาดว่าจะได้รับ

โครงงานนี้เป็นการบูรณาการเทคโนโลยีด้านปัญญาประดิษฐ์และสัญญาณทางสรีรวิทยาเพื่อพัฒนาระบบตรวจวัดความเครียดที่มีความแม่นยำสูง ซึ่งจะช่วยเพิ่มประสิทธิภาพในการคัดกรองและประเมินภาวะความเครียดในผู้ป่วยได้อย่างรวดเร็วและแม่นยำมากขึ้น ระบบนี้เป็นต้นแบบที่มีเป้าหมายระยะยาวเพื่อช่วยลดภาระงานของบุคลากรทางการแพทย์และผู้ดูแลในการสังเกตและติดตามสภาวะสุขภาพจิตของผู้ป่วย อีกทั้งยังสามารถแจ้งเตือนเมื่อพบความเสี่ยงในการเกิดภาวะเครียดสูง ช่วยให้ผู้ดูแลสามารถดำเนินการจัดการปัญหาได้ตั้งแต่ระยะเริ่มต้น นอกจากนี้ระบบที่พัฒนาขึ้นยังสามารถนำไปประยุกต์ใช้ในสภาพแวดล้อมการดูแลผู้สูงอายุได้อย่างมีประสิทธิภาพ ไม่ว่าจะเป็นในสถานพยาบาลหรือที่บ้าน ซึ่งเป็นการส่งเสริมให้ผู้สูงอายุมีคุณภาพชีวิตที่ดีขึ้น และช่วยเตรียมความพร้อมให้กับระบบสาธารณสุขของประเทศไทยในการรับมือกับการเข้าสู่สังคมผู้สูงอายุอย่างสมบูรณ์

1.5 ผลที่คาดว่าจะได้รับเมื่อเสร็จสิ้นโครงการ

1. ได้กรอบแนวคิดการนำเทคโนโลยีปัญญาประดิษฐ์และการวัดสัญญาณคลื่นกิจกรรมไฟฟ้าบนผิวหนัง (EDA) และความแปรปรวนของอัตราการเต้นของหัวใจ (HRV) เพื่อนำไปใช้ในการตรวจจับความเครียด
2. ได้ตัวแบบการเรียนรู้สำหรับการจำแนกระดับความเครียดโดยใช้สัญญาณคลื่นกิจกรรมไฟฟ้าบนผิวหนังและความแปรปรวนของอัตราการเต้นของหัวใจ
3. ได้ระบบต้นแบบการตรวจจับความเครียดแบบเรียลไทม์ที่แม่นยำ โดยใช้ข้อมูลสัญญาณ EDA และ HRV ร่วมกับเทคโนโลยีการเรียนรู้ของเครื่อง (Machine Learning) เพื่อเรียนรู้และประเมินระดับความเครียด

1.6 ขั้นตอนการดำเนินงาน

ระยะเวลาดำเนินงาน 11 เดือน ตั้งแต่เดือน ตุลาคม พ.ศ. 2567 ถึงเดือน สิงหาคม พ.ศ. 2568

ตาราง 1 แผนการดำเนินงาน

แผนการดำเนินงาน	ต.ค. 67				พ.ย. 67				ธ.ค. 67				ม.ค. 68				ก.พ. 68				มี.ค. 68				เม.ย. 68				พ.ค. 68				มิ.ย. 68				ก.ค. 68				ส.ค. 68			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
ศึกษาปัญหาและระบบ																																											
เขียนข้อเสนอโครงงาน																																											
สอบข้อเสนอโครงงาน																																											
รวบรวมและวิเคราะห์ข้อมูล																																											
ทดสอบเครื่องมือและอัลกอริทึมสำหรับพัฒนาโมเดล																																											
พัฒนาโมเดลสำหรับประมวลผล																																											
สอบความก้าวหน้าโครงงาน 1																																											
พัฒนาระบบส่วนหน้าและส่วนหลัง																																											
ทดสอบและประเมินผล																																											
สอบกลางภาคโครงงาน 2																																											
สรุปผลโครงงาน																																											
สอบโครงงาน 2																																											
สอบโครงงาน 2 ภาคโปสเตอร์																																											

1.7 อุปกรณ์ที่ใช้ในการพัฒนา

การพัฒนาระบบ ผู้พัฒนาได้เลือกใช้เครื่องมือที่หลากหลาย เพื่อการใช้งานที่หลากหลาย ครบถ้วนตามความต้องการซึ่งมีทั้งซอฟต์แวร์และฮาร์ดแวร์ดังนี้

1.7.1 ด้านซอฟต์แวร์ (Software)

ตาราง 2 รายละเอียดอุปกรณ์ซอฟต์แวร์ (Software) ที่ใช้ในการพัฒนา

ชุดอุปกรณ์/ชุดคำสั่ง	**คำอธิบาย**
ระบบปฏิบัติการ Window 11	**Window 11** เป็นระบบปฏิบัติการใหม่ล่าสุดจาก Microsoft ที่มาพร้อมกับอินเทอร์เฟซใหม่ที่ทันสมัยขึ้น พร้อมคุณสมบัติการทำงาน แบบไฮบริด ช่วงเพิ่มประสิทธิภาพการทำงานระยะไกล ปกป้องได้ทั้งฮาร์ดแวร์ ซอร์ฟแวร์ ไปจนถึงระบบ ไอคลาวด์
ฐานข้อมูล NoSQL • MongoDB	**MongoDB** เป็นฐานข้อมูลแบบ NoSQL ที่มี ความยืดหยุ่นและปรับขนาดได้ สำหรับการพัฒนา โมบายแอพ เว็บไซต์ และเซิร์ฟเวอร์
ฐานข้อมูล SQL • MySQL	**MySQL** เป็นระบบจัดการฐานข้อมูล SQL แบบ โอเพ่นซอร์ส โดยข้อมูลจะถูกเก็บในฐานข้อมูล ด้วยโครงสร้างแบบแถวและคอลัมน์ MySQL เป็นซอฟต์แวร์ที่ทำให้ผู้ใช้สามารถสร้างและจัดการ ฐานข้อมูลได้
ซอฟต์แวร์สำหรับการพัฒนาระบบ • Neurokit • scikit-learn, pandas • Node.js JavaScript runtime • Next.js • Github • Matplotlib, seaborn • Colab (Google Colab)	**neurokit2** ไลบรารี (library) ที่ถูกพัฒนาขึ้นด้วย ภาษา Python สำหรับการวิเคราะห์ข้อมูลทาง กายภาพ มีวัตถุประสงค์เพื่อช่วยให้นักวิจัยและ นักพัฒนาสามารถทำการวิเคราะห์ข้อมูลทาง กายภาพที่ได้มาจากการวัดกิจกรรมร่างกาย **scikit-learn, pandas** ไลบรารี (library) สำหรับ การทำงานกับการเรียนรู้ machine learning ด้วย 7 ภาษา Python เป็นหนึ่งในไลบรารีที่ได้รับความ นิยมสูงสุดสำหรับการทำงานทางด้านนี้และมี ความหลากหลายของอัลกอริทึม **FastAPI** framework สำหรับการสร้าง API (Application Programming Interface) ด้วยภาษา Python ที่ได้รับความนิยม เนื่องจากความเร็วและ ประสิทธิภาพที่สูง **Node.js JavaScript runtime** Environment สำหรับการพัฒนาแอปพลิเคชันที่ใช้ JavaScript บนฝั่งเซิร์ฟเวอร์ โดย Node.js runtime มีคุณสมบัติหลักที่ช่วยให้สามารถรันโค้ด JavaScript นอกเบราว์เซอร์ได้

ชุดอุปกรณ์/ชุดคำสั่ง	คำอธิบาย
	ซึ่งแตกต่างจากเดิมที่ JavaScript ถูกออกแบบมาเพื่อทำงานในเบราว์เซอร์เท่านั้น **Next.js** เป็นเฟรมเวิร์กสำหรับการพัฒนาเว็บแอปพลิเคชันที่ใช้ React ซึ่งถูกออกแบบมาเพื่อช่วยให้นักพัฒนาสร้างเว็บแอปพลิเคชันที่มีประสิทธิภาพสูง **Github** เป็นแพลตฟอร์มคลาวด์ที่ให้บริการ นวัตกรรมด้านคลาวด์และบริการความรู้ด้านเทคโนโลยีของ Google สำหรับธุรกิจและนักพัฒนาซอฟต์แวร์ร่วมกัน (Collaboration) โดยใช้ Git ซึ่งเป็นระบบควบคุมเวอร์ชัน (Version Control System) **Matplotlib, seaborn** เป็นไลบรารีใน Python ที่ใช้สำหรับการสร้างกราฟและการแสดงผลข้อมูลในรูปแบบ 2D (และบางส่วนใน 3D) ซึ่งเหมาะสำหรับการวิเคราะห์ข้อมูลและการนำเสนอข้อมูลด้วยภาพ (Data Visualization) **Colab (Google Colab)** เป็นเครื่องมือออนไลน์ฟรีที่ช่วยให้นักพัฒนาสามารถเขียนและรันโค้ด Python ได้ผ่านเบราว์เซอร์ โดยไม่ต้องติดตั้งซอฟต์แวร์ใด ๆ บนเครื่องคอมพิวเตอร์ของตนเอง เป็นที่นิยมอย่างมากในหมู่นักวิจัยและนักพัฒนาที่ทำงานเกี่ยวกับ Machine Learning, Data Science และ Deep Learning
ซอฟต์แวร์สำหรับการจัดการเอกสาร • Microsoft Office • Google Drive • Google Sheets • Google Docs • Google Forms	**Microsoft Office** ชุดโปรแกรมสำนักงานที่พัฒนาและจัดจำหน่ายโดย Microsoft ซึ่งออกแบบมาเพื่อช่วยงานด้านเอกสาร การคำนวณ และการนำเสนองาน ใช้งานได้ทั้งแบบติดตั้งในเครื่องและออนไลน์ผ่าน Microsoft 365 ประกอบด้วยแอปพลิเคชันยอดนิยม **Google Drive** บริการพื้นที่เก็บข้อมูลออนไลน์ (Cloud Storage) จาก Google ช่วยให้ผู้ใช้จัดเก็บไฟล์ต่าง ๆ เช่น เอกสาร รูปภาพ และวิดีโอ รวมถึงสามารถแชร์ไฟล์กับผู้อื่นและเข้าถึงได้ทุกที่ผ่านอินเทอร์เน็ต โดยเชื่อมต่อกับบริการในชุด Google Workspace **Google Sheets** แอปพลิเคชันตารางข้อมูลที่ทำงานบนคลาวด์จาก Google ใช้สำหรับจัดการข้อมูล การคำนวณ และการวิเคราะห์ รองรับการทำงานร่วมกันแบบเรียลไทม์ สามารถแชร์และแก้ไขไฟล์พร้อมกันได้ **Google Docs** แอปพลิเคชันจัดการเอกสารข้อความที่ทำงานบนคลาวด์

ชุดอุปกรณ์/ชุดคำสั่ง	คำอธิบาย
	จาก Google ใช้สำหรับพิมพ์ จัดรูปแบบ และแก้ไขเอกสาร รองรับการทำงานแบบออนไลน์พร้อมกันหลายคน **Google Forms** แอปพลิเคชันสร้างแบบสอบถามหรือแบบฟอร์มออนไลน์จาก Google ใช้สำหรับการเก็บข้อมูล เช่น การสำรวจความคิดเห็นหรือการลงทะเบียน
ซอฟต์แวร์สำหรับการสื่อสาร • Discord	**Discord** แพลตฟอร์มการสื่อสารแบบออนไลน์ที่เน้นการพูดคุยผ่านข้อความ เสียง และวิดีโอ เหมาะสำหรับการสร้างชุมชนหรือกลุ่มสนทนา เช่น ทีมงาน หรือกลุ่มเพื่อน มีฟีเจอร์การสร้างเซิร์ฟเวอร์ส่วนตัว รองรับการแชร์หน้าจอ การส่งไฟล์ และบอทเพื่อเพิ่มประสิทธิภาพการใช้งาน

1.7.2 ด้านฮาร์ดแวร์ (Hardware)

ตาราง 3 รายละเอียดอุปกรณ์ฮาร์ดแวร์ (Hardware) ที่ใช้ในการพัฒนา

ชุดอุปกรณ์/ชุดคำสั่ง	คำอธิบาย
เทคโนโลยีที่ใช้ • Emotibit • Microprocessor (ESP32) • TFT Display 1.8” 128 x 160	**EmotiBit** คืออุปกรณ์ที่ใช้สำหรับการติดตามข้อมูลทางชีวภาพ (biometric) และการวัดสัญญาณทางสรีรวิทยา เช่น อัตราการเต้นของหัวใจ การหายใจ อุณหภูมิร่างกาย และการเคลื่อนไหวของร่างกาย โดยอุปกรณ์นี้ได้รับการออกแบบเพื่อใช้ในงานวิจัย การพัฒนาสุขภาพ หรือการสร้างแอปพลิเคชันที่เกี่ยวข้องกับการติดตามสุขภาพและสมรรถภาพร่างกาย **ESP32** เป็นไมโครคอนโทรลเลอร์ (Microcontroller) ที่ออกแบบโดยบริษัท Espressif Systems โดยเป็นชิปที่มีประสิทธิภาพสูงและมีฟีเจอร์ครบครันสำหรับงาน IoT (Internet of Things) และระบบฝังตัว (Embedded Systems) ด้วยความสามารถในการเชื่อมต่อ Wi-Fi และ Bluetooth **TFT Display 1.8” 128 x 160** เป็นหน้าจอแสดงผลชนิด TFT (Thin-Film Transistor) ขนาด 1.8 นิ้ว ที่มีความละเอียด 128 x 160 พิกเซล ซึ่งสามารถแสดงผลแนวนอนได้อย่างชัดเจนและคมชัด เหมาะสำหรับใช้แสดงข้อมูลแบบเรียลไทม์

ชุดอุปกรณ์/ชุดคำสั่ง	คำอธิบาย
	รวมถึงผลลัพธ์จากการวัดค่าทางชีวภาพและข้อมูลต่าง ๆ จากอุปกรณ์อย่าง EmotiBit
เครื่องคอมพิวเตอร์สำหรับการพัฒนา • Lenovo Legion 5 15IAH7 • Lenovo ideapad Gaming 3-15ACH6 • Lenovo Yoga Pro 7 14IMH9	**Lenovo Legion 5 15IAH7** • CPU: 12th Gen Intel(R) Core (TM) i5-12500H 2.50 GHz • GPU: NVIDIA GeForce RTX 3050 Ti (4 GB GDDR6) • RAM: 16.0 GB (15.7 GB usable) • OS: Window 11 Home **Lenovo ideapad Gaming 3-15ACH6** • CPU: AMD Ryzen 7 5800H with Radeon Graphics 3.20 GHz • GPU: NVIDIA GeForce RTX 3060 (6GB GDDR6) • RAM: 32.0 GB (27.9 GB usable) • OS: Window 11 Home **Lenovo Yoga Pro 7 14IMH9** • CPU: Processor: Intel(R) Core (TM) Ultra 7 155H • RAM: 32 GB (31.4 GB usable) • OS: Window 11 Home

บทที่ 2
ทฤษฎีและเทคโนโลยีที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 ภาวะความเครียด

ภาวะความเครียด (Stress) เป็นปฏิกิริยาทางสรีรวิทยาและจิตวิทยาที่เกิดขึ้นเมื่อบุคคลเผชิญกับสิ่งเร้าหรือสถานการณ์ที่ท้าทาย (Yu และคณะ, 2024) กลไกการตอบสนองต่อความเครียดเกี่ยวข้องโดยตรงกับระบบประสาทอัตโนมัติ (Autonomic Nervous System, ANS) ซึ่งประกอบด้วยระบบประสาทซิมพาเทติก (Sympathetic Nervous System, SNS) และระบบประสาทพาราซิมพาเทติก (Parasympathetic Nervous System, PNS) ระบบ SNS (Haque และคณะ, 2024) มีหน้าที่ในการเตรียมร่างกายสำหรับสถานการณ์ที่ต้องใช้พลังงานอย่างรวดเร็ว เช่น การต่อสู้หรือการหลบหนี (fight-or-flight response) เมื่อเกิดความเครียดหรือความตื่นเต้น ร่างกายจะตอบสนองโดยการเร่งการเต้นของหัวใจ เพิ่มความดันโลหิต และเพิ่มปริมาณเลือดที่ไหลไปยังกล้ามเนื้อใหญ่ ๆ เพื่อให้พร้อมสำหรับการตอบสนองต่อสถานการณ์ฉุกเฉิน นอกจากนี้ ระบบซิมพาเทติกยังมีส่วนกระตุ้นการหลั่งฮอร์โมนคอร์ติซอลจากต่อมหมวกไต ซึ่งมีผลเพิ่มระดับน้ำตาลในเลือดเพื่อให้พลังงานแก่ร่างกาย ในขณะที่ PNS จะทำหน้าที่ช่วยให้ร่างกายกลับสู่ภาวะสมดุลหลังจากเผชิญกับความเครียด

ความเครียดสามารถแบ่งออกเป็น 3 ระดับหลัก (Haque และคณะ, 2024)

1. ความเครียดระดับต่ำ (Low stress) เป็นภาวะที่ร่างกายสามารถจัดการได้อย่างมีประสิทธิภาพ อาจก่อให้เกิดการตื่นตัวและเพิ่มประสิทธิภาพการทำงานในระยะสั้น
2. ความเครียดระดับปานกลาง (Moderate stress) ร่างกายเริ่มแสดงอาการตอบสนองต่อความเครียดที่ชัดเจนขึ้น แต่ยังสามารถปรับตัวได้ หากเรื้อรังอาจนำไปสู่ปัญหาสุขภาพ
3. ความเครียดระดับสูง (High stress) เป็นภาวะที่ร่างกายไม่สามารถจัดการกับความเครียดได้อย่างมีประสิทธิภาพ ส่งผลให้เกิดการตอบสนองทางสรีรวิทยาที่รุนแรง เช่น การหลั่งฮอร์โมนคอร์ติซอล (Cortisol) ในปริมาณมาก

ผลกระทบของความเครียด ส่งผลต่อทั้งร่างกายและจิตใจ ซึ่งสามารถทำให้เกิดผลกระทบที่หลากหลายและรุนแรงได้ โดยแบ่งออกได้เป็นสองด้านหลักๆ ดังนี้

1) ผลกระทบทางร่างกาย ความเครียดมีผลต่อระบบการทำงานของร่างกายหลายระบบ (Haque และคณะ, 2024) โดยเฉพาะอย่างยิ่งระบบหัวใจและหลอดเลือด ความเครียดเรื้อรังจะทำให้หัวใจเต้นเร็วขึ้นและมีความดันโลหิตสูง นอกจากนี้ความเครียดยังส่งผลให้กล้ามเนื้อตึงเครียด โดยเฉพาะบริเวณคอ ไหล่ และหลัง ซึ่งอาจนำไปสู่ความเจ็บปวดและความไม่สบายตัวในระยะยาว นอกจากนี้ความเครียดยังส่งผลต่อระบบย่อยอาหาร ทำให้เกิดปัญหาเช่น กรดไหลย้อน ท้องอืด หรือแม้แต่การย่อยอาหารที่ผิดปกติ การที่ร่างกายต้องเผชิญกับความเครียดอย่างต่อเนื่องยังอาจก่อให้เกิดโรคเรื้อรัง เช่น โรคหัวใจและหลอดเลือด ความดันโลหิตสูง โรคอ้วน และโรคเบาหวาน เนื่องจากการหลั่งฮอร์โมนคอร์ติซอลในระดับสูงอย่างต่อเนื่อง ซึ่งทำให้การเผาผลาญน้ำตาลและการสะสมไขมันในร่างกายเปลี่ยนแปลงไป

นอกจากนี้ความเครียดยังส่งผลต่อระบบภูมิคุ้มกัน (Haque และคณะ, 2024) ทำให้ความสามารถของร่างกายในการต่อสู้กับโรคลดลง จึงทำให้มีโอกาสป่วยจากโรคติดเชื้อ เช่น ไข้หวัด หรือแม้แต่โรคร้ายแรงอย่างมะเร็งได้ง่ายขึ้นในระยะยาว หากความเครียดยังคงอยู่เป็นเวลานาน โดยเฉพาะความเครียดที่ไม่ได้รับการจัดการอย่างถูกต้อง จะทำให้ระบบต่างๆ ของร่างกายเกิดความผิดปกติ ทำให้เกิดปัญหาสุขภาพในหลากหลายรูปแบบ

2) ผลกระทบทางจิตใจ ในด้านจิตใจ ความเครียดสามารถทำให้เกิดความวิตกกังวล ซึมเศร้า และอารมณ์ผันผวนได้ (Yu และคณะ, 2024) ซึ่งอาจส่งผลต่อสมาธิและความสามารถในการตัดสินใจของบุคคล ทำให้การทำงานและการเรียนรู้มีประสิทธิภาพลดลง นอกจากนี้ ความเครียดยังส่งผลให้เกิดความเหนื่อยล้าทางจิตใจ ซึ่งทำให้บุคคลรู้สึกหมดแรง หมดกำลังใจ และไม่สามารถผ่อนคลายได้แม้ว่าจะหยุดพักก็ตาม

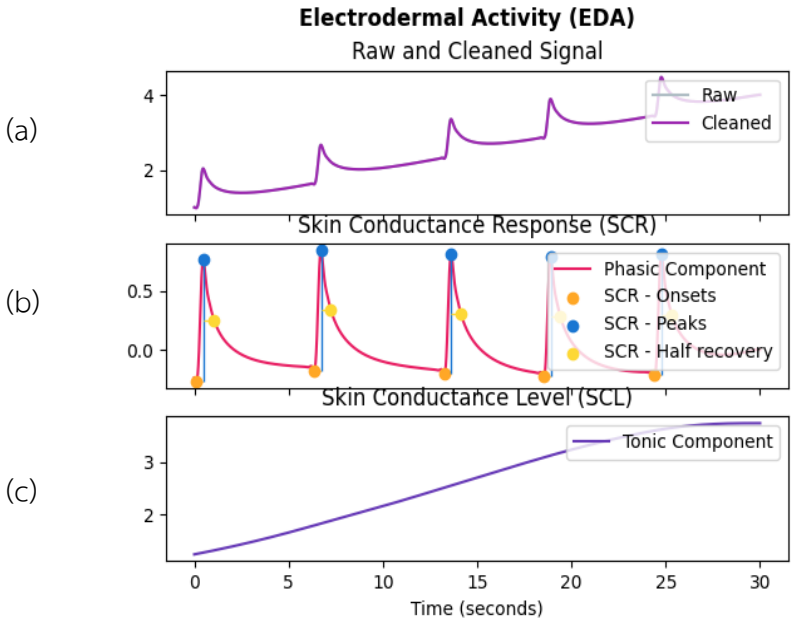
ผลกระทบที่รุนแรงกว่านั้นคือความเครียดเรื้อรังที่ไม่ได้รับการจัดการอาจนำไปสู่ปัญหาสุขภาพจิตอย่างรุนแรง (World Health Organization, 2013) เช่น โรคซึมเศร้า โรควิตกกังวล และโรคเครียดหลังเหตุการณ์ร้ายแรง (Post-Traumatic Stress Disorder: PTSD) ซึ่งทำให้คุณภาพชีวิตของบุคคลลดลง นอกจากนี้ ความเครียดยังส่งผลต่อความสัมพันธ์ระหว่างบุคคล ทำให้เกิดความขัดแย้งในครอบครัวหรือที่ทำงานได้ง่ายขึ้น ความสามารถในการแก้ไขปัญหาและการตัดสินใจอย่างมีเหตุผลลดลง ทำให้มีการตัดสินใจที่ไม่ถูกต้องหรือการแก้ปัญหาที่ไม่มีประสิทธิภาพ

2.1.2 สัญญาณทางชีวภาพ EDA และ HRV

1) สัญญาณคลื่นกิจกรรมไฟฟ้าบนผิวหนัง EDA (Electrodermal Activity)

สัญญาณ EDA คือการวัดการเปลี่ยนแปลงของการนำไฟฟ้าที่ผิวหนัง ซึ่งเป็นผลจากการทำงานของต่อมเหงื่อที่ถูกควบคุมโดยระบบประสาทซิมพาเทติก (SNS) เมื่อต่อมเหงื่อถูกกระตุ้น (Yu และคณะ, 2024) เช่น เมื่อเกิดความเครียดหรือความตื่นเต้น จะเกิดการเพิ่มของการนำไฟฟ้าผ่านผิวหนัง ซึ่งสามารถวัดได้เป็นสัญญาณ EDA โดยทั่วไป การวิเคราะห์ EDA จะประกอบด้วยสองส่วนหลักคือ:

1. Skin Conductance Level (SCL) เป็นส่วนที่แสดงการเปลี่ยนแปลงช้าๆ ของการนำไฟฟ้าที่ผิวหนัง และเป็นตัวชี้วัดที่แสดงระดับความเครียดหรือการตื่นตัวในระยะยาว
2. Skin Conductance Response (SCR) เป็นการตอบสนองแบบรวดเร็วของการนำไฟฟ้า ซึ่งเกิดขึ้นจากการตอบสนองต่อสิ่งเร้าภายนอกหรือภายในที่มีผลต่อความเครียด เช่น การได้ยินเสียงดังหรือการเห็นภาพที่ตื่นเต้น SCR จึงเป็นตัวบ่งชี้ถึงความตื่นเต้นในช่วงเวลาสั้นๆ และสามารถนำมาใช้วิเคราะห์การตอบสนองของระบบประสาทซิมพาเทติกได้



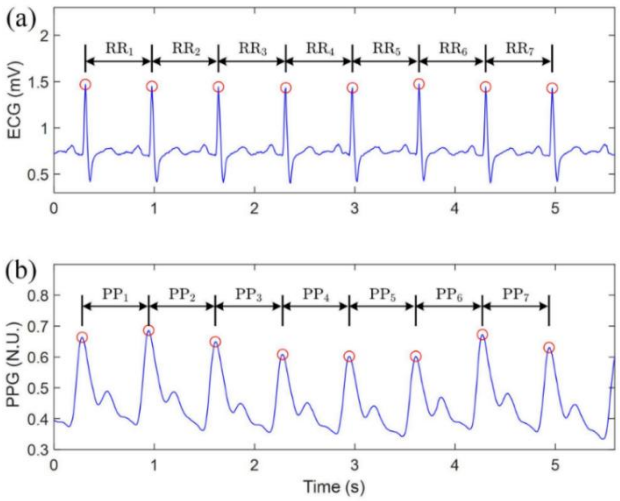
ภาพ 1 สัญญาณคลื่นกิจกรรมไฟฟ้าบนผิวหนัง *(NeuroKit, 2024)* ภาพนี้แสดงสัญญาณ EDA ดิบและที่ถูกกรองแล้ว

2) สัญญาณความแปรปรวนของอัตราการเต้นของหัวใจ HRV (Heart Rate Variability)

สัญญาณ HRV คือการวัดความแปรผันของช่วงเวลาระหว่างการเต้นของหัวใจแต่ละครั้ง (R-R intervals) ซึ่งแสดงถึงการทำงานของระบบประสาทอัตโนมัติ (ANS) (Ding และคณะ, 2024) โดย HRV มีความสัมพันธ์กับการทำงานของทั้งระบบประสาทซิมพาเทติกและพาราซิมพาเทติก (PNS) การวิเคราะห์ HRV สามารถแบ่งออกเป็นสองประเภทใหญ่ๆ คือ:

1. การวิเคราะห์ในเชิงเวลา (Time-Domain Analysis) เป็นการวิเคราะห์ความแปรผันของสัญญาณ HRV ในเชิงเวลา เช่น การคำนวณค่าเฉลี่ยของช่วง R-R interval (avgRR) หรือการคำนวณรากที่สองของค่าเฉลี่ยของผลต่างของ R-R interval (RMSSD) ซึ่งใช้เป็นตัวชี้วัดความสามารถของระบบพาราซิมพาเทติกในการควบคุมการทำงานของหัวใจ
2. การวิเคราะห์ในเชิงความถี่ (Frequency-Domain Analysis) เป็นการวิเคราะห์การกระจายตัวของพลังงานในสัญญาณ HRV ตามช่วงความถี่ต่างๆ เช่น:
   - Low Frequency (LF) เป็นตัวบ่งชี้การทำงานของระบบพาราซิมพาเทติกและซิมพาเทติก
   - High Frequency (HF) เป็นตัวบ่งชี้เฉพาะการทำงานของระบบพาราซิมพาเทติก
   - LF/HF ratio ใช้เป็นตัวชี้วัดความสมดุลระหว่างระบบประสาทซิมพาเทติกและพาราซิมพาเทติก

ความสัมพันธ์ระหว่าง EDA และ HRV ทั้งสัญญาณ EDA และ HRV สามารถใช้ร่วมกันในการวิเคราะห์ความเครียดได้อย่างมีประสิทธิภาพ (Haque และคณะ, 2024) โดยสัญญาณ EDA ใช้เพื่อบ่งชี้ถึงการตอบสนองของระบบประสาทซิมพาเทติกในระยะสั้น ขณะที่สัญญาณ HRV ใช้ในการวิเคราะห์การควบคุมระบบประสาททั้งสองด้านในระยะยาว การวิเคราะห์ร่วมกันจะช่วยให้สามารถประเมินการตอบสนองของร่างกายต่อความเครียดได้อย่างครบถ้วนและชัดเจน



ภาพ 2 สัญญาณความแปรปรวนของอัตราการเต้นของหัวใจ HRV *(Lu และคณะ, 2023)* ภาพแสดงการคำนวณค่า HRV จากสัญญาณ ECG และ PPG (a) ช่วง RR ในสัญญาณ ECG, และ (b) ช่วง PP ในสัญญาณ PPG. N.U.: หน่วยที่ถูกปรับให้เป็นปกติ (Normalized units)

จาก**ภาพที่ 2** จากภาพด้านบนแสดงกระบวนการวิเคราะห์ค่า HRV (Heart Rate Variability) ผ่านการวัดด้วยสองวิธี โดยภาพ (a) แสดงสัญญาณ ECG (Electrocardiogram) ซึ่งเป็นการตรวจวัดกิจกรรมทางไฟฟ้าของหัวใจโดยตรง โดยสามารถสังเกตคลื่น R ที่มีลักษณะเด่นชัด (peak amplitude) ซึ่งใช้ในการคำนวณระยะเวลาระหว่างการเต้นของหัวใจที่เรียกว่า RR intervals การวัดด้วยวิธีนี้ให้ความแม่นยำสูงเนื่องจากเป็นการวัดสัญญาณไฟฟ้าจากหัวใจโดยตรง อย่างไรก็ตามจำเป็นต้องใช้อุปกรณ์เฉพาะทางการแพทย์และต้องมีการติดตั้งขั้วไฟฟ้าที่ผิวหนังของผู้ถูกตรวจวัด

ภาพ (b) แสดงสัญญาณ PPG (Photoplethysmogram) ซึ่งเป็นการวัดการเปลี่ยนแปลงปริมาณเลือดในหลอดเลือดที่ผิวหนังด้วยเทคนิคทางแสง โดยใช้จุดสูงสุดของคลื่น P ในการคำนวณระยะเวลาที่เรียกว่า PP intervals แม้ว่าการวัดด้วยวิธีนี้จะมีความแม่นยำน้อยกว่า ECG แต่ได้รับความนิยมในการใช้งานเนื่องจากไม่จำเป็นต้องใช้อุปกรณ์ที่ซับซ้อน สามารถทำการวัดได้ผ่านอุปกรณ์สวมใส่อัจฉริยะ (wearable devices) มีต้นทุนต่ำและเหมาะสมสำหรับการติดตามสุขภาพในชีวิตประจำวัน

ดังนั้น การเลือกใช้ PPG สำหรับการวัด HRV จึงมีเหตุผลสำคัญคือ ความสะดวกในการใช้งาน ต้นทุนที่ต่ำกว่า ความง่ายในการเข้าถึงเทคโนโลยี และความเหมาะสมสำหรับการติดตามสุขภาพในระยะยาว แม้จะมีความแม่นยำน้อยกว่า ECG แต่ด้วยข้อได้เปรียบเหล่านี้ทำให้ PPG เป็นทางเลือกที่เหมาะสมสำหรับการใช้งานในชีวิตประจำวัน

2.1.3 Signal Processing

การประมวลผลสัญญาณ (Signal Processing) อ้างอิงจากทฤษฎีพื้นฐานในด้านการจัดการและวิเคราะห์ข้อมูลสัญญาณทางสรีรวิทยา เช่น ECG, PPG และ EDA เพื่อเพิ่มคุณภาพและความแม่นยำในการวิเคราะห์ ขั้นตอนแรกคือ การปรับค่าฐาน (Baseline Adjustment) ซึ่งใช้หลักการของ convex optimization เพื่อลด drift และความเบี่ยงเบนของค่าฐานที่เกิดจาก noise หรือปัจจัยภายนอก โดยการแก้ปัญหาสมการนูนช่วยให้ค่าพื้นฐานมีความสมดุลมากขึ้น สำหรับ การลดสัญญาณรบกวน (Denoising) ทฤษฎีการออกแบบฟิลเตอร์ เช่น Butterworth Filter ถูกนำมาใช้เพื่อลดผลกระทบของความถี่ต่ำและความถี่สูงที่ไม่เกี่ยวข้องกับข้อมูลหลัก ทำให้ได้สัญญาณที่ชัดเจนและเหมาะสมกับการใช้งาน ทฤษฎี deconvolution ถูกนำมาใช้ในการแยกส่วนประกอบของสัญญาณ เช่น tonic component และ phasic component ใน EDA โดยการแก้ปัญหา inverse problem เพื่อแยกองค์ประกอบที่ซ้อนกันได้อย่างแม่นยำ สำหรับการวิเคราะห์ในโดเมนความถี่ (Frequency Domain) ทฤษฎีของ Fourier Transform ถูกใช้ในการแปลงข้อมูลจากโดเมนเวลาเป็นความถี่ ซึ่งช่วยประเมินพลังงานในย่านความถี่ต่ำ (Low Frequency: LF) และย่านความถี่สูง (High Frequency: HF) ที่เกี่ยวข้องกับการทำงานของระบบประสาทอัตโนมัติ สุดท้าย ทฤษฎีการตรวจจับค่าผิดปกติ (Outlier Detection) และการประมาณค่า (Interpolation) ถูกนำมาใช้ในการจัดการสิ่งรบกวน (Artifacts) เพื่อเพิ่มความน่าเชื่อถือของข้อมูล การประยุกต์ใช้ทฤษฎีเหล่านี้ทำให้กระบวนการประมวลผลสัญญาณมีประสิทธิภาพและเหมาะสมสำหรับการวิเคราะห์ในงาน

1. การเตรียมสัญญาณก่อนการประมวลผล (Signal Preprocessing)
    - ขั้นตอนการเตรียมสัญญาณชีวภาพเป็นกระบวนการสำคัญในการทำความสะอาดข้อมูลจากสัญญาณรบกวน (noise) และอาร์ติแฟกต์ (artifacts) เพื่อให้ข้อมูลที่ได้มีคุณภาพดีเพียงพอสำหรับการวิเคราะห์ต่อไป
    - การยกเลิกอาร์ติแฟกต์ยังเป็นส่วนหนึ่งของการปรับปรุงคุณภาพของสัญญาณ
2. การวิเคราะห์สัญญาณเชิงเวลาและความถี่
    - การวิเคราะห์สัญญาณชีวภาพสามารถทำได้ในหลายรูปแบบ เช่น การวิเคราะห์ในโดเมนเวลา (time-domain) โดเมนความถี่ (frequency domain) และการวิเคราะห์แบบเวลาความถี่ (time frequency analysis)

- เทคนิคการแปลงเชิงฟูเรีย (Fourier transform) และเทคนิคการแปลงเวฟเลต (wavelet transform) ถูกใช้ในการศึกษาและวิเคราะห์คุณลักษณะของสัญญาณที่เปลี่ยนแปลงตามเวลา

3. การสกัดคุณลักษณะสัญญาณ (Feature Extraction)
   - การตรวจจับจุดยอด (Peaks) ในสัญญาณ PPG เพื่อคำนวณอัตราการเต้นของหัวใจ (Heart Rate)
   - การวิเคราะห์ tonic และ phasic components ในสัญญาณ EDA เพื่อระบุการตอบสนองของระบบประสาทอัตโนมัติ
   - การใช้การวิเคราะห์แบบช่วงสั้นๆ หรือการแบ่งกลุ่มช่วงเวลา เพื่อค้นหาลักษณะเฉพาะที่เกี่ยวข้องกับสภาวะสุขภาพ

2.1.4 Algorithm ML

1. Artificial Neural Networks (ANN)

เป็นหนึ่งในอัลกอริทึมการเรียนรู้ของเครื่องที่ใช้กันอย่างแพร่หลายมากที่สุด ดังที่ชื่อบอกไว้ มันเลียนแบบโครงข่ายประสาทในระบบชีววิทยาโดยใช้คอมพิวเตอร์ โมเดลที่ซับซ้อนมากขึ้นมักต้องการพารามิเตอร์จำนวนมาก ซึ่งอาจทำให้การจำแนกข้อมูลใหม่ช้าลงเมื่อเปรียบเทียบกับวิธีการที่ง่ายกว่า

ANNs ทำงานโดยการฝึกชุดพารามิเตอร์ด้วยข้อมูล พารามิเตอร์เหล่านี้จะถูกใช้เพื่อกำหนดผลลัพธ์ของโมเดล ซึ่งอาจเป็นข้อมูลนำเข้าหรือการกระทำ เช่น หากเรามีโมเดลที่ทำนายว่าบุคคลจะซื้อรถหรือไม่ โดยใช้ข้อมูลการซื้อในอดีตและข้อมูลประชากร เราสามารถป้อนข้อมูลใหม่ให้โมเดลเพื่อทำนายผลลัพธ์ต่อไปได้ เราสามารถใช้ตัวแปรหลายตัว เช่น อายุ สถานภาพสมรส รายได้ และอื่น ๆ เพื่อช่วยในกระบวนการทำนาย

โหนด (Nodes) ในโครงข่ายประสาทจะเชื่อมต่อกันด้วยลิงก์ที่มีน้ำหนัก (Weighted Links) โดยน้ำหนักนี้บ่งบอกถึงความเกี่ยวข้องกับผลลัพธ์ ซึ่งค้นพบได้ผ่านกระบวนการลดข้อผิดพลาดที่เรียกว่าการถ่ายทอดย้อนกลับ (Backpropagation) แต่ละเลเยอร์ในโครงข่ายและนิวรอนที่เกี่ยวข้องมักจะสอดคล้องกับคุณสมบัติหรือแอตทริบิวต์บางอย่าง

รูปแบบที่ง่ายที่สุดของโครงข่ายประสาทเทียมคือ Perceptron แต่ในปัจจุบัน เราใช้โครงข่ายประสาทลึก (Deep Neural Networks) สำหรับปัญหาที่ซับซ้อนมากขึ้น เช่น การจัดหมวดหมู่ภาพ ซึ่งมีข้อมูลนำเข้าที่เป็นไปได้จำนวนมาก (เช่น สภาพถนนที่แตกต่างกันสำหรับรถยนต์ขับเคลื่อนอัตโนมัติ)

เป้าหมายสุดท้ายของการฝึกอบรมคือการปรับแต่งพารามิเตอร์ (Weights) สำหรับแต่ละโหนดให้เหมาะสมที่สุดกับข้อมูลที่เห็น เมื่อโหนดทั้งหมดได้รับการฝึกแล้ว ควรสามารถตัดสินใจได้โดยอิงจากพารามิเตอร์เหล่านั้น โดยมีสูตรการคำนวณดังนี้

$$z = \sum_{i=1}^{n} w_i x_i + b$$

z	ค่าผลรวมของน้ำหนัก
w_i	น้ำหนักของฟีเจอร์ i
x	ค่าอินพุตของฟีเจอร์ i
b	ค่า Bias

2. Recurrent Neural Network (RNN)

เป็นสถาปัตยกรรมของโครงข่ายประสาทเทียมที่ถูกออกแบบมาเพื่อจัดการกับข้อมูลลำดับ (Sequential Data) เช่น ข้อมูลเวลา (Time-series), ข้อความ (Text), หรือสัญญาณชีวภาพ (Bio signals) โดยแตกต่างจากโครงข่ายประสาทเทียมทั่วไป (Feedforward Neural Network) ตรงที่ RNN มีการส่งข้อมูลย้อนกลับ (Recurrent Connection) ซึ่งทำให้สามารถจดจำสถานะในอดีต (previous states) เพื่อส่งผลต่อการคำนวณในขั้นถัดไป ในเชิงคณิตศาสตร์ การคำนวณใน RNN ที่เวลาขั้นที่ t สามารถเขียนได้เป็น:

$$\mathrm{h_t} = \sigma(\mathrm{W_{xh}x_t} + \mathrm{W_{hh}h_{t-1}} + \mathrm{b_h})$$

$$\mathrm{y_t} = \mathrm{W_{hy}h_t} + \mathrm{b_y}$$

x_t	อินพุตในลำดับที่ *t*
$\mathrm{h_t}$	สถานะแฝง (*hidden state)* ที่เวลาที่ *t*
$\mathrm{y_t}$	เอาต์พุตของโมเดล
W และ b	น้ำหนักและไบแอสที่เรียนรู้ได้จากข้อมูล
σ	ฟังก์ชันกระตุ้น (activation function) เช่น tanh หรือ ReLU

3. Long Short-Term Memory (LSTM)

LSTM เป็นหนึ่งในประเภทของ Recurrent Neural Networks (RNNs) ซึ่งออกแบบมาเพื่อจัดการกับข้อมูลลำดับ (Sequential Data) เช่น ข้อความ เวลา หรือข้อมูลต่อเนื่องทางเวลา โดยแก้ปัญหาข้อจำกัดของ RNN แบบเดิมที่ไม่สามารถจดจำข้อมูลระยะยาวได้ดี เนื่องจากปัญหา Vanishing Gradient LSTM ใช้กลไกพิเศษที่เรียกว่า Memory Cells และ Gates (เช่น Forget Gate, Input Gate, และ Output Gate) เพื่อควบคุมการเก็บและลืมข้อมูลในหน่วยความจำ ทำให้สามารถวิเคราะห์ข้อมูลที่มีความสัมพันธ์ในระยะยาวได้อย่างมีประสิทธิภาพ

LSTM ทำงานโดยการฝึกพารามิเตอร์ของโมเดลจากข้อมูลเชิงลำดับ เช่น หากเราต้องการทำนายราคาหุ้นในอนาคตโดยใช้ข้อมูลในอดีต LSTM จะพิจารณาลำดับของข้อมูล เช่น วัน ราคาเปิด และปริมาณการซื้อขาย โมเดลสามารถเรียนรู้ความสัมพันธ์เชิงเวลาในข้อมูลเหล่านี้เพื่อช่วยในการทำนายโครงสร้างของ LSTM ประกอบด้วยหน่วยพื้นฐานที่เรียกว่า Cells ซึ่งแต่ละ Cell มี 3 ประตูหลัก:

- Forget Gate ใช้ตัดสินใจว่าจะลืมข้อมูลบางส่วนจากหน่วยความจำเดิมหรือไม่ โดยมีการใช้ค่าผลรวมของน้ำหนักและ bias ร่วมกับฟังก์ชัน sigmoid
- Input Gate ตัดสินใจว่าจะเพิ่มข้อมูลใหม่เข้าไปในหน่วยความจำหรือไม่ โดยใช้ค่าจากอินพุตปัจจุบันและน้ำหนักร่วมกับฟังก์ชัน sigmoid
- Output Gate ควบคุมข้อมูลที่จะส่งออกจากหน่วยความจำไปยังขั้นตอนถัดไป

ในแต่ละรอบการทำงาน (Time Step) ของ LSTM น้ำหนัก (Weights) และค่า bias จะถูกปรับปรุงผ่านกระบวนการ Backpropagation Through Time (BPTT) ซึ่งเป็นการลดข้อผิดพลาดจากค่าผลลัพธ์ที่โมเดลคาดการณ์ เทียบกับค่าจริง (Ground Truth) โดยใช้ Gradient Descent โดยมีสูตรการคำนวณดังนี้

3.1 Forget Gate

ใช้เพื่อตัดสินใจว่าจะลืมข้อมูลบางส่วนในสถานะหน่วยความจำก่อนหน้า (c_{t-1}) หรือไม่

$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] + b_f\right)$$

$\mathrm{f_t}$	ค่าเอาต์พุตของ Forget Gate
σ	ฟังก์ชัน Sigmoid
W_f	น้ำหนักที่ใช้ใน Forget Gate
h_{t-1}	เอาต์พุตจากขั้นตอนเวลาก่อนหน้า
x_t	อินพุตในขั้นตอนปัจจุบัน
b_f	ค่า bias ของ Forget Gate

3.2 Input Gate

ใช้เพื่อตัดสินใจว่าจะเพิ่มข้อมูลใหม่เข้าสู่สถานะหน่วยความจำหรือไม่

$$i_t = \sigma\big(W_f \cdot [h_{t-1}, x_t] + b_f\big)$$
$$\tilde{C}_t = tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$
$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t$$

$\mathrm{i_t}$	ค่าเอาต์พุตของ Input Gate
$\tilde{C}_t$	สถานะหน่วยความจำใหม่
C_t	สถานะหน่วยความจำที่อัปเดต
$tanh$	ฟังก์ชัน Hyperbolic Tangent
W_i, W_c	น้ำหนักที่ใช้ใน Input Gate และ Cell State
b_i, b_c	ค่า bias ของ Input Gate และ Cell State

3.3 Output Gate

ใช้เพื่อตัดสินใจว่าจะส่งข้อมูลจากสถานะหน่วยความจำออกเป็นเอาต์พุตหรือไม่

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$
$$h_t = o_t \cdot \tanh(C_t)$$

$\mathrm{o_t}$	ค่าเอาต์พุตของ Output Gate
h_t	เอาต์พุตสุดท้ายของ LSTM ในขั้นตอนปัจจุบัน
W_o	น้ำหนักที่ใช้ใน Output Gate

b_o ค่า bias ของ Output Gate

4. Gated Recurrent Unit (GRU)

เป็นสถาปัตยกรรมของโครงข่ายประสาทเทียมเชิงลำดับ (Recurrent Neural Network: RNN) ที่ได้รับการพัฒนาเพื่อแก้ปัญหาการจดจำบริบทระยะยาว ซึ่งเป็นข้อจำกัดสำคัญของ RNN แบบดั้งเดิม โดย GRU ถูกเสนอโดย Cho et al. ในปี 2014 โดยมีโครงสร้างภายในที่ใช้กลไก gate เพื่อควบคุมการไหลของข้อมูล ทำให้สามารถเรียนรู้ข้อมูลลำดับยาวได้มีประสิทธิภาพมากขึ้น

โดยจะใช้สอง gate หลัก ได้แก่ **Update Gate** และ **Reset Gate** เพื่อควบคุมข้อมูลที่ ในแต่ละช่วงเวลา

1. **Update Gate** (z_t) กำหนดว่าค่าของ hidden state เดิมจะยังคงอยู่มากน้อยเพียงใด
2. **Reset Gate** (r_t) ควบคุมว่าค่าของ hidden state เดิมควรถูกลืมแค่ไหนในการคำนวณสถานะใหม่

โดยกระบวนการคำนวณภายในสามารถเขียนเป็นสมการได้ดังนี้:

$$z_t = \sigma(W_z x_t + U_z h_{t-1})$$

$$r_t = \sigma(W_r x_t + U_r h_{t-1})$$

$$\tilde{h}_t = \tanh(W_h x_t + U_h(r_t \odot h_{t-1}))$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$

x_t อินพุตในลำดับที่ t

h_{t-1} hidden state จากลำดับก่อนหน้า

h_t hidden state ปัจจุบัน

σ sigmoid function

$\odot$ การคูณเชิงจุด (element-wise multiplication)

2.2 งานวิจัยหรือระบบที่ใกล้เคียง

2.2.1 Stress Detection in Seniors Using Biosensors and Psychometric Tests

Goumopoulos และ Menti (Goumopoulos & Menti, 2019) ได้นำเสนอการตรวจจับความเครียดในผู้สูงอายุผ่านการใช้เซ็นเซอร์และแบบสอบถามทางจิตวิทยา โดยใช้ข้อมูลจาก EDA และ HRV ซึ่งมีจุดเด่น คือ การใช้ทั้งข้อมูลสัญญาณทางสรีรวิทยา EDA, HRV และข้อมูลจากแบบสอบถามทางจิตวิทยา ทำให้การประเมินความเครียดมีความครอบคลุมมากขึ้น

ผลงานวิจัยพบว่า EDA และ HRVสามารถเป็นตัวชี้วัดความเครียดที่แม่นยำในผู้สูงอายุ แต่ทว่างานวิจัยดังกล่าวยังไม่มีการใช้เทคโนโลยีเพื่อแจ้งเตือนเมื่อเกิดความเครียดในชีวิตประจำวัน อีกทั้งการใช้งานยังคงอยู่ในระดับการทดลองและไม่ได้ออกแบบเพื่อการใช้งานจริงในชีวิตประจำวัน

2.2.2 Exploring physiological stress response evoked by passive translational acceleration in healthy adults: a pilot study utilizing electrodermal activity and heart rate variability measurements

Yu และคณะ (Yu และคณะ, 2024) ได้นำเสนอการศึกษาผลกระทบของการเคลื่อนที่ (เช่น การขึ้น-ลงลิฟต์) ต่อการตอบสนองทางสรีรวิทยา โดยใช้ EDA และ HRV เพื่อวิเคราะห์ความเครียดในผู้ใหญ่ที่มีสุขภาพดี ซึ่งมีจุดเด่น คือ การใช้วิธีการทดลองแบบ Passive Translational Acceleration (PTA) เพื่อวิเคราะห์การเปลี่ยนแปลงสัญญาณทางสรีรวิทยา

ผลงานวิจัยพบว่า ผสมผสานการใช้EDA และHRV ซึ่งเป็นมาตรวัดในทางสรีรวิทยาช่วยให้การวิเคราะห์ผลกระทบจากการเร่งความเร็วแบบเฉื่อย (PTA) ครอบคลุมมากขึ้นและให้ข้อมูลที่ละเอียดขึ้น แต่ทว่างานวิจัยนี้มีข้อจำกัด คือ การวิเคราะห์ข้อมูลไม่ได้ใช้เทคโนโลยีปัญญาประดิษฐ์เพื่อช่วยในการทำนายความเครียด ทำให้เกิดความซับซ้อนในการวิเคราะห์ผล

2.2.3 Integrated mental stress smartwatch based on sweat cortisol and HRV sensors

Ding และคณะ (Ding และคณะ, 2024) ได้นำเสนอการพัฒนาสมาร์ทวอทช์ที่มีการรวมเซ็นเซอร์ตรวจวัดคอร์ติซอลในเหงื่อและความแปรปรวนของอัตราการเต้นของหัวใจ (HRV) เพื่อติดตามความเครียดทางจิตใจแบบเรียลไทม์โดยไม่รุกล้ำ อุปกรณ์นี้สามารถบันทึกระดับคอร์ติซอลในเหงื่อและค่าดัชนี HRV พร้อมกันได้อย่างต่อเนื่อง ซึ่งมีการใช้สมาร์ทวอทช์ที่พัฒนาสามารถใช้งานจริงในชีวิตประจำวันเพื่อการติดตามและจัดการความเครียดของ

ผู้ใช้งานได้ และมีการรวมเซ็นเซอร์คอร์ติซอลในเหงื่อเข้ากับ HRV ทำให้สามารถวัดความเครียดได้ทั้งจากสัญญาณฮอร์โมนและระบบประสาทอัตโนมัติ

ผลงานวิจัยพบว่างานวิจัยนี้ผสานข้อมูลทางสรีรวิทยาและชีวเคมีด้วยการใช้สมาร์ทวอทช์ในการวัดระดับคอร์ติซอลในเหงื่อ และความแปรปรวนของอัตราการเต้นของหัวใจ (HRV) ซึ่งเป็นการรวมข้อมูลสองส่วนที่สำคัญเพื่อให้ได้การประเมินความเครียด ซึ่งสามารถใช้ในการวิเคราะห์ความเครียดที่เกิดขึ้นได้ ข้อจำกัดของงานวิจัยนี้ คือ การวิเคราะห์ข้อมูลไม่ได้ใช้เทคโนโลยีปัญญาประดิษฐ์ในการวิเคราะห์ ซึ่งการใช้เทคโนโลยีปัญญาประดิษฐ์ อาจช่วยเพิ่มความแม่นยำในการทำนายและวิเคราะห์ความเครียด อุปกรณ์สวมใส่ที่มีอยู่ในปัจจุบันยังไม่สามารถตรวจวัดสัญญาณความเครียดได้อย่างต่อเนื่องและสอดคล้องกับการใช้งานจริง

2.2.4 State-of-the-Art of Stress Prediction from Heart Rate Variability Using Artificial Intelligence

Haque และคณะ (Haque และคณะ, 2024) ได้นำเสนอการใช้เทคโนโลยีปัญญาประดิษฐ์ (AI) ในการทำนายความเครียดจากข้อมูล HRV ซึ่งเป็นสัญญาณสำคัญที่สะท้อนถึงการทำงานของระบบประสาทอัตโนมัติ โดยได้ทบทวนและสรุปงานวิจัยต่าง ๆ ที่นำ AI และเทคโนโลยี Machine Learning (ML) มาใช้ในการทำนายความเครียด จุดเด่น คือ มีการใช้เทคโนโลยีปัญญาประดิษฐ์ (AI) เพื่อทำนายความเครียดและมีการประมวลผลข้อมูลแบบเรียลไทม์ ทำนายความเครียดได้อย่างรวดเร็ว

ผลงานวิจัยพบว่า การวิเคราะห์ข้อมูลที่ซับซ้อนและการทำนายความเครียดได้อย่างแม่นยำโดยใช้โมเดลการเรียนรู้เชิงลึก (Deep Learning) และการเรียนรู้ของเครื่อง (Machine Learning)สามารถทำการประมวลผลข้อมูลที่หลากหลายได้ แต่ทว่างานวิจัยนี้เน้นการศึกษาการพัฒนาระบบมากกว่าการใช้งานจริง ดังนั้นการทดลองในสภาพแวดล้อมจริงอาจจำเป็นต้องมีการพัฒนาต่อไปเพื่อให้ AI สามารถประยุกต์ใช้ในสถานการณ์ต่าง ๆ ได้ อีกทั้งยังไม่มีการใช้เทคโนโลยีเพื่อแจ้งเตือนเมื่อเกิดความเครียดในชีวิตประจำวัน

2.2.5 สัญญาณ EDA และการดูแลผู้ป่วยติดเตียง

Ghiasi, Sahoh และคณะ (Ghiasi และคณะ, 2020; Sahoh และคณะ, 2023) ได้นำเสนอการElectrodermal Activity หรือ EDA คือหนึ่งในสัญญาณทางสรีรวิทยา (Physiological Signals) ที่สามารถใช้อุปกรณ์เพื่อตรวจวัดได้ และเนื่องจากสัญญาณดังกล่าวนี้มีความสัมพันธ์กับ การถูกกระตุ้นทางอารมณ์จึงทำให้สามารถใช้สัญญาณ EDA เพื่อบ่งบอกถึงความรู้สึกสบาย หรือไม่สบายได้ โดยนอกจากสัญญาณดังกล่าวแล้ว ยังสามารถนำเอา 16 HRV หรือ Heart Rate Variability ซึ่งเป็นหนึ่งในสัญญาณทางสรีรวิทยาเช่นเดียวกันมาใช้ ร่วมกันในการบอกถึงความรู้สึกสบายหรือไม่สบายเพื่อเพิ่มความแม่นยำได้

ผลการวิจัยพบว่า การนำเทคโนโลยีตรวจวัดสัญญาณ EDA มาใช้จะช่วยให้ผู้ดูแลสามารถเฝ้าดูอาการ ของผู้ป่วยได้โดยไม่รุกล้ำความเป็นส่วนตัวของผู้ป่วย สามารถรับรู้ได้ว่าเมื่อใดที่ผู้ป่วยเริ่มมีอาการ แผลกดทับหรือรู้สึกไม่สบายตัวและสามารถแก้ไขทันท่วงทีได้ก่อนที่อาการจะลุกลาม โดยเฉพาะ อย่างยิ่งในผู้ป่วยติดเตียงกลุ่มสีแดงที่ไม่รู้สึกตัวจึงไม่สามารถแจ้งอาการกับผู้ดูแลได้

2.2.6 การใช้เทคโนโลยีการเรียนรู้ของเครื่องในการติดตามดูแลผู้ป่วยติดเตียง

Lebedev และคณะ (Lebedev et al., 2020) ได้นำเสนอการใช้สัญญาณทางสรีรวิทยา Electrodermal Activity (EDA) ซึ่งสามารถตรวจวัดได้ด้วยอุปกรณ์เฉพาะ โดย EDA มีความสัมพันธ์กับการถูกกระตุ้นทางอารมณ์และสามารถใช้บ่งบอกความรู้สึกสบายหรือไม่สบายของผู้ป่วยได้ นอกจากนี้ยังมีการผสานข้อมูลจาก Heart Rate Variability (HRV) เพื่อเพิ่มความแม่นยำในการประเมินความรู้สึกของผู้ป่วยติดเตียง แนวทางนี้มีเป้าหมายเพื่อช่วยลดภาระงานของบุคลากรทางการแพทย์ที่ขาดแคลนและแก้ปัญหาการเกิดแผลกดทับในผู้ป่วยที่ต้องนอนในท่าเดิมเป็นเวลานาน โดยเฉพาะในกลุ่มผู้ป่วยที่ไม่รู้สึกตัวซึ่งไม่สามารถแจ้งอาการได้

ผลการวิจัยพบว่าการนำ EDA และ HRV มาใช้สามารถช่วยให้ผู้ดูแลรับรู้อาการไม่สบายตัวหรือสัญญาณเริ่มต้นของแผลกดทับได้โดยไม่รุกล้ำความเป็นส่วนตัวของผู้ป่วย และสามารถแก้ไขปัญหาได้อย่างทันท่วงทีก่อนที่อาการจะลุกลาม อย่างไรก็ตาม ระบบยังมีข้อจำกัด เช่น ความแม่นยำที่ขึ้นอยู่กับการตั้งค่าและการรวมข้อมูลจากสัญญาณ รวมถึงข้อจำกัดด้านต้นทุนและความพร้อมใช้งานของอุปกรณ์ ซึ่งอาจเป็นอุปสรรคต่อการนำไปใช้ในวงกว้างในบริบทจริง

จากงานวิจัยข้างต้นสามารถนำเสนอผ่านตารางการเปรียบเทียบงานวิจัยได้ดังตารางที่ 4

ตาราง 4 การเปรียบเทียบงานวิจัยและนวัตกรรมที่เกี่ยวข้อง

การเปรียบเทียบ	**นวัตกรรมที่นำเสนอ**	(Goumopoulos & Menti, 2019)	(Yu และคณะ, 2024)	(Ding และคณะ, 2024)	(Haque และคณะ, 2024)	(Ghiasi และคณะ, 2020)	(Sahoh และคณะ, 2023)	(Lebedev และคณะ, 2020)
ให้คำแนะนำเบื้องต้น	/	×	×	×	/	x	×	x
ใช้	/	/	×	×	/	x	/	/

การเปรียบเทียบ	นวัตกรรมที่นำเสนอ	(Goumopoulos & Menti, 2019)	(Yu และคณะ, 2024)	(Ding และคณะ, 2024)	(Haque และคณะ, 2024)	(Ghiasi และคณะ, 2020)	(Sahoh และคณะ, 2023)	(Lebedev และคณะ, 2020)
ปัญญาประดิษฐ์ในการตรวจจับ								
การแจ้งเตือนอัตโนมัติ	/	×	×	/	×	x	/	/
รายงานสรุปแนวโน้มความเครียด	/	×	×	/	/	x	×	x
ลักษณะการใช้งาน	อุปกรณ์สวมใส่ติดตั้งบริเวณข้อมือ	ติดตั้งบริเวณนิ้วมือ	ติดตั้งตามจุดของร่างกาย	อุปกรณ์สวมใส่ติดตั้งบริเวณข้อมือ (สมาร์ทวอทช์)	-	การพัฒนาระบบความสบายทางความร้อนส่วนบุคคล	ติดตั้งอุปกรณ์สวม ใส่ติดตัว	การติดตามลักษณะท่านอน

2.3.1 An Analysis of Physiological and Psychological Responses in Virtual Reality and Flat Screen Gaming

Vatsal และคณะ (2023) ได้นำเสนอการวิเคราะห์เชิงเปรียบเทียบระหว่างการเล่นเกมในสภาพแวดล้อม Virtual Reality (VR) และ Flat Screen (FS) โดยมีวัตถุประสงค์เพื่อศึกษาปฏิกิริยาทางสรีรวิทยาและจิตวิทยาที่แตกต่างกันเมื่อผู้เล่นเผชิญกับประสบการณ์เกมที่มีความสมจริงไม่เท่ากัน งานวิจัยนี้ใช้เกมเชิงพาณิชย์ที่คัดเลือกจาก valence-arousal space เพื่อให้ได้

อารมณ์ที่หลากหลาย และให้อาสาสมัครจำนวน 33 คนเข้าร่วมการทดลอง การวัดประกอบด้วยสัญญาณทางสรีรวิทยา ได้แก่ Blood Volume Pulse (BVP) และ Electrodermal Activity (EDA) ร่วมกับการประเมินเชิงจิตวิทยาแบบ self-report (SAM, VAS) หลังการเล่นเกม ผลการวิจัยพบว่า การเล่นเกมใน VR ก่อให้เกิด ระดับ arousal และความเครียดสูงกว่า การเล่นใน FS อย่างมีนัยสำคัญ นอกจากนี้ยังพบว่าใน VR ผู้เล่นมี cognitive load สูงขึ้น และรู้สึกควบคุมสถานการณ์ได้น้อยกว่า (lower dominance) เมื่อเทียบกับ FS จุดเด่นของงานวิจัยนี้ คือ การจัดทำ VRFS dataset ที่รวบรวมข้อมูล multimodal (สัญญาณทางสรีรวิทยาและ self-report) มากกว่า 15 ชั่วโมง เพื่อใช้ในการศึกษาต่อไป ถือเป็น dataset แรกที่เปรียบเทียบอย่างเป็นระบบระหว่าง VR และ FS ในเกมหลากหลายประเภท ซึ่งมีประโยชน์อย่างมากต่อการพัฒนาโมเดลประเมินอารมณ์และความเครียดในอนาคต

2.3.2 Stress as an influence on serious gaming experience

Ooms (2018) ได้ทำการศึกษาโดยใช้ serious game ที่ออกแบบมาให้ผู้เล่นต้องตัดสินใจภายใต้แรงกดดันของเวลา (time-pressure decision making) เพื่อทดสอบระดับความเครียด งานวิจัยนี้ใช้วิธีการผสมผสาน ได้แก่ ข้อมูลจาก sensor ทางสรีรวิทยา (เช่น HR, EDA), in-game logs และ แบบสอบถามหลังเล่น ผลการศึกษาพบว่า ข้อมูลจาก sensor และ in-game logs มีประสิทธิภาพในการสะท้อนระดับความเครียดมากกว่าแบบสอบถามเพียงอย่างเดียว จุดเด่นของงานนี้คือการใช้ ข้อมูลหลายแหล่ง (multimodal) ทำให้สามารถประเมินภาวะความเครียดได้ครอบคลุมและแม่นยำยิ่งขึ้น อย่างไรก็ตาม งานยังมีข้อจำกัดในด้านการประเมินเฉพาะในกลุ่มตัวอย่างเล็ก และยังไม่ได้ทดสอบในบริบทการใช้งานจริงนอกห้องทดลอง

2.3.3 The Beneficial or Harmful Effects of Computer Game Stress on Cognitive Functions of Players

Aliyari และคณะ (2018) ได้ทำการศึกษาผลของเกมประเภทต่าง ๆ ต่อระดับความเครียด โดยเลือกเกม 4 ประเภท ได้แก่ Runner, Fear, Excitement และ Puzzle เพื่อให้อาสาสมัครเล่นในสภาพแวดล้อมที่ควบคุมได้ งานวิจัยนี้ใช้การวัด ฮอร์โมน cortisol และ α-amylase จาก

น้ำลาย รวมถึงการตรวจคลื่นสมอง (EEG) เพื่อประเมินระดับความเครียดที่เกิดขึ้น ผลการทดลองพบว่า เกม Fear, Runner และ Excitement ทำให้ระดับความเครียดเพิ่มขึ้น ในขณะที่ เกม Puzzle ช่วยลดระดับความเครียด จุดเด่นของงานนี้คือการใช้ การวัดทางสรีรวิทยาร่วมกับ EEG เพื่อยืนยันผลลัพธ์เชิงวัตถุและเชิงจิตวิทยา อย่างไรก็ตาม งานนี้เน้นไปที่การเปรียบเทียบประเภทเกมมากกว่าการสร้างระบบตรวจจับเชิงอัตโนมัติ ซึ่งอาจต้องต่อยอดในอนาคตเพื่อพัฒนาเครื่องมือวัดความเครียดที่แม่นยำยิ่งขึ้น

2.3 เทคโนโลยีที่ใช้ในการพัฒนา

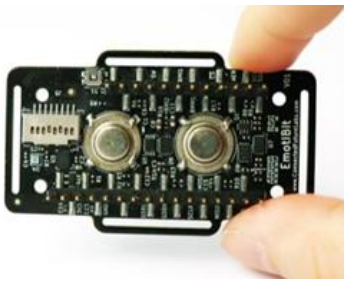
เทคโนโลยีที ใช้ในการศึกษาการตอบสนองทางสัญญาณสรีรวิทยาต่อสภาวะความเครียด โดยอาศัย เทคโนโลยีปัญญาประดิษฐ์และอินเตอร์เน็ตของสรรพสิ่ง มีองค์ประกอบที่สำคัญอยู่ 2 ด้านคือ 1) อุปกรณ์ชุดเซนเซอร์สำหรับวัดสัญญาณทางสรีรวิทยา และ 2) หน่วยประมวลผลขนาดเล็ก (nodeMCU)

2.3.1 อุปกรณ์ชุดเซนเซอร์สำหรับวัดสัญญาณทางสรีรวิทยา

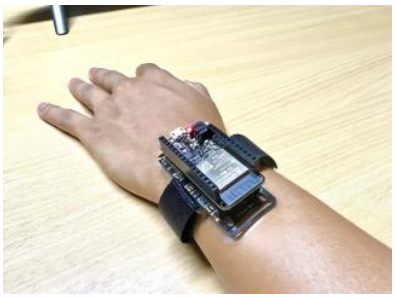
การวัดปัจจัยเชิงสรีระของกลุ่มตัวอย่างการทดลองเมื่อเกิดอารมณ์ผิดปกติจะใช้อุปกรณ์ ชุดเซนเซอร์ที่มีชื่อว่า EmotiBit สำหรับวัดสัญญาณกิจกรรมไฟฟ้าที่ผิวหนัง (Electrodermal Activity : EDA) การเปลี่ยนแปลงของปริมาณเลือดหรือการไหลเวียนเลือดในร่างกายซึ่งเกิดขึ้นกับการเต้นของหัวใจ (Photoplethysmography: PPG) และผิวหนัง (Skin Temperature) คุณสมบัติเป็นไปตาม**ตารางที่ 5** และการติดตั้งเป็นไปตาม**ภาพที่ 3**

ตาราง 5 แสดงคุณลักษณะของอุปกรณ์ชุดเซนเซอร์สำหรับวัดสัญญาณทางสรีรวิทยา

อุปกรณ์	Sensor IC	Function	Sampling Rate
EmotiBit	BMI160+BMI150	Motion	25
	MAX30101	PPG	25
	MAX30101/MLX90632	Temperature	7.5
	ADS1114	EDA	15



(ก) อุปกรณ์ EmotiBit



(ข) ตัวอย่างการติดตั้ง EmotiBit

ภาพ 3 ตัวอย่างอุปกรณ์ชุดเซนเซอร์และการติดตั้ง

2.3.2 หน่วยควบคุมการประมวลผลขนาดเล็ก (MCU node)

หน่วยควบคุมการประมวลผลขนาดเล็ก หรือ MCU node เป็นเทคโนโลยีการประมวลผลขนาดเล็กที่ถูกพัฒนาขึ้นมาสำหรับใช้ในกับเทคโนโลยีอินเทอร์เน็ตของสรรพสิ่ง คุณสมบัติของ MCU node จะประกอบด้วยโมดูลที่รองรับการเชื่อมต่อ Wi-Fi และ Bluetooth 4.2 ภายในตัว MCU node คุณสมบัติที่โดดเด่นอีกอย่างของ MCU node คือ ใช้พลังงานในการประมวลผลต่ำ เหมาะต่อการนำมาประยุกต์ใช้เพื่อพัฒนาอุปกรณ์เคลื่อนที่ นอกจากนี้ยังมีราคา ประหยัดและมีระบบประมวลผลที่รวดเร็ว ซึ่งคุณสมบัติพื้นฐานของ nodeMCU ESP32 จะแสดงดัง**ตารางที่ 6**

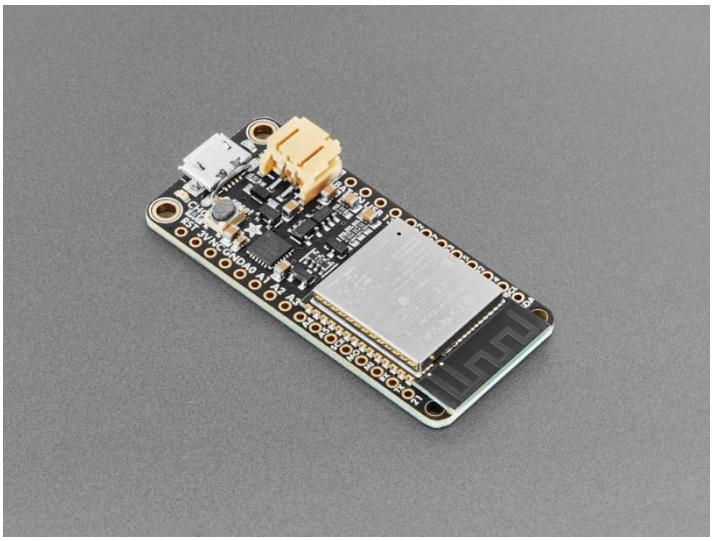
ตาราง 6 คุณสมบัติ ESP32

คุณสมบัติ	รายละเอียด
หน่วยประมวลผล	- Cores: 2 - Clock frequency: up to 240 MHz - Performance: up to 600 DMIPs
กำลังไฟ	- 3.3-5 V.
หน่วยความจำ (memory)	- 320 KiB RAM - 448 KiB ROM
ระบบเครือข่ายไร้สาย (Wireless connectivity)	- Wi-Fi: 802.11 b/g/n - Bluetooth: v4.2 BR/EDR and BRE
การสื่อสาร (Peripheral interfaces)	- 34 × programmable GPIOs - 12-bit SAR ADC up to 18 channels - 2 × 8-bit DACs - 10 × touch sensors - 4 × SPI - 2 × I²S interfaces

คุณสมบัติ	รายละเอียด
	- 2 × I²C interfaces - 3 × UART - SD/SDIO/CE-ATA/MMC/eMMC - SDIO/SPI slave controller - Ethernet MAC - CAN bus 2.0 - Infrared remote controller (TX/RX, up to 8 channels) - Ultra-low-power analog pre-amplifier
ความปลอดภัย (Security)	- IEEE 802.11 - Secure boot - Flash encryption - 1024-bit OTP, up to 768-bit for customers - Cryptographic hardware acceleration
การจัดการพลังงาน (Power management)	- Internal low-dropout regulator - Individual power domain for RTC - 5 μA deep sleep current - Wake up from GPIO interrupt, timer, ADC measurements, capacitive touch sensor interrupt

2.3.3 บอร์ดไมโครคอนโทรลเลอร์ (Adafruit HUZZAH32 – ESP32 Feather Board)

เป็นบอร์ดไมโครคอนโทรลเลอร์ที่พัฒนาโดย Adafruit ซึ่งมีการออกแบบในตระกูล Feather โดยใช้ชิป ESP32 ที่เป็นไมโครคอนโทรลเลอร์แบบ 32 บิต พร้อมการรองรับ Wi-Fi และ Bluetooth LE (Low Energy) ในตัว บอร์ด HUZZAH32 มีขนาดกะทัดรัด มาพร้อมกับพอร์ต USB สำหรับการเชื่อมต่อ และการชาร์จแบตเตอรี่ลิเธียม ที่สามารถเชื่อมต่อได้ บอร์ดนี้มีพินอินพุตและเอาต์พุตดิจิทัล (GPIO) หลายพิน รวมถึงพินแอนะล็อกและการเชื่อมต่อแบบ I2C, SPI และ UART ทำให้เหมาะสำหรับการพัฒนาโครงงานอินเทอร์เน็ตของสรรพสิ่ง (IoT) และแอปพลิเคชันที่ต้องการการเชื่อมต่อไร้สาย



ภาพ 4 บอร์ดไมโครคอนโทรลเลอร์ (Adafruit HUZZAH32 – ESP32 Feather Board)

บทที่ 3
เอกสารความต้องการของระบบ

3.1 ภาพรวมของการวิเคราะห์ระบบ

3.1.1 ขอบเขตงาน

ระบบการตรวจวัดความเครียดประกอบด้วยผู้ใช้งาน 1 กลุ่ม ได้แก่ ผู้ดูแล โดยคำนึงถึงข้อจำกัดด้านการใช้เทคโนโลยี ผู้ดูแลสามารถลงทะเบียนและจัดการข้อมูลผู้ป่วย ดูรายงานและแนวโน้มความเครียด รับการแจ้งเตือนเมื่อผู้ป่วยมีความเครียดในระดับที่กำหนด และรับคำแนะนำการดูแลจากระบบ ระบบประกอบด้วย 4 ส่วนหลัก ได้แก่ 1) ระบบจัดการข้อมูลสมาชิก ที่รองรับการลงทะเบียน พร้อมเชื่อมต่อระบบ OAuth สำหรับความปลอดภัย 2) ระบบจัดการการตรวจวัดความเครียด ที่ให้ผู้ดูแลสามารถดูและค้นหาข้อมูลการตรวจวัดตามช่วงเวลาหรือระดับความเครียด รวมถึงประวัติผู้ป่วย 3) ระบบตรวจวัดและแจ้งเตือนระดับความเครียด ซึ่งใช้เทคโนโลยีการเรียนรู้ของเครื่องในการตรวจวัดความเครียดและแจ้งเตือนผู้ดูแลผ่านช่องทางที่กำหนด 4) ระบบรายงานผล ที่สามารถสร้างรายงานสรุปภาวะความเครียดในรูปแบบไฟล์ รวมถึงส่งออกข้อมูลในรูปแบบ PDF เพื่อการวิเคราะห์เพิ่มเติม ทั้งหมดนี้ออกแบบโดยคำนึงถึงความสะดวกและเหมาะสมต่อการใช้งานของผู้ดูแลทุกกลุ่ม

3.1.2 กลุ่มผู้ใช้ระบบ

โดยกลุ่มผู้ใช้งานคือ ผู้ดูแล ระบบการตรวจวัดความเครียดนี้ออกแบบมาเพื่อให้ผู้ดูแลสามารถลงทะเบียน และจัดการข้อมูลผู้ป่วยในความดูแลได้อย่างมีประสิทธิภาพ ผู้ดูแลสามารถดูรายงานและแนวโน้มความเครียดของผู้ป่วย และรับการแจ้งเตือนเมื่อระบบตรวจพบความเครียดในระดับที่กำหนด นอกจากนี้ ระบบยังให้คำแนะนำในการดูแลและช่วยเหลือผู้ป่วยเมื่อเกิดภาวะเครียด

3.1.3 วิธีการเก็บข้อมูล

1. ตัวแปรที่ใช้ในการศึกษา
    1) สัญญาณทางสรีรวิทยา ได้แก่ EDA (Electrodermal Activity) และ HRV (Heart Rate Variability)
    2) ข้อมูลทางสภาพอากาศ ได้แก่ อุณหภูมิ, ระดับเสียงที่เหมาะสมกับมนุษย์
2. สถานที่ที่ใช้ในการเก็บข้อมูล คือ พื้นที่ภายในอาคารภายในมหาวิทยาลัยวลัยลักษณ์ เช่น ห้องทดสอบ
3. ระยะเวลาในการเก็บข้อมูล คือ เก็บมูลในระยะเวลา 1 ภาคการศึกษา

4. การทดสอบในการเก็บข้อมูล
    1) จำนวนผู้ทดสอบทั้งหมด 25 คน
    2) เป็นทดสอบรายบุคคล โดยใช้ระยะเวลาในการทดสอบ 30 นาที ต่อผู้ทดสอบ 1 คน
    3) การทำแบบทดสอบ
        I. ทำการทดสอบโดยการใช้แบบสอบถามกรมสุขภาพจิตจำนวน 5 ข้อ
        II. ทำแบบสอบถามเกี่ยวกับความเครียด จำนวน 3 ข้อ โดยให้ผู้ทดสอบทำการบันทึกความรู้สึกหลังการทดสอบว่ารู้สึกอย่างไรบ้าง ได้แก่ เครียดเล็กน้อย เครียดปานกลาง เครียดมาก
        III. ทำแบบสอบถามเกี่ยวกับข้อมูลส่วนตัว ได้แก่ ระยะเวลาการนอนหลับ ประเภทของสีผิว น้ำหนัก เพศ

3.2 ความต้องการของระบบ

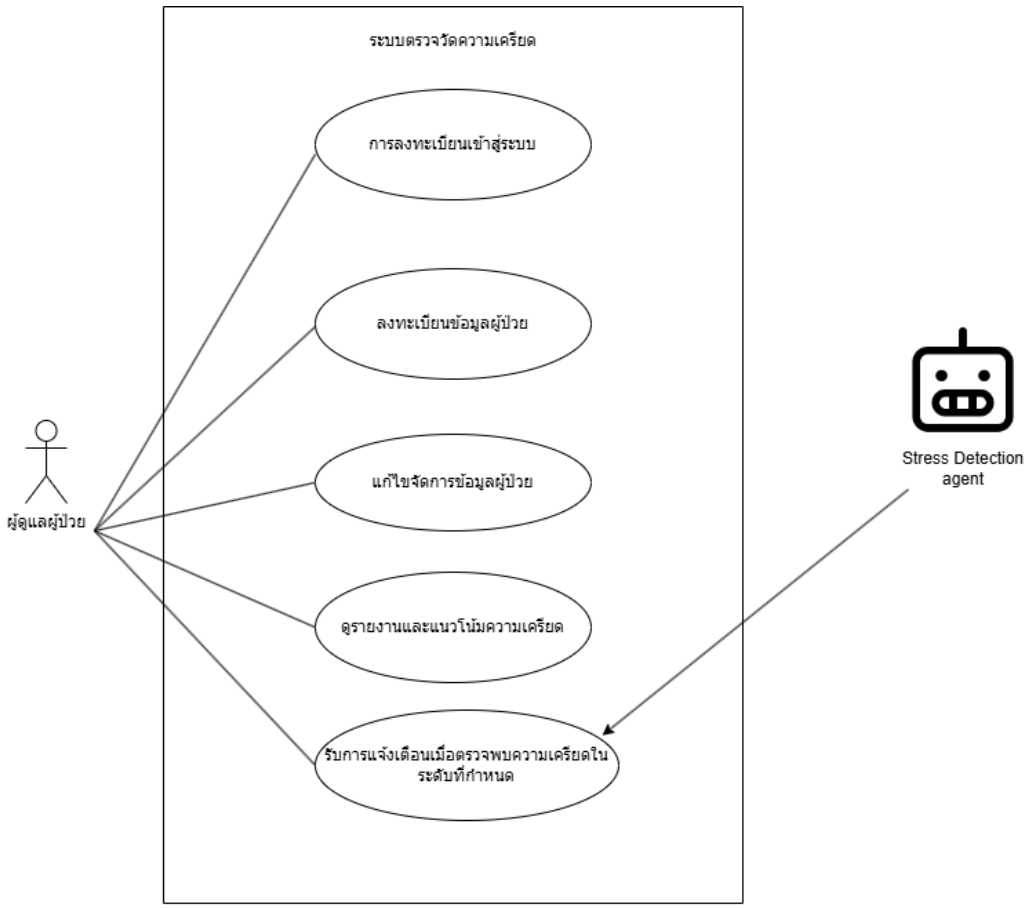
ตาราง 7 ความต้องการของระบบ

ลำดับ	คำอธิบายความต้องการ	ความสำคัญ (M, S, C, W)
Req 01	ผู้ดูแลระบบ สามารถกำหนดชื่อผู้ใช้ (username) และรหัสผ่าน (password) ให้กับผู้ดูแลได้ (UC01)	M
Req 02	ในฐานะผู้ดูแล สามารถเข้าสู่ระบบอย่างปลอดภัยด้วย OAuth authentication เพื่อปกป้องข้อมูลส่วนตัว (UC01)	M
Req 03	ในฐานะผู้ดูแล สามารถดูข้อมูลการตรวจวัดความเครียดของผู้ป่วยที่ดูแล เพื่อประเมินสภาพอย่างมีประสิทธิภาพ (UC02)	M
Req 04	ในฐานะผู้ดูแล สามารถค้นหาข้อมูลการตรวจวัดความเครียดตามช่วงเวลา หรือระดับความเครียด เพื่อการกรองและวิเคราะห์ข้อมูล (UC02)	S
Req 05	ในฐานะผู้ดูแล สามารถค้นหาข้อมูลผู้ป่วยและประวัติการตรวจวัดความเครียด เพื่อการเข้าถึงข้อมูลที่สะดวก (UC02)	C
Req 06	ในฐานะระบบ สามารถตรวจวัดระดับความเครียดด้วยสัญญาณทางสรีรวิทยาโดยใช้ Machine Learning เพื่อเพิ่มความแม่นยำในการตรวจจับความเครียด (UC02)	M

ลำดับ	คำอธิบายความต้องการ	ความสำคัญ (M, S, C, W)
Req 07	ในฐานะระบบ สามารถแจ้งเตือนผู้ดูแลเมื่อระดับความเครียดของผู้ป่วยอยู่ในระดับเครียดมาก (UC03)	M
Req 08	ในฐานะระบบ สามารถสร้างรายงานแนวโน้มความเครียดของผู้ป่วยเพื่อการติดตามผล (UC02)	S
Req 09	ในฐานะระบบ สามารถส่งออกข้อมูลการตรวจวัดความเครียดในรูปแบบเอกสาร PDF เพื่อการวิเคราะห์เพิ่มเติม (UC02)	C

3.3 แผนภาพ

แผนภาพ Use Case เป็นรายการและขั้นตอนการใช้งานระบบของผู้ดูแลและผู้ใช้งานเพื่อให้สามารถตรวจวัดความเครียดได้ทันทีทันใด โดยแผนภาพ Use Case ของระบบตรวจวัดความเครียดจะมีลักษณะดังภาพที่ 5



ภาพ 5 Use case ภาพรวมของระบบ

3.4 คุณลักษณะของระบบ

ตาราง 8 คุณลักษณะของระบบ

คุณลักษณะ: F-01 การลงทะเบียนและจัดการข้อมูลผู้ป่วย
คำอธิบาย: ระบบที่ออกแบบมาสำหรับจัดการข้อมูลสมาชิก ผู้ดูแลระบบสามารถกำหนดชื่อผู้ใช้ (username) และรหัสผ่าน (password) ให้กับผู้ดูแลได้ และผู้ดูแลผู้ป่วยสามารถจัดการข้อมูลของผู้ป่วยเช่น ลงทะเบียน แก้ไข หรือลบข้อมูล เพื่อความเหมาะสมกับการใช้งาน และยืนยันตัวตนเพื่อปกป้องข้อมูล
Actor: 1. ผู้ดูแลผู้ป่วย (Caregiver)
เงื่อนไข (ถ้ามี): - ผู้ใช้ต้องเป็นสมาชิกของระบบ - ผู้ดูแลผู้ป่วยสามารถจัดการข้อมูลสมาชิกของผู้ป่วย

- การยืนยันตัวตนจะใช้ OAuth Authentication เพื่อความปลอดภัย			
หมายเลข	คำอธิบายข้อกำหนดความต้องการ	ความสำคัญ	UC ที่เกี่ยวข้อง
Req 01	ผู้ดูแลระบบสามารถกำหนดชื่อผู้ใช้ (username) และรหัสผ่าน (password) ให้กับผู้ดูแลได้	M	UC01
Req 01	ในฐานะผู้ดูแลผู้ป่วย สามารถจัดการข้อมูลของผู้ป่วยได้ เช่น การแก้ไขหรืออัปเดตข้อมูลส่วนบุคคลของผู้ป่วย	M	UC01
Req 02	ในฐานะผู้ดูแล สามารถเข้าสู่ระบบอย่างปลอดภัยด้วย OAuth authentication เพื่อปกป้องข้อมูลส่วนตัว	M	UC01

คุณลักษณะ: F-02 รายงานและแนวโน้มความเครียด			
คำอธิบาย: ระบบช่วยให้ผู้ดูแลสามารถดูรายงานผลการตรวจวัดความเครียดย้อนหลัง พร้อมแสดงแนวโน้มเพื่อช่วยให้สามารถจัดการความเครียดได้อย่างเหมาะสม			
Actor: ผู้ดูแลผู้ป่วย (Caregiver)			
เงื่อนไข (ถ้ามี): - ต้องมีการบันทึกข้อมูลในฐานข้อมูล - รายงานต้องสามารถแสดงผลในรูปแบบกราฟ			
หมายเลข	คำอธิบายข้อกำหนดความต้องการ	ความสำคัญ	UC ที่เกี่ยวข้อง
Req 03	ในฐานะผู้ดูแลผู้ป่วย สามารถดูแนวโน้มความเครียดในรูปแบบกราฟ	M	UC02

คุณลักษณะ: F-03 ประเมินค่าระดับความเครียด			
คำอธิบาย: ระบบสามารถประเมินค่าความเครียดจากข้อมูลที่ได้รับ และแสดงผลในรูปแบบที่เข้าใจง่ายสำหรับผู้ใช้งาน			
Actor: ผู้ดูแลผู้ป่วย (Caregiver)			
เงื่อนไข (ถ้ามี):			
หมายเลข	คำอธิบายข้อกำหนดความต้องการ	ความสำคัญ	UC ที่เกี่ยวข้อง

Req 06	ในฐานะผู้ดูแลผู้ป่วย สามารถดูค่าประเมินความเครียดที่ถูกวิเคราะห์จากระบบ	M	UC02

คุณลักษณะ: F-04 การส่งสัญญาณชีวภาพ (EDA และ HRV)			
คำอธิบาย: ระบบสามารถรวบรวมและส่งข้อมูลสัญญาณชีวภาพ เช่น ค่า EDA และ HRV เพื่อใช้ในการวิเคราะห์ระดับ			
Actor: 1. ผู้ดูแลผู้ป่วย (Caregiver)			
เงื่อนไข (ถ้ามี): - ต้องมีการเชื่อมต่ออุปกรณ์ที่รองรับการวัดค่า EDA และ HRV			
หมายเลข	คำอธิบายข้อกำหนดความต้องการ	ความสำคัญ	UC ที่เกี่ยวข้อง
Req 06	ในฐานะผู้ดูแลผู้ป่วย สามารถเข้าถึงข้อมูลสัญญาณชีวภาพของผู้สูงอายุได้	M	UC02

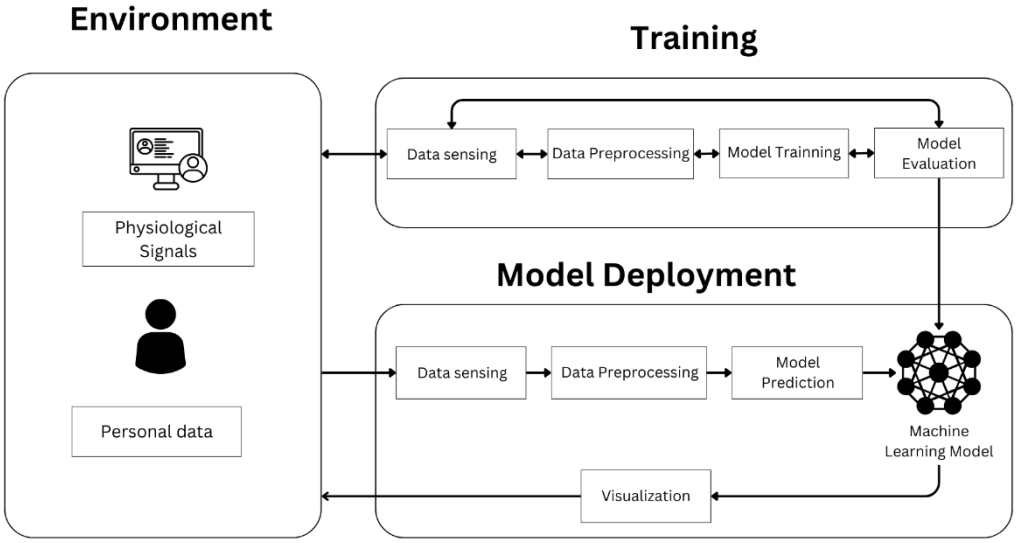
คุณลักษณะ: F-05 การแจ้งเตือนเมื่อระดับความเครียดเกินเกณฑ์			
คำอธิบาย: ระบบสามารถส่งการแจ้งเตือนไปยังผู้ดูแลและผู้ป่วยเมื่อระดับความเครียดของผู้ป่วยสูงเกินค่าที่กำหนด			
Actor: ผู้ดูแลผู้ป่วย (Caregiver)			
เงื่อนไข (ถ้ามี):			
หมายเลข	คำอธิบายข้อกำหนดความต้องการ	ความสำคัญ	UC ที่เกี่ยวข้อง
Req 07	ในฐานะผู้ดูแลผู้ป่วย สามารถรับการแจ้งเตือนเมื่อความเครียดเกินระดับที่กำหนด	M	UC03

บทที่ 4
การออกแบบระบบ

จากเทคโนโลยีที่นำมาใช้ในโครงการนี้ได้มีการออกแบบระบบเพื่อการศึกษาและพัฒนาโครงการ โดยใช้การจำลองสภาวะความเครียดเช่น วิตกกังวล ผ่านการกระตุ้นโดยสิ่งเร้า ภายนอก เพื่อเก็บข้อมูลสัญญาณ EDA และ HRV จากกลุ่มตัวอย่างซึ่งเป็นการจำลองในสถานการสถานการณ์ในสภาวะความเครียดจำนวน 25 คน เพื่อนำมาใช้ในการพัฒนาตัวแบบการเรียนรู้และระบบต้นแบบ

4.1 สถาปัตยกรรมซอฟต์แวร์ของระบบ

ขอบเขตการทดลองภายในโครงงานนี้แบ่งเป็น 3 ส่วน คือ กรอบแนวคิดการพัฒนาระบบและการทดลองเพื่อเก็บข้อมูลในการพัฒนาโมเดลการเรียนรู้ โดยกรอบแนวคิดการพัฒนาระบบดังกล่าว แสดงได้ดังภาพ



ภาพ 6 กรอบแนวคิดระบบตรวจวัดความเครียดโดยใช้เทคโนโลยีปัญญาประดิษฐ์ร่วมกับสัญญาณทางสรีระวิทยา

จาก**ภาพที่ 6** กรอบแนวคิดของระบบตรวจวัดความเครียดแบ่งออกเป็น 3 ส่วนหลัก คือ ส่วนสภาพแวดล้อม (Environment) เป็นการเก็บสัญญาณทางสรีระวิทยาจากผู้เข้าร่วมทดสอบเมื่อเกิดการกระตุ้นโดยสิ่งเร้า ปัจจัยทางสภาพแวดล้อมต่าง ๆ ส่วนการฝึกฝน (Model Training) เป็นส่วนที่ทำการฝึกฝนตัวแบบ machine learning model และส่วนการนำไปใช้งาน (Model Deployment) คือส่วนที่นำ model ที่สมบูรณ์แล้วนำไปใช้งานจริง

1. ส่วนสภาพแวดล้อม (Environment) ประกอบด้วยแหล่งข้อมูลสองประเภท ได้แก่
   1.1 สัญญาณทางสรีรวิทยา (Physiological Signals) เป็นข้อมูลที่วัดได้จากร่างกายของผู้ใช้ เช่น อัตราการเต้นของหัวใจ (HRV) และการนำไฟฟ้าที่ผิวหนัง (EDA)
   1.2 ข้อมูลส่วนตัว (Personal data) ข้อมูลส่วนตัวที่อาจส่งผลต่อผลลัพธ์จากทดสอบ ซึ่งเป็นการทดสอบความเครียดโดยใช้เกมเป็นเครื่องมือในการทดสอบทั้งหมด 3 ช่วง โดยมีปัจจัยจากข้อมูลต่างๆ เช่น โรคประจำตัว, อายุ และดัชนีมวลกาย (BMI) อาจส่งผลต่อระดับความเครียดในการทำการทดสอบ
2. ส่วนการฝึกฝนตัวแบบ (Model Training) แบ่งออกเป็น 4 ระยะ ได้แก่
   - ระยะที่ 1 การเก็บข้อมูล (Data Sensing) การเก็บข้อมูลจากผู้เข้าร่วมทดสอบจำนวน 25 คน
   - ระยะที่ 2 การเตรียมข้อมูล (Data Preprocessing) การนำข้อมูลที่ได้จากผู้เข้าร่วมการทดสอบมาทำการเตรียมข้อมูลให้พร้อมสำหรับการนำไปเทรนโมเดล
   - ระยะที่ 3 การฝึกฝนโมเดล (Model Training) การนำข้อมูลที่เตรียมพร้อมแล้วไปทำการสร้างโมเดล Machine Learning
   - ระยะที่ 4 การประเมิณผลโมเดล (Model Evaluation) การประเมิณผลโมเดลว่าโมเดลที่ได้มีประสิทธิภาพเพียงพอสำหรับการนำไปใช้งานหรือไม่
3. ส่วนการนำไปใช้งาน (Model Deployment) คือการนำโมเดล machine learning ที่ได้ไปใช้งานจริง แบ่งออกเป็น 2 ส่วน คือ ส่วนประมวลผล และส่วนนำเสนอ
   3.1 ส่วนประมวลผลจะแบ่งย่อยออกเป็น
   - การรับข้อมูล (Data sensing) คือรับข้อมูลทางสรีรวิทยาจากผู้ใช้งาน
   - การเตรียมข้อมูล (Data preprocessing) คือการจัดเตรียมข้อมูลให้พร้อมสำหรับนำไปใช้กับโมเดลที่ฝึกฝนไว้แล้ว
   - การทำนาย (Model Prediction) คือการนำข้อมูลไปให้โมเดลทำนายผลว่า ไม่เครียด เครียดน้อย เครียดปานกลาง หรือ เครียดมาก
   - การทำนาย (Model Prediction) คือการนำข้อมูลไปให้โมเดลทำนายผลว่า ไม่เครียด, เครียดน้อย, เครียดปานกลาง หรือ เครียดมาก
   3.2 ส่วนการนำเสนอ (Visualization) คือการนำเสนอข้อมูลออกมาในรูปแบบ Application เพื่อให้ผู้ใช้เข้าใจง่าย

4.2 การนำเข้าข้อมูล (Data Sensing)

การนำเข้าข้อมูลที่ได้จาก Environment ผ่านการทดลองต่าง ๆ โดยข้อมูลที่ได้เป็น ข้อมูลดิบ (Raw Data) คือไม่ผ่านกระบวนการจัดการข้อมูล หากข้อมูลที่ส่งมาใช้งานต่อไม่ได้ก็จะทำการเก็บข้อมูลใหม่จากกลุ่มตัวอย่าง

4.2.1 กลุ่มตัวอย่างที่เข้ารับการศึกษา

ประชากรที่จะใช้ศึกษาในโครงการวิจัยนี้เป็นบุคคลทั่วไปอายุตั้งแต่ 18 ปีขึ้นไป ที่มีสุขภาพร่างกายแข็งแรง และต้องไม่มีปัญหาทางด้านมีประวัติโรคทางจิตเวชที่รุนแรง

i. เกณฑ์การคัดเลือก (Inclusion Criteria)

ก. อายุระหว่าง 18-26 ปี

ข. สามารถสื่อสารและเข้าใจคำอธิบายเกี่ยวกับการทดลองได้

ค. ไม่มีโรคประจำตัวที่ส่งผลกระทบรุนแรงต่อการทำงานของระบบประสาทอัตโนมัติ

ง. ยินยอมเข้าร่วมการทดลองโดยสมัครใจและลงนามในหนังสือให้ความยินยอม

จ. ต้องมีค่าดัชนีมวลกาย (BMI) ดังต่อไปนี้

- BMI ต่ำกว่าเกณฑ์ (น้อยกว่า 18.5) จำนวน 8 ราย
- BMI อยู่ในเกณฑ์ปกติ (18.5-24.9) จำนวน 8 ราย
- BMI สูงกว่าเกณฑ์ (มากกว่า 25) จำนวน 9 ราย

ii. เกณฑ์การคัดออก (Exclusion Criteria)

1. มีประวัติโรคทางจิตเวชที่รุนแรง
2. กำลังใช้ยาที่มีผลต่อระบบประสาทอัตโนมัติอย่างมีนัยสำคัญ (เช่น ยาลดความดันโลหิต ยารักษาภูมิแพ้ ยาต้านโรคซึมเศร้า)
3. มีโรคประจำตัวที่ส่งผลกระทบต่อการทำงานของระบบประสาทอัตโนมัติ (เช่น โรคหัวใจ โรคเบาหวาน)
4. มีแผลหรือการบาดเจ็บบริเวณข้อมือที่จะใช้ติดอุปกรณ์วัดสัญญาณ
5. อยู่ในช่วงที่มีความเครียดสูงผิดปกติ ซึ่งวัดผลโดยแบบทดสอบระดับความเครียดโดยกรมสุขภาพจิต

4.2.2 สภาพแวดล้อมของห้องทดลอง

การควบคุมสภาพแวดล้อมให้เหมือนกันในทุกชุดการทดลองหรือทุกกลุ่มตัวอย่างที่เข้าร่วมการทดลอง เพื่อป้องกันไม่ให้ผลการทดลองเกิดความคลาดเคลื่อนจากปัจจัยอื่น

นอกเหนือจากการทดลองที่ได้ทำการกระตุ้นสภาวะตกใจของผู้เข้าร่วมการทดลองตามรายละเอียดดังนี้

1) อุณหภูมิห้อง (Room temperature)

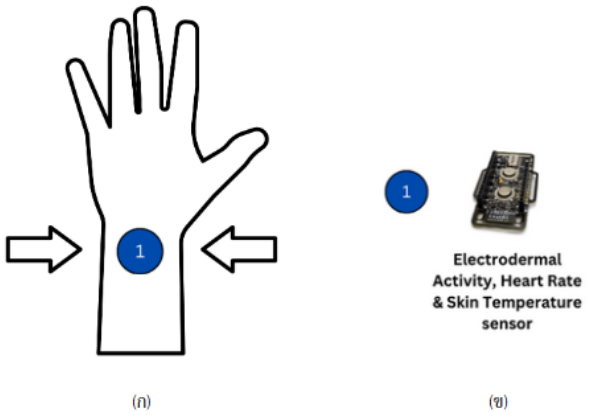
ช่วงของอุณหภูมิโดยทั่วไปที่มนุษย์รู้สึกสบายและเป็นอุณหภูมิมาตรฐานสำหรับพื้นที่ภายในอาคาร ช่วงอุณหภูมินี้สามารถขยายออกไปได้ขึ้นอยู่กับความชื้นการ ไหลเวียนของอากาศ และปัจจัยอื่น ๆ ในการทดลองนี้ได้กำหนดอุณหภูมิห้องคือ 23-25 °C

2) ระดับความดังของสื่อทดลอง

โดยกำหนดเสียงที่มนุษย์สามารถรับรู้ได้และไม่ก่อให้เกิดอันตรายโดยในการทดลองนี้ได้ คือ 85 dB (Lebedev และคณะ, 2020)

4.2.3 การติดตั้งอุปกรณ์ชุดเซนเซอร์

การวัดปัจจัยเชิงสรีระของกลุ่มตัวอย่างการทดลองเมื่อเกิดสภาวะตกใจจะติดตั้งอุปกรณ์ ชุดเซนเซอร์ดังภาพที่ 5 เพื่อเก็บข้อมูลจากผู้เข้าร่วมการทดลอง



ภาพ 7 แสดงตำแหน่งติดตั้งเซนเซอร์ในบริเวณต่าง ๆ ของผู้เข้าร่วมการทดลอง

จากภาพที่ **7** เป็นการติดตั้งอุปกรณ์เซนเซอร์บนสรีระของกลุมตัวอย่างผู้เข้าร่วมการทดลองเพื่อบันทึกการเปลี่ยนแปลงเชิงสรีรวิทยา การตอบสนองของร่างกายผู้ป่วยต่อการกระตุ้น ทางอารมณ์ โดยภาพ (ก) จะแสดงภาพจำลองการติดตั้งอุปกรณ์บริเวณมือ ภาพ (ข) จะแสดง ภาพอุปกรณ์เซนเซอร์ที ใช้ในการบันทึกการทดลอง ซึ่งหมายเลขที่ปรากฏในภาพจะแทนที่ของ เซนเซอร์ โดยหมายเลข 1 เป็นเซนเซอร์วัดกิจกรรมทางไฟฟ้าที่ผิวหนัง (Electrodermal Activity Sensor: EDA) และ อัตราการเต้นของหัวใจ (Heart Rate: HR) เพื่อประเมินการตอบสนองของร่างกายที่สัมผัสกับสภาพแวดล้อม

4.2.4 การออกแบบการทดลองเก็บข้อมูล

การออกแบบและพัฒนาตัวแบบการเรียนรู้ของเครื่องเพื่อจำแนกสภาวะความเครียดของ ผู้เข้าร่วมการทดลอง เป็นการวางแผนการทดลองก่อนลงมือปฏิบัติจริง โดยให้สอดคล้องกับการ เกิดสภาวะความเครียดในระดับปัจเจกบุคคล แบ่งระดับความเครียดเป็น 4 ระดับ (Critchley, 2002; Task Force of the European Society of Cardiology, 1996) ได้แก่ ระดับปกติ ระดับต่ำ ระดับปานกลาง และระดับสูง โดยควบคุมตัวแปรต่าง ๆ ที่มีผลต่อสภาวะตกใจ ได้แก่

1. ตัวแปรต้น (Manipulated Variable) คือ ตัวแปรที่ต้องทำการตรวจสอบดูว่าเป็นสาเหตุที่ก่อให้เกิดผลเช่นนั้นหรือไม่ ซึ่งในโครงงานนี้จะมีตัวแปรต้น ได้แก่ 1) กิจกรรม ทางไฟฟ้าที่ผิวหนัง (EDA) และ 2) อัตราการเต้นของหัวใจ (HR) โดยวิธีการที่ใช้กระตุ้นระดับความเครียด คือ การใช้เกม โดยจากการวิจัยของ (เหล่าแคบุญสูง, 2023) ได้นำเสนอ ให้เห็นว่าการเล่นเกมออนไลน์สามารถส่งผลต่อระดับความเครียดของผู้เล่นได้อย่างชัดเจน โดยเฉพาะในสถานการณ์ที่กำหนดเวลาหรือเพิ่มความซับซ้อนในตัวเกม ซึ่งสามารถกระตุ้นระบบการรับรู้ ความคิด และอารมณ์ของผู้เล่นในระดับต่าง ๆ ได้ ดังนั้นในโครงการนี้จึงเลือกการใช้เกม 3 ประเภท ดังนี้

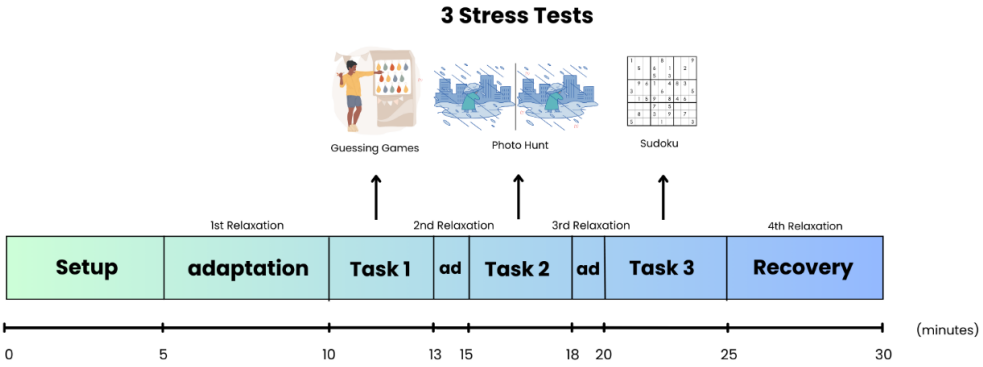
- เกมทายภาพ (Guessing Game) ผู้เข้าร่วมจะต้องทายภาพที่ปรากฏภายในเวลาที่กำหนด เพื่อสร้างความกดดันและกระตุ้นความเครียดในระดับหนึ่ง
- เกมจับผิดภาพ (Photo Hunt) ผู้เข้าร่วมต้องค้นหาความแตกต่างระหว่างสองภาพภายในเวลาที่จำกัด ซึ่งต้องใช้ความสังเกตและความรวดเร็วในการตัดสินใจ
- เกมซูโดกุ (Sudoku) เกมปริศนาตัวเลขที่ต้องใช้การคิดวิเคราะห์และการแก้ปัญหาในเวลาที่กำหนด เพื่อทดสอบความสามารถในการจัดการกับความเครียด

2. ตัวแปรตาม (Dependent Variable) คือ ผลที่เกิดจากการทดลองตามตัวแปรต้น โดยการสังเกตหรือวัดผลด้วยวิธีการต่าง ๆ เพื่อเก็บข้อมูลไว้ ซึ่งในโครงงานนี้จะมีตัวแปรตามคือ ระดับความรู้สึกเครียด ที่ได้จากการบันทึกการตอบแบบสอบถามของกลุ่มตัวอย่าง ซึ่งระดับความเครียดจะแบ่งออกเป็น 4 ระดับ ได้แก่

ตาราง 9 ตารางแสดงระดับความเครียดและนิยามของความเครียด

ระดับความเครียด	นิยาม	ปัจจัยที่ส่งผลต่อระดับความเครียด	ค่าทางสถิติของสัญญาณ EDA		ค่าทางสถิติของสัญญาณ HRV	
ระดับปกติ	ความเครียดในระดับที่พบได้ในชีวิตประจำวัน ไม่ส่งผลกระทบต่อการดำเนินชีวิต	การพักผ่อน ความสงบ การทำกิจกรรมเบา ๆ	SCL	SCR	SDNN	RMSSD
			5-10 µS	0.05-0.1 Hz	20-50 ms	20-40 ms
ระดับต่ำ	เริ่มรู้สึกถึงความเครียดเล็กน้อย มีความกังวลแต่ยังสามารถจัดการได้	งานที่มีความท้าทายเล็กน้อยและการเปลี่ยนแปลงในชีวิตประจำวัน	< 5 µS	< 0.05 Hz	< 20 ms	< 20 ms
ระดับปานกลาง	ความเครียดที่เริ่มส่งผลกระทบต่อชีวิตประจำวัน อาจต้องการการจัดการที่ดีขึ้น	ความกดดันจากการทำงาน ปัญหาความสัมพันธ์ ความกังวลทางการเงิน	10-15 µS	0.1-0.15 Hz	50-100 ms	40-60 ms
ระดับสูง	ความเครียดที่ส่งผลกระทบอย่างมากต่อการดำเนินชีวิต จำเป็นต้องการความช่วยเหลือจากผู้เชี่ยวชาญ	การทำงานภายใต้แรงกดดันสูง การสูญเสียคนใกล้ชิด ปัญหาสุขภาพรุนแรง	15 µS	0.15 Hz	> 100 ms	> 60 ms

3. ตัวแปรควบคุม (Control Variable) คือ ปัจจัยอื่น ๆ ที่นอกเหนือจากตัวแปรต้นที่มี ผลต่อการทดลอง และต้องควบคุมให้เหมือนกันทุกชุดการทดลอง เพื่อป้องกันไม่ ให้ผลการทดลองเกิดความคลาดเคลื่อน ซึ่งในโครงงานนี้จะมีตัวแปรควบคุม คือ สิ่ง เร้าที่ใช้ในการกระตุ้น ขนาดของห้อง ปัจจัยทางสิ่งแวดล้อม ได้แก่ อุณหภูมิ 23-25 °C ระดับเสียงของการทดลองคือ 85 dB ความเงียบภายในห้องและบริเวณรอบ ๆ ซึ่งตัวแปรทั้งหมดเหล่านี้จะเป็นตัวแปรที่ต้องควบคุมให้เหมือนกันทุกชุด การทดลองดังแสดงใน**ภาพที่ 8**



ภาพ 8 แผนภาพแสดงขั้นตอนการทดลอง

จาก**ภาพที่ 8** ภาพนี้เป็นการทดลองที่ออกแบบเพื่อประเมินระดับความเครียดของผู้เข้าร่วม โดยใช้การทดสอบ แบ่งออกได้เป็น 3 ช่วงการทดสอบ และการวัดสัญญาณทางสรีรวิทยา โครงสร้างการทดลองแบ่งออกเป็น 3 ช่วงหลัก รวมระยะเวลา 30 นาที ดังนี้

1. ช่วงเตรียมการ (Setup) นาทีที่ 0-5
   - ติดตั้งอุปกรณ์วัดสัญญาณทางสรีรวิทยา
   - ชี้แจงขั้นตอนการทดลองแก่ผู้เข้าร่วม และอธิบายรายละเอียดในแต่ละช่วงการทดสอบ
   - ทำการเก็บข้อมูลด้วยแบบสอบถามระดับความรู้สึกเครียด
2. ช่วงปรับตัว (Adaptation) นาทีที่ 5-10
   - ดำเนินกิจกรรมผ่อนคลายครั้งที่ 1 เพื่อให้ผู้เข้าร่วมปรับสภาพร่างกายและจิตใจเตรียมพร้อมสำหรับการทดสอบ
3. ช่วงทดสอบ (Task) นาทีที่ 10-25
   - ผู้เข้าร่วมทำการทดสอบความเครียดแบ่งออกเป็น 3 ช่วง ได้แก่
     - ช่วงที่ 1 ใช้เวลาในการทดสอบ 3 นาที โดยใช้เกมทายภาพ (Guessing Game)
     - ดำเนินกิจกรรมผ่อนคลายครั้งที่ 2 ใช้เวลา 2 นาที เพื่อให้ผู้เข้าร่วมปรับสภาพร่างกายและจิตใจเตรียมพร้อมสำหรับการทดสอบช่วงที่ 2 โดยระหว่างนั้นจะทำการเก็บข้อมูลด้วยแบบสอบถามระดับความรู้สึกเครียด 15 วินาที
     - ช่วงที่ 2 ใช้เวลาในการทดสอบ 3 นาที โดยใช้เกมจับผิดภาพ (Photo Hunt)
     - ดำเนินกิจกรรมผ่อนคลายครั้งที่ 3 ใช้เวลา 2 นาที เพื่อให้ผู้เข้าร่วมปรับสภาพร่างกายและจิตใจเตรียมพร้อมสำหรับการทดสอบช่วงที่ 3 โดยระหว่างนั้นจะทำการเก็บข้อมูลด้วยแบบสอบถามระดับความรู้สึกเครียด 15 วินาที
     - ช่วงที่ 3 ใช้เวลาในการทดสอบ 5 นาที โดยใช้เกมซูโดกุ (Sudoku)
   - เก็บข้อมูลสัญญาณทางสรีรวิทยารตลอดการทำแบบทดสอบ

4. ช่วงฟื้นตัว (Recovery): นาทีที่ 25-30
    - ดำเนินกิจกรรมผ่อนคลายครั้งที่ 4 เพื่อให้ผู้เข้าร่วมกลับสู่สภาวะปกติโดยระหว่างนั้นจะทำการเก็บข้อมูลด้วยแบบสอบถามระดับความรู้สึกเครียดหลังจากทำการทดสอบครั้งที่ 3 เสร็จสิ้นและหลังจบการทดลองแล้วเสร็จเพื่อให้แน่ใจว่าผู้เข้าร่วมทดสอบกลับเข้าสู่สภาวะอารมณ์ปกติ

โดยการวัดสัญญาณทางสรีรวิทยาอย่างต่อเนื่องตลอดการทดลอง สามารถเปรียบเทียบการเปลี่ยนแปลงในแต่ละช่วง ซึ่งจะให้ข้อมูลเชิงลึกเกี่ยวกับกลไกการตอบสนองต่อความเครียดของแต่ละบุคคล การทดลองนี้ออกแบบมาเพื่อให้ได้ข้อมูลที่ครอบคลุมทั้งด้านจิตวิทยาและสรีรวิทยา โดยใช้เวลาอย่างมีประสิทธิภาพ ซึ่งเหมาะสมสำหรับการศึกษาวิจัยเกี่ยวกับความเครียดในสภาพแวดล้อมที่ควบคุมได้การออกแบบและพัฒนาตัวแบบการเรียนรู้ของเครื่องเพื่อจำแนกสภาวะความเครียดของ ผู้เข้าร่วมการทดลอง เป็นการวางแผนการทดลองก่อนลงมือปฏิบัติจริง โดยให้สอดคล้องกับการ เกิดสภาวะความเครียดในระดับปัจเจกบุคคล โดยควบคุมตัวแปรต่าง ๆ ที่มีผลต่อสภาวะความเครียด

4.3 การเตรียมข้อมูล (Data Preprocessing)

จากการเก็บข้อมูลของผู้เข้าร่วมการทดลองทั้งหมด 25 คน ข้อมูลที่ได้รวมทั้งหมด 5,175,000 ชุดข้อมูล โดยแบ่งข้อมูลออกเป็น 2 ประเภท คือ 1) สัญญาณ EDA มีชุดข้อมูลทั้งหมด 675,000 ชุดข้อมูล โดยข้อมูลมีลักษณะเป็น 15 ชุด / วินาที 2) สัญญาณ PPG มีชุดข้อมูลทั้งหมด 4,500,000 ชุดข้อมูล โดยข้อมูลมีลักษณะเป็น 100 ชุด / วินาที แล้วนำข้อมูลมาทำให้เป็น 1 ชุดข้อมูล / วินาที และสกัดคุณลักษณะต่าง ๆ ของข้อมูล รวมถึงผลการ Label ของข้อมูลโดยรายละเอียดข้อมูลจะเป็นไปตาม**ตารางที่ 10** **ตารางที่ 11** และ**ตารางที่ 12**



ภาพ 9 แผนภาพแสดงขั้นตอนการเตรียมข้อมูล

กระบวนการเตรียมข้อมูลมีเป้าหมายหลักเพื่อแปลงข้อมูลดิบเหล่านี้ให้อยู่ในรูปแบบที่เหมาะสมสำหรับการสร้างโมเดลเรียนรู้ของเครื่อง โดยจะมีการสกัดคุณลักษณะ (feature extraction) ที่สำคัญ และปรับให้อยู่ในลักษณะของชุดคุณลักษณะ (feature set) ที่มีอัตรา 1 ชุดต่อวินาที (1 Hz) สำหรับการวิเคราะห์ความเครียดในขั้นตอนต่อไป กระบวนการนี้อาศัยไลบรารี neurokit2 โดยใช้ฟังก์ชันหลัก เช่น ppg_process() สำหรับการประมวลผลสัญญาณ PPG เบื้องต้น (เช่น การทำความสะอาดสัญญาณและการหาตำแหน่งค่าพีค) และ eda_process() สำหรับการ

ประมวลผลและสกัดคุณลักษณะจากสัญญาณ EDA จากภาพที่ 9 คือขั้นตอนการการเตรียมข้อมูลซึ่งมีขั้นตอนดังนี้

1. Clean หรือการทำความสะอาดข้อมูล คือ การกรองข้อมูลโดยการลบข้อมูลที่มีสัญญาณรบกวนออก และทำการแปลงเวลาประทับให้เป็นเวลาตามประเทศไทย (GMT+7)
2. Remove Outlier หรือการจัดการข้อมูลผิดปกติ คือการลบข้อมูลที่อยู่นอกเหนือจากค่า z score โดยการหา z score มีสูตรดังนี้

$$z = \frac{(x - \mu)}{\sigma}$$

z ค่า Z-score
x ค่าเฉพาะจุดที่ต้องการหา Z-score
μ ค่าเฉลี่ยของชุดข้อมูล
σ ส่วนเบี่ยงเบนมาตรฐานของชุดข้อมูล

3. Preprocess data หรือการเตรียมการข้อมูล โดยใช้ฟังก์ชัน ppg_process() และ eda_process() เพื่อสกัดคุณลักษณะออกมาจากข้อมูลแต่ละประเภท
4. Resampling คือการนำความถี่ของข้อมูลมาหาค่าเฉลี่ย เพื่อให้ได้ 1 ชุดข้อมูล / วินาที

4.3.1 Preprocess Data

กระบวนการการเตรียมข้อมูลก่อนนำไปฝึกฝนโมเดลการเรียนรู้ของเครื่อง เพื่อทำนายผลลัพธ์ของข้อมูล มีขั้นตอนหลักดังนี้

1. การทำความสะอาดข้อมูล (Data Cleaning)
    - การกรองสัญญาณรบกวน สัญญาณรบกวนในข้อมูล EDA และ PPG ได้รับการจัดการเบื้องต้นโดยฟังก์ชัน eda_process() และ ppg_process() จากไลบรารี neurokit2 ซึ่งมีกระบวนการทำความสะอาดสัญญาณ (signal cleaning) อยู่ภายใน
    - การแปลงเวลาประทับ (Timestamp Conversion) ข้อมูลเวลาประทับ (LocalTimestamp ในรูปแบบ Unix timestamp) ถูกแปลงให้เป็นรูปแบบ DateTime ที่สามารถอ่านได้ง่าย และปรับให้เป็นเวลามาตรฐานประเทศไทย (GMT+7) โดยใช้ไลบรารี pandas
2. การกำจัดค่าผิดปกติ (Remove Outlier)
    - ใช้วิธี z-score โดยกำหนดเกณฑ์ $|z| > 3$ เป็นค่าผิดปกติ

- ข้อมูลที่มีค่า Z-score นอกช่วง -3 ถึง 3 จะถูกกำจัดออกเพื่อลดความคลาดเคลื่อนของโมเดล

3. การสกัดคุณลักษณะ (Feature Extraction)
    - สัญญาณ EDA ใช้ฟังก์ชัน eda_process() จาก neurokit2 เพื่อทำความสะอาดสัญญาณและสกัดคุณลักษณะต่างๆ ที่เกี่ยวข้องกับการตอบสนองทางไฟฟ้าของผิวหนัง เช่น EDA Tonic
    - สัญญาณ PPG ใช้ฟังก์ชัน ppg_process() จาก neurokit2 เพื่อทำความสะอาดสัญญาณและตรวจจับตำแหน่งพีค (peak detection) จากสัญญาณ PPG ที่ระบุ จากนั้นจึงคำนวณคุณลักษณะที่เกี่ยวข้องกับอัตราการเต้นของหัวใจ (Heart Rate) และความแปรปรวนของอัตราการเต้นของหัวใจ (Heart Rate Variability - HRV) โดยละเอียด เช่น HRV_RMSSD, HRV_LFHF
4. การปรับความถี่ข้อมูล (Resampling)
    - HRV จะถูกนำมาหาค่าเฉลี่ยในแต่ละวินาที เพื่อให้ได้ชุดคุณลักษณะในอัตรา 1 ชุดต่อวินาที (5 Hz) จากข้อมูลดิบเดิมที่เป็น 100 ชุดต่อวินาที
    - EDA จะถูกนำมาหาค่าเฉลี่ยในแต่ละวินาที เพื่อให้ได้ชุดคุณลักษณะในอัตรา 1 ชุดต่อวินาที (1 Hz) จากข้อมูลดิบเดิมที่เป็น 15 ชุดต่อวินาที

4.3.2 การเข้ารหัสคลาส (label encoding)

เนื่องจากตัวแปรเป้าหมาย 'stress' และตัวแปรคุณลักษณะบางตัว เช่น 'gender', 'type', และ 'sleep' เป็นข้อมูลเชิงคุณภาพ (categorical data) จึงจำเป็นต้องทำการแปลงข้อมูลเหล่านี้ให้อยู่ในรูปแบบตัวเลขเพื่อให้โมเดลสามารถประมวลผลได้ ในการทดลองนี้ใช้วิธี Label Encoding ซึ่งเป็นการกำหนดค่าตัวเลขที่ไม่ซ้ำกันให้กับแต่ละคลาสหรือแต่ละประเภทของข้อมูล ผลลัพธ์การแปลงข้อมูล

ตาราง 10 ตารางการเข้ารหัสคลาส (label encoding)

ข้อมูล	รหัสคลาส
female, male	0, 1
Skin Type 2, Skin Type 3, Skin Type 4, Skin Type 5,	0, 1, 2, 3
6 - 8 hours, less than 8 hours, more than 8 hours	0, 1, 2
high, low, medium, normal	0, 1, 2, 3

4.3.3 การปรับสเกลข้อมูล (Scaling)

เพื่อให้โมเดลการเรียนรู้ของเครื่องสามารถเรียนรู้ได้อย่างมีประสิทธิภาพและป้องกันไม่ให้คุณลักษณะ (features) ที่มีค่าตัวเลขสูงมีอิทธิพลมากกว่าคุณลักษณะที่มีค่าต่ำโดยไม่จำเป็น จึงต้องมีการปรับสเกลของข้อมูลเชิงปริมาณให้อยู่ในช่วงที่เหมาะสม ในการทดลองนี้เลือกใช้วิธี StandardScaler จากไลบรารี scikit-learn วิธีนี้จะทำการแปลงข้อมูลแต่ละคุณลักษณะ (ยกเว้นคอลัมน์ 'id' และคอลัมน์ label) ให้มีค่าเฉลี่ย (mean) เป็น 0 และส่วนเบี่ยงเบนมาตรฐาน (standard deviation) เป็น 1 ซึ่งช่วยให้โมเดลสามารถเรียนรู้และปรับปรุงค่าพารามิเตอร์ได้อย่างมีประสิทธิภาพมากขึ้น

4.3.4 การสร้างลำดับข้อมูล (Sequence Creation)

เนื่องจากข้อมูลสัญญาณ EDA และ PPG เป็นข้อมูลอนุกรมเวลา (time-series data) ซึ่งลำดับของข้อมูลมีความสำคัญ การสร้างลำดับข้อมูล (sequences) จะช่วยให้โมเดลโดยเฉพาะโมเดลประเภท Recurrent Neural Network (RNN) เช่น LSTM สามารถเรียนรู้รูปแบบและความสัมพันธ์เชิงเวลา (temporal patterns) ที่ปรากฏในข้อมูลได้ดีขึ้น ในการทดลองนี้ มีการสร้างลำดับข้อมูลจากชุดคุณลักษณะที่ได้เตรียมไว้ โดยกำหนดความยาวของแต่ละลำดับเท่ากับ 30 วินาที/ชุดคุณลักษณะ ทำให้ได้ข้อมูลป้อนเข้าโมเดลในรูปแบบ 3 มิติ คือ (จำนวนตัวอย่างทั้งหมด, ความยาวลำดับ, จำนวนคุณลักษณะ) ซึ่งจะสร้างลำดับข้อมูลโดยอ้างอิงจากรหัสผู้เข้าร่วมการทดลอง ('id') คือ ลำดับข้อมูลจะถูกสร้างขึ้นหากป้ายกำกับระดับความเครียด (stress label) ภายในหน้าต่างของลำดับข้อมูลที่ใช้สร้างคุณลักษณะนั้นมีค่าเดียวกันทั้งหมด และโมเดลจะถูกฝึกให้ทำนายป้ายกำกับ ณ เวลาถัดไป

4.3.5 การจัดการข้อมูลไม่สมดุล (SMOTE)

ในชุดข้อมูลที่เกี่ยวข้องกับสภาวะทางอารมณ์หรือความเครียด มักจะประสบปัญหาข้อมูลไม่สมดุล (imbalanced data) กล่าวคือ จำนวนข้อมูลในแต่ละคลาสของระดับความเครียด (เช่น normal, low, medium, high) อาจมีจำนวนไม่เท่ากัน โดยเฉพาะคลาสที่มีระดับความเครียดสูงอาจมีจำนวนน้อยกว่าคลาสอื่นๆ หากนำข้อมูลที่ไม่สมดุลนี้ไปฝึกโมเดลโดยตรง โมเดลอาจมีแนวโน้มที่จะเอนเอียงไปทางคลาสที่มีจำนวนข้อมูลมากกว่า (majority class) และทำนายคลาสที่มีจำนวนข้อมูลน้อย (minority class) ได้ไม่ดี เพื่อแก้ไขปัญหานี้ ในการทดลองจึงได้ใช้เทคนิค SMOTE (Synthetic Minority Over-sampling Technique) กับชุดข้อมูลฝึกฝน (training set) เท่านั้น (หลังจากการแบ่งข้อมูล Train/Test) SMOTE ทำงานโดยการสร้างข้อมูลสังเคราะห์ (synthetic samples) สำหรับคลาสที่มีจำนวนน้อย โดยพิจารณาจากข้อมูลที่มีอยู่จริงในคลาสเดียวกัน การใช้ SMOTE ช่วยให้โมเดลสามารถเรียนรู้จากทุกคลาสได้อย่างทั่วถึงมากขึ้นและป้องกันการเอนเอียง โดย

มีการปรับค่า k_neighbors แบบไดนามิกเพื่อป้องกันข้อผิดพลาดในกรณีที่คลาสมีจำนวนน้อยมาก

4.3.6 การแบ่งข้อมูล (Train/Test Split)

การแบ่งข้อมูลออกเป็นชุดสำหรับฝึกโมเดล (training set) และชุดสำหรับทดสอบ (test set) เป็นขั้นตอนสำคัญในการประเมินประสิทธิภาพของโมเดล ในการทดลองนี้ ได้ใช้ฟังก์ชัน train_test_split จาก sklearn.model_selection หลังจากสร้างลำดับข้อมูล (sequences) เรียบร้อยแล้ว โดยกำหนดให้ชุดทดสอบมีขนาด 30% ของข้อมูลทั้งหมด และใช้พารามิเตอร์ stratify=y เพื่อให้สัดส่วนของระดับความเครียดในชุดฝึกและชุดทดสอบใกล้เคียงกัน แต่การใช้ train_test_split กับชุดข้อมูล sequences ที่รวมข้อมูลจากผู้เข้าร่วมทั้งหมดไว้ด้วยกันอาจทำให้ข้อมูลของผู้เข้าร่วมคนเดียวกันกระจายไปอยู่ทั้งในชุดฝึกและชุดทดสอบ ดังนั้นในการแบ่งข้อมูลจึงได้ทำการแบ่งผู้เข้าร่วมการทดลอง (ตาม ID) ออกเป็นกลุ่มฝึกและกลุ่มทดสอบก่อน แล้วจึงสร้างลำดับข้อมูลสำหรับแต่ละกลุ่มแยกจาก ซึ่งจะช่วยรักษาความเป็นอิสระของข้อมูลระหว่างชุดฝึกและชุดทดสอบได้ดีกว่า

ตาราง 11 ข้อมูลที่ได้รับจากอุปกรณ์ก่อนเตรียมข้อมูล

ลำดับที่	ชื่อตัวแปร	ช่วงข้อมูล	ที่มาของข้อมูล	คำอธิบาย
1	EDA_Raw	Numeric [0.2464 +/- 0.4900 (0.0301 – 3.5727)]	จากการเก็บข้อมูล	ข้อมูลที่ยังไม่ผ่านกระบวนการประเมิณผลข้อมูล
2	PPG_Raw	Numeric [5,553.6307 +/- 2,609.8162 (1,361.6633 – 14,257.8064)]	จากการเก็บข้อมูล	ข้อมูลที่ยังไม่ผ่านกระบวนการประเมิณผลข้อมูล

ตาราง 12 ข้อมูลที่ได้รับจากอุปกรณ์หลังการเตรียมข้อมูล

ลำดับที่	ชื่อตัวแปร	ช่วงข้อมูล	ที่มาของข้อมูล	คำอธิบาย
1	EDA_Clean	Numeric [0.2464 +/- 0.4900 (0.0301 – 3.5728)]	จากการสกัดคุณลักษณะ	ข้อมูลที่ผ่านการกรองสัญญาณข้อมูล
2	EDA_Tonic	Numeric [0.2463 +/- 0.4839 (0.0126– 3.2399)]	จากการสกัดคุณลักษณะ	แสดงความต่ำหรือสูงที่คงที่โดยไม่มีการ เปลี่ยนแปลงที่

ลำดับที่	ชื่อตัวแปร	ช่วงข้อมูล	ที่มาของข้อมูล	คำอธิบาย
				สัมพันธ์กับสิ่งต่าง ๆ ที่เกิดขึ้นรอบ ๆ
3	EDA_Phasic	Numeric [-3.3564 +/- 0.0554e-05 (0.0126– 3.2399)]	จากการสกัดคุณลักษณะ	มีการเปลี่ยนแปลงที่เกิดขึ้นขณะที่กำลังตอบสนองต่อเหตุการณ์
4	PPG_Clean	Numeric [-0.0444 +/- 41.2373 (-168.7803 – 168.8205)]	จากการสกัดคุณลักษณะ	ข้อมูลที่ผ่านการกรองสัญญาณข้อมูล
5	HRV_LF	Numeric [0.0099 +/- 0.0234 (0.0050– 0.03833)]	จากการสกัดคุณลักษณะ	แสดงพลังงานในช่วงความถี่ต่ำ (Low Frequency: 0.04–0.15 Hz) ซึ่งสัมพันธ์กับการทำงานของระบบประสาทอัตโนมัติทั้ง Sympathetic และ Parasympathetic
6	HRV_HF	Numeric [0.02321+/- 0.0148 (0.0004– 0.0467)]	จากการสกัดคุณลักษณะ	แสดงพลังงานในช่วงความถี่สูง (High Frequency: 0.15–0.4 Hz) ซึ่งสะท้อนการทำงานของระบบประสาทพาราซิมพาเทติก (Parasympathetic)
7	HRV_VHF	Numeric [0.0013+/- 0.0010 (1.97e-06 – 0.0040)]	จากการสกัดคุณลักษณะ	แสดงพลังงานในช่วงความถี่สูงมาก (Very High Frequency: >0.4 Hz) ซึ่งใช้ในงานวิจัยเฉพาะเพื่อวิเคราะห์การตอบสนองรวดเร็วของระบบหัวใจและหลอดเลือด

ตาราง 13 ข้อมูลที่ได้จากแบบสอบถาม

ลำดับที่	ชื่อตัวแปร	ช่วงข้อมูล	จำนวน	คำอธิบาย
1	Gender	Female	12	เพศ
		Male	13	
2	BMI	Slim	7	ค่าดัชนีมวลกาย
		Normal	8	
		Overweight	10	
3	Time_to_sleep	Less than 8 hours	6	ระยะเวลาการนอน ก่อนวันที่ทดลอง
		6-8 hour Sleep Quality	14	
		More than 8 hours	5	
4	Skin_color	Type 1	0	ระดับของสีผิว
		Type 2	2	
		Type 3	9	
		Type 4	13	
		Type 5	1	
5	Has_chronic_condition	TRUE	3	มีโรคประจำตัวหรือไม่
		FALSE	12	
6	Stress	Normal	6	ความเครียด 4 ระดับ
		low	32	
		moderate	33	
		high	10	

ตาราง 14 ข้อมูลที่เลือกใช้สำหรับการพัฒนาตัวแบบการเรียนรู้

ลำดับที่	ชื่อตัวแปร	ช่วงข้อมูล	ที่มาของข้อมูล	คำอธิบาย
1	EDA_Phasic	Numeric [-3.3564 +/- 0.0554e-05 (0.0126–3.2399)]	จากการสกัดคุณลักษณะ	มีการเปลี่ยนแปลงที่เกิดขึ้นขณะที่กำลังตอบสนองต่อเหตุการณ์
2	EDA_Tonic	Numeric [0.2463 +/- 0.4839 (0.0126–3.2399)]	จากการสกัดคุณลักษณะ	แสดงความต่ำหรือสูงที่คงที่โดยไม่มีการ เปลี่ยนแปลงที่สัมพันธ์กับสิ่งต่าง ๆ ที่เกิดขึ้นรอบ ๆ
3	SCR_Amplitude	Numeric [0.0000 +/-	จากการสกัด	ขนาดของการตอบสนอง

ลำดับที่	ชื่อตัวแปร	ช่วงข้อมูล	ที่มาของข้อมูล	คำอธิบาย
		0.0007 (0.0000–0.0333)]	คุณลักษณะ	ผิวหนังต่อสิ่งเร้า (ความแรงของ SCR)
4	SCR_Onsets	Numeric [0.0092 +/- 0.0248 (0.0000–0.2000)]	จากการสกัดคุณลักษณะ	จำนวนครั้งที่มีการตอบสนองผิวหนังเกิดขึ้น
5	HRV_SDNN	Numeric [175.4565 +/- 135.3884 (28.8612–1328.0000)]	จากการสกัดคุณลักษณะ	ค่าความเบี่ยงเบนมาตรฐานของช่วงเวลาหัวใจเต้นต่อเนื่อง
6	HRV_RMSSD	Numeric [236.8445 +/- 180.9788 (27.4753–1822.4110)]	จากการสกัดคุณลักษณะ	ค่ารากที่สองของค่าเฉลี่ยกำลังสองของความแตกต่าง RR ถัดกัน
7	HRV_LF	Numeric [0.0253 +/- 0.0145 (0.0013–0.0670)]	จากการสกัดคุณลักษณะ	พลังงานคลื่นความถี่ต่ำสัมพันธ์กับการควบคุมอัตโนมัติของหัวใจ
8	HRV_HF	Numeric [0.0491 +/- 0.0284 (0.0018–0.1338)]	จากการสกัดคุณลักษณะ	พลังงานคลื่นความถี่สูงสัมพันธ์กับการหายใจและพาราซิมพาเทติก
9	HRV_LFHF	Numeric [0.5892 +/- 0.3407 (0.1258–3.8958)]	จากการสกัดคุณลักษณะ	อัตราส่วนระหว่าง LF ต่อ HF ใช้บ่งชี้สมดุลระบบประสาทอัตโนมัติ
10	Gender	Female (12 คน)	แบบสอบถาม	เพศ
		Male (13 คน)		
11	BMI	Slim (7 คน)	แบบสอบถาม	ค่าดัชนีมวลกาย
		Normal (8 คน)		
		Overweight (10 คน)		
12	Time_to_sleep	Less than 8 hours (6 คน)	แบบสอบถาม	ระยะเวลาการนอน ก่อนวันที่ทดลอง
		6-8 hour Sleep Quality (14 คน)		
		More than 8 hours (5 คน)		

ลำดับที่	ชื่อตัวแปร	ช่วงข้อมูล	ที่มาของข้อมูล	คำอธิบาย
13	Skin_color	Type 2 (2 คน)	แบบสอบถาม	ระดับของสีผิว
		Type 3 (9 คน)		
		Type 4 (13 คน)		
		Type 5 (1 คน)		

4.4 การพัฒนาตัวแบบการเรียนรู้

การนำข้อมูลที่ผ่านกระบวนการประมวลผลข้อมูลเรียบร้อยแล้วจากขั้นตอน Data Preprocessing ข้อมูลที่ได้จะเป็นลักษณะไฟล์ DataFrame (.csv) และมีผล Label ออกเป็น 4 กลุ่มข้อมูล คือ ระดับปกติ ระดับต่ำ ระดับปานกลาง และระดับสูง

4.4.1 ปัญหาที่เกิดกับข้อมูล

ข้อมูลที่ได้จากกลุ่มตัวอย่างผู้ทดลอง ซึ่งเป็นข้อมูลที่ไม่พร้อมในการนำเข้าสู่การเรียนรู้ ของโมเดลโดยทันที เนื่องจากข้อมูลมีจำนวนที่ไม่เท่ากันจากการเก็บข้อมูลโดยเทคโนโลยีที่ใช้ใน การพัฒนาทั้ง 4 แบบ และไม่มีผล label เพื่อให้โมเดลทำการเรียนรู้

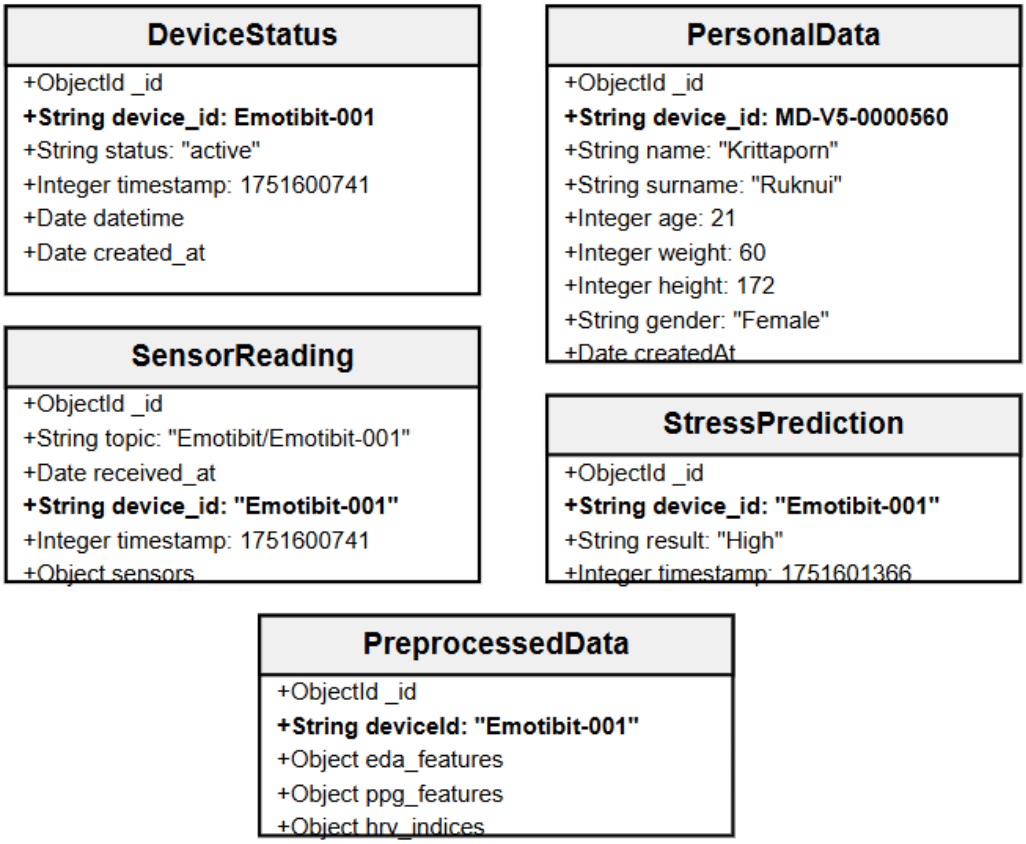
4.4.2 ลักษณะของข้อมูล

ข้อมูลที่ได้เพื่อนำเข้าสู่การเรียนรู้ของโมเดล คือข้อมูลที่ผ่านกระบวนการประมวลผลข้อมูลจาก Data Preprocessing โดยข้อมูลที่ได้คือ DataFrame (.csv) จะประกอบด้วยคอลัมน์ (column) ของสัญญาณ EDA จากฟังก์ชัน eda_process() สัญญาณ HRV จากฟังก์ชัน ppg_process() ลักษณะทางกายภาพของผู้เข้าร่วม การทดลองแต่ละบุคคลจากการกรอกแบบสอบถาม และสุดท้ายคือผล label ของข้อมูล

4.4.3 Algorithm ที่ใช้ในการพัฒนา

เนื่องจากข้อมูลของโครงการนี้เป็นการ classification หรือการแยกกลุ่มของข้อมูลจาก ข้อมูลที่โมเดลได้เรียนรู้เพื่อให้ได้ผลลัพธ์ตามผล label Algorithm ของการ classification ที่ เป็นไปได้ในการเรียนรู้ข้อมูลของโครงการนี้คือ RNN, LSTM และ GRU การนำ Algorithm มาใช้กับข้อมูลจะต้องทำการ เปรียบเทียบ Algorithm ที่เป็นไปได้ทั้งหมด และเลือก Algorithm ที่ดีที่สุดในการพัฒนาตัว ต้นแบบการเรียนรู้

4.5 Data Schema



ภาพที่ 9 แผนภาพ UML Class Diagram โครงสร้างของฐานข้อมูล

จาก**ภาพที่ 9** แผนภาพ UML Class Diagram นี้แสดงโครงสร้างข้อมูลของระบบวิเคราะห์ความเครียด ซึ่งแบ่งข้อมูลออกเป็นห้าส่วนหลัก ได้แก่ **DeviceStatus** (สถานะอุปกรณ์), **PersonalData** (ข้อมูลผู้ใช้), **SensorReading** (ข้อมูลเซนเซอร์ดิบ), **PreprocessedData** (ข้อมูลที่ผ่านการประมวลผล), และ **StressPrediction** (ผลการทำนาย) การจัดระเบียบข้อมูลเป็นคลาสที่ชัดเจนนี้ทำให้ระบบสามารถจัดการข้อมูลที่ซับซ้อนได้อย่างมีประสิทธิภาพ ตั้งแต่การเก็บข้อมูลดิบจากอุปกรณ์ ไปจนถึงการประมวลผลเพื่อทำนายระดับความเครียด และการเชื่อมโยงผลลัพธ์เหล่านั้นกับข้อมูลส่วนตัวของผู้ใช้ได้อย่างเป็นระบบ และแสดงตัวอย่างไฟล์ JSON ดังรูปแบบนี้

1. device_status


```
{
  "_id": {
    "$oid": "68674e6547469cca5c5a15c3"
  },
```

```
  "device_id": "Emotibit-001",
  "status": "active",
  "timestamp": 1751600741,
  "datetime": {
    "$date": "2025-07-04T03:45:41.000Z"
  },
  "created_at": {
    "$date": "2025-07-04T03:45:41.778Z"
  }
}
```


2. personal_data


```
{
  "_id": {
    "$oid": "68999e86928c5153a05fe966"
  },
  "device_id": "MD-V5-0000560",
  "name": "Krittaporn",
  "surname": "Ruknui",
  "age": 21,
  "weight": 60,
  "height": 172,
  "CD": "-",
  "gender": "Female",
  "skinType": "Type 3",
  "timeToSleep": "More than 8 hours",
  "ward": "Ward A",
  "bed": 2,
  "createdAt": {
    "$date": "2025-08-11T07:40:54.276Z"
  },
```

```
  "updatedAt": {
    "$date": "2025-08-11T07:40:54.276Z"
  },
  "__v": 0
}
```


3. preprocessed_data


```
{
  "_id": {
    "$oid": "686750b1c5700307d2caff4a"
  },
  "deviceId": "Emotibit-001",
  "eda_features": {
    "EDA_Raw": 441.93333333333334,
    "EDA_Clean": 442.41060256993256,
    "EDA_Tonic": 558.7514812056362,
    "EDA_Phasic": -241.34361355851215,
    "SCR_Onsets": 0.06666666666666667,
    "SCR_Peaks": 0.06666666666666667,
    "SCR_Height": 3.3957419347602382,
    "SCR_Amplitude": 32.950156469405506,
    "SCR_RiseTime": 0.013333333333333334,
    "SCR_Recovery": 0.06666666666666667,
    "SCR_RecoveryTime": 0.02666666666666667
  },
  "ppg_features": {
    "PPG_Raw": 531.54,
    "PPG_Clean": 30.168062484822123,
    "PPG_Rate": 105.65647751161276,
    "PPG_Quality": 0.6200249825692613,
    "PPG_Peaks": 0.02
```

},
"hrv_indices": {
  "HRV_MeanNN": 588.0392156862745,
  "HRV_SDNN": 190.62321127086966,
  "HRV_SDANN1": 13.962407300506339,
  "HRV_SDNNI1": 190.95475006420156,
  "HRV_SDANN2": null,
  "HRV_SDNNI2": null,
  "HRV_SDANN5": null,
  "HRV_SDNNI5": null,
  "HRV_RMSSD": 275.5355563789846,
  "HRV_SDSD": 275.80648204428627,
  "HRV_CVNN": 0.32416751499881136,
  "HRV_CVSD": 0.4685666347225147,
  "HRV_MedianNN": 550,
  "HRV_MadNN": 192.738,
  "HRV_MCVNN": 0.3504327272727273,
  "HRV_IQRNN": 270,
  "HRV_SDRMSSD": 0.69182799409263,
  "HRV_Prc20NN": 420,
  "HRV_Prc80NN": 752.0000000000005,
  "HRV_pNN50": 86.66666666666667,
  "HRV_pNN20": 94.70588235294117,
  "HRV_MinNN": 310,
  "HRV_MaxNN": 1410,
  "HRV_HTI": 28.333333333333332,
  "HRV_TINN": 218.75,
  "HRV_ULF": null,
  "HRV_VLF": 0.005935618064392741,
  "HRV_LF": 0.04532054778478839,
  "HRV_HF": 0.09454011430680563,

"HRV_VHF": 0.047826210255198634,
"HRV_TP": 0.1936224904111854,
"HRV_LFHF": 0.4793790246298223,
"HRV_LFn": 0.23406654716889366,
"HRV_HFn": 0.48827031460051984,
"HRV_LnHF": -2.3587310445337324,
"HRV_SD1": 195.02463374872056,
"HRV_SD2": 186.37875719515557,
"HRV_SD1SD2": 1.0463887445311806,
"HRV_S": 114192.0199096157,
"HRV_CSI": 0.955667771873861,
"HRV_CVI": 5.764605865094795,
"HRV_CSI_Modified": 712.4646864532547,
"HRV_PIP": 0.6803921568627451,
"HRV_IALS": 0.6824457593688363,
"HRV_PSS": 0.8988439306358381,
"HRV_PAS": 0.25833333333333336,
"HRV_GI": 49.93702770780857,
"HRV_SI": 49.62378101897789,
"HRV_AI": 50.33432502066284,
"HRV_PI": 51.67652859960552,
"HRV_C1d": 0.5328052542232526,
"HRV_C1a": 0.4671947457767473,
"HRV_SD1d": 142.35539700031785,
"HRV_SD1a": 133.30261293077953,
"HRV_C2d": 0.4571642970285405,
"HRV_C2a": 0.5428357029714597,
"HRV_SD2d": 126.01799470987723,
"HRV_SD2a": 137.31899410828822,
"HRV_Cd": 0.4966985875113079,
"HRV_Ca": 0.5033014124886921,

"HRV_SDNNd": 134.435103387874,
"HRV_SDNNa": 135.3257047960315,
"HRV_DFA_alpha1": 0.584633244304655,
"HRV_MFDFA_alpha1_Width": 1.8373793286261995,
"HRV_MFDFA_alpha1_Peak": 0.7716778686912056,
"HRV_MFDFA_alpha1_Mean": 1.0813770486668708,
"HRV_MFDFA_alpha1_Max": -1.4113846191900716,
"HRV_MFDFA_alpha1_Delta": -1.249014681889345,
"HRV_MFDFA_alpha1_Asymmetry": -0.33144515933613666,
"HRV_MFDFA_alpha1_Fluctuation": 0.0003486440892334341,
"HRV_MFDFA_alpha1_Increment": 0.1535520950710742,
"HRV_DFA_alpha2": 0.5101423756443052,
"HRV_MFDFA_alpha2_Width": 0.274215521441044,
"HRV_MFDFA_alpha2_Peak": 0.5129287465590964,
"HRV_MFDFA_alpha2_Mean": 0.6159368365654361,
"HRV_MFDFA_alpha2_Max": 0.2943048458520665,
"HRV_MFDFA_alpha2_Delta": -0.5997402247492496,
"HRV_MFDFA_alpha2_Asymmetry": -0.1243535396354786,
"HRV_MFDFA_alpha2_Fluctuation": 0.000020235253798371972,
"HRV_MFDFA_alpha2_Increment": 0.0032908189290850836,
"HRV_ApEn": 1.3562145024930956,
"HRV_SampEn": 2.1461549501328325,
"HRV_ShanEn": 5.964298396413941,
"HRV_FuzzyEn": 1.6119839356620413,
"HRV_MSEn": 0.9261324027172948,
"HRV_CMSEn": 1.3824188696567985,
"HRV_RCMSEn": 2.1626773634100807,
"HRV_CD": 1.8885272332063427,
"HRV_HFD": 2.002849459512265,
"HRV_KFD": 5.559722460185336,
"HRV_LZC": 1.075795214996844

```
  },
  "timestamp": 1751601329
}
```


4. **sensor_reading**

{"_id": {"$oid": "68674e6547469cca5c5a15c4"}, "topic": "Emotibit/Emotibit-001", "received_at": {"$date": "2025-07-04T03:45:41.779Z"}, "device_id": "Emotibit-001", "timestamp": 1751600741, "sensors": {"skintemp": 36.57, "eda": [511, 398, 913, 756, 785, 26, 895, 831, 297, 384, 801, 460, 172, 379, 533], "ppg": [449, 834, 104, 660, 462, 7, 580, 855, 802, 633, 780, 275, 869, 305, 68, 543, 598, 72, 769, 935, 577, 112, 118, 722, 39, 159, 936, 179, 564, 279, 659, 449, 530, 512, 725, 898, 230, 713, 487, 125, 479, 345, 117, 171, 220, 358, 578, 529, 584, 52, 446, 73, 848, 748, 564, 885, 552, 222, 571, 87, 568, 676, 504, 937, 357, 471, 802, 593, 953, 727, 765, 527, 645, 318, 338, 939, 707, 637, 842, 615, 1020, 618, 442, 227, 730, 543, 331, 550, 887, 624, 983, 704, 956, 868, 581, 322, 1018, 803, 109, 886]}}

5. **stress_predictions**


```
{
  "_id": {
    "$oid": "686750d6c5700307d2caff4f"
  },
  "device_id": "Emotibit-001",
  "result": "High",
  "timestamp": 1751601366
}
```

บทที่ 5
การพัฒนา ติดตั้ง และทดสอบระบบ

ในโครงงานฉบับนี้ ระบบที่ได้รับการพัฒนาประกอบด้วยองค์ประกอบหลัก 3 ส่วนที่ทำงานร่วมกันอย่างสอดคล้อง ได้แก่ อุปกรณ์แบบสวมใส่ (Wearable Device) สำหรับเก็บข้อมูลสัญญาณทางสรีรวิทยา เช่น สัญญาณ Electrodermal Activity (EDA) และ Heart Rate Variability (HRV), โมเดลปัญญาประดิษฐ์สำหรับตรวจจับระดับความเครียด (Stress Detection Model) ที่ทำหน้าที่วิเคราะห์ข้อมูลจากอุปกรณ์เพื่อตรวจจับและประเมินระดับความเครียดของผู้ใช้ และระบบแสดงผลผ่านเว็บแอปพลิเคชัน (Web Application) ที่นำเสนอผลการวิเคราะห์ในรูปแบบที่เข้าถึงง่ายและเข้าใจได้สะดวก

5.1 การพัฒนาอุปกรณ์แบบสวมใส่ (Wearable Device)

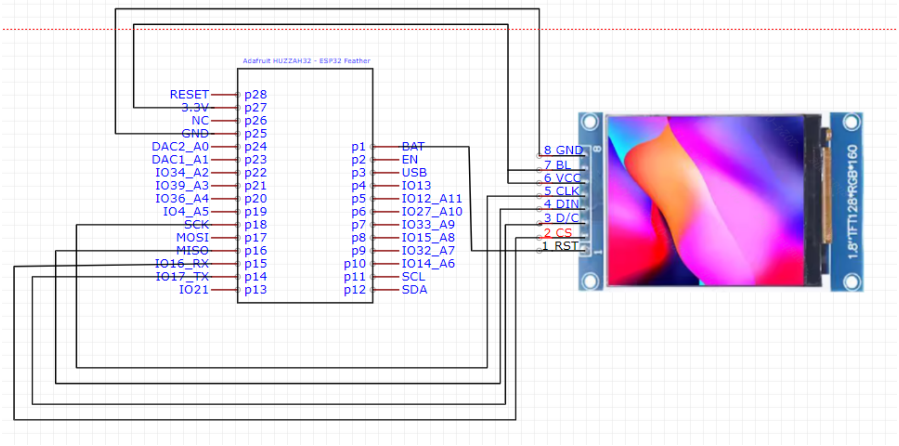
5.1.1 เซนเซอร์ที่ใช้ในการพัฒนาอุปกรณ์แบบสวมใส่

ในโครงการนี้ใช้อุปกรณ์ชุดเซนเซอร์ชื่อ EmotiBit สำหรับวัดสัญญาณกิจกรรมไฟฟ้าที่ผิวหนัง (Electrodermal Activity: EDA), การเปลี่ยนแปลงของปริมาณเลือดหรือการไหลเวียนเลือด (Photoplethysmography: PPG), และอุณหภูมิผิวหนัง (Skin Temperature) มีเซนต์เซอร์ที่ใช้ดังต่อไปนี้

ตาราง 15 คุณลักษณะของ Emotibit

ประเภทของสัญญาณ	Sensor IC	Sampling Rate (samples per second)
PPG	MAX30101	25
EDA	ADS1114	15
Temperature	MAX30101 / MLX90632	7.5

5.1.2 โครงสร้างการเชื่อมต่ออุปกรณ์



ภาพ 10 โครงสร้างการเชื่อมต่อของสายสัญญาณ

จาก**ภาพที่ 10** จะแสดงการเชื่อมต่อของ ไมโครคอนโทรลเลอร์ และ จอแสดงผล LCD ซึ่งเป็นส่วนประกอบสำคัญในระบบของโครงงานนี้

- **ไมโครคอนโทรลเลอร์** ESP 32 Microcontroller ทำหน้าที่เป็นหน่วยประมวลผลหลัก ควบคุมการทำงานของระบบทั้งหมด และส่งข้อมูลภาพไปยังจอแสดงผล
- **จอแสดงผล LCD** คือส่วนทางด้านขวามือ ซึ่งเป็นโมดูลจอแสดงผล ใช้สำหรับแสดงข้อมูล สถานะ หรือผลลัพธ์การทำงานของอุปกรณ์ โดยรับสัญญาณข้อมูลภาพและควบคุมจากไมโครคอนโทรลเลอร์

การเชื่อมต่อระหว่างไมโครคอนโทรลเลอร์และจอแสดงผล LCD เป็นไปตามโปรโตคอลการสื่อสารแบบอนุกรม (Serial Communication) โดยเฉพาะอย่างยิ่ง SPI (Serial Peripheral Interface) ซึ่งเห็นได้จากพินที่เชื่อมต่อกัน ได้แก่

- **MISO (Master In Slave Out)** ใช้สำหรับรับข้อมูลจากจอแสดงผล (ถ้าจอแสดงผลมีข้อมูลส่งกลับ)
- **MOSI (Master Out Slave In)** ใช้สำหรับส่งข้อมูลภาพจากไมโครคอนโทรลเลอร์ไปยังจอแสดงผล
- **SCLK (Serial Clock)** เป็นสัญญาณนาฬิกาสำหรับควบคุมจังหวะการส่งข้อมูล
- **CS (Chip Select)** ใช้เลือกอุปกรณ์ปลายทาง (จอแสดงผล) ในกรณีที่มีอุปกรณ์ SPI หลายตัวเชื่อมต่อในบัสเดียวกัน

- **DC (Data/Command)** ใช้ระบุว่าข้อมูลที่ส่งไปเป็นข้อมูล (Data) หรือคำสั่ง (Command)
- **RESET** ใช้สำหรับรีเซ็ตจอแสดงผล
- **LED/BL (Backlight)** ใช้ควบคุมไฟแบ็คไลท์ของจอแสดงผล
- **VCC/3.3V และ GND** สำหรับจ่ายไฟเลี้ยงและกราวด์ให้กับโมดูลจอแสดงผล

5.1.3 ผลลัพธ์ของของอุปกรณ์

1) การแสดงผลบนจอแสดงผล (Real-time Display Output)

อุปกรณ์มีการติดตั้งจอแสดงผล LCD เพื่อแสดงผลข้อมูลสำคัญที่วัดได้จากเซ็นเซอร์แบบเรียลไทม์ โดยข้อมูลที่แสดงบนจออาจประกอบด้วย

- **วันที่และเวลา** แสดงวันและเวลาปัจจุบัน
- **อุณหภูมิผิวหนัง** แสดงค่าอุณหภูมิของผิวหนังเป็นองศาเซลเซียส (°C)
- **สถานะแบตเตอรี** แสดงระดับพลังงานคงเหลือของอุปกรณ์ เพื่อแจ้งให้ผู้ใช้ทราบถึงความจำเป็นในการชาร์จ
- **อัตราการเต้นของหัวใจ** แสดงค่าอัตราการเต้นของหัวใจ (Heart Rate: HR) เป็นจังหวะการเต้นต่อนาที (BPM)

2) การส่งออกและจัดเก็บข้อมูลในฐานข้อมูล (Data Output to Database)

ข้อมูลที่วัดได้จากเซ็นเซอร์ทั้งหมดจะถูกประมวลผลและส่งออกไปยังฐานข้อมูลภายนอกอย่างต่อเนื่อง เพื่อการจัดเก็บข้อมูลระยะยาวและการวิเคราะห์เพิ่มเติมในภายหลัง การส่งข้อมูลจะอยู่ในรูปแบบ ไฟล์ JSON (JavaScript Object Notation) ซึ่งเป็นรูปแบบข้อมูลที่นิยมใช้ในการแลกเปลี่ยนข้อมูลบนเว็บแอปพลิเคชัน เนื่องจากมีโครงสร้างที่อ่านง่ายและสามารถนำไปประมวลผลต่อได้สะดวก โดยมีรายละเอียดดังนี้

รูปแบบข้อมูล JSON ข้อมูลจากเซ็นเซอร์แต่ละตัวจะถูกจัดเรียงเป็นคู่ของ "key-value" ภายในโครงสร้าง JSON ซึ่งรวมถึง

- **Timestamp** ระบุเวลาที่ข้อมูลถูกบันทึก ซึ่งสำคัญสำหรับการวิเคราะห์ข้อมูลตามช่วงเวลา
- **Raw Sensor Data** ข้อมูลดิบจากเซ็นเซอร์ PPG, EDA, อุณหภูมิ

- **Device Id** หัสประจำตัวของอุปกรณ์ (Unique Identifier) ที่ใช้ในการระบุแหล่งที่มาของข้อมูล ซึ่งสำคัญอย่างยิ่งเมื่อมีการใช้อุปกรณ์หลายตัวพร้อมกัน หรือสำหรับการติดตามข้อมูลจากอุปกรณ์แต่ละเครื่อง

5.2 การพัฒนาโมเดลการตรวจจับระดับความเครียด (Stress Detection Model)

การพัฒนาโมเดลสำหรับตรวจจับระดับความเครียดในโครงงานนี้ ประกอบด้วยการทดลองหลัก 2 ประเภท คือ การประเมินความแม่นยำ (Model Predictive Ability) และการประเมินความเสถียรในการเรียนรู้ของอัลกอริธึม (Model Robustness) ซึ่งการทดลองทั้งสองมีวัตถุประสงค์และกระบวนการดำเนินงานที่แตกต่างกัน เพื่อให้สามารถประเมินและพัฒนาประสิทธิภาพของโมเดลได้อย่างครอบคลุมและแม่นยำ

5.2.1 การทดลองคัดเลือกอัลกอริทึมและการปรับไฮเปอร์พารามิเตอร์

การทดลองนี้มุ่งเน้นไปที่การค้นหาอัลกอริธึมและชุดไฮเปอร์พารามิเตอร์ที่เหมาะสมที่สุดสำหรับการเรียนรู้และจำแนกข้อมูลระดับความเครียด โดยมีการตั้งสมมติฐานว่าอัลกอริธึมและพารามิเตอร์ที่เหมาะสมจะช่วยเพิ่มประสิทธิภาพในการทำนายและลดความผิดพลาดของโมเดล ซึ่งประกอบด้วยขั้นตอนสำคัญดังนี้

1) วัตถุประสงค์ของการทดลอง คือ เพื่อคัดเลือกอัลกอริธึมและพารามิเตอร์ที่เหมาะสมจะช่วยเพิ่มประสิทธิภาพในการทำนายและลดความผิดพลาดของโมเดล ที่เหมาะสมกับการเรียนรู้แพทเทิร์นของข้อมูล
2) ข้อมูลและวิธีการทดลอง
   การทดลองนี้ใช้ข้อมูลตั้งต้นจำนวน 28,285 แถว และ 115 คอลัมน์ ซึ่งผ่านกระบวนการเตรียมข้อมูลอย่างละเอียดเพื่อนำมาใช้ในการสร้างและประเมินโมเดลตรวจจับความเครียด
   2.1) ข้อมูลจำนวน Column (Feature) สำหรับ Train/Test
   หลังจากผ่านกระบวนการเตรียมข้อมูล ซึ่งรวมถึงการสกัดคุณลักษณะ (Feature Extraction) จากสัญญาณชีวภาพ (PPG, EDA) โดยใช้ neurokit2 การรวมเข้ากับคุณลักษณะพื้นฐาน เช่น gender, type, sleep ที่ผ่าน Label Encoding และการ Resampling ข้อมูลให้เป็น 1 Hz แล้ว จำนวนคอลัมน์ (features) ที่จะใช้ในการป้อนเข้าโมเดล (X_train, X_test) จะไม่ใช่ 115 คอลัมน์เดิม แต่จะเป็นจำนวนคุณลักษณะสุดท้ายที่ได้หลังจากการเตรียมข้อมูลทั้งหมด

- สกัดคุณลักษณะเด่นด้วย NeuroKit2 การเตรียมข้อมูลคือการดึงเอา สัญญาณ PPG และ EDA ออกมา ใช้เครื่องมือไลบรารี neurokit2 เข้ามาช่วย โดยมีฟังก์ชันหลักคือ
  1) ppg_process() ทำหน้าที่จัดการกับสัญญาณ PPG (Photoplethysmography) หรือสัญญาณชีพจรที่เราวัดได้จากปลายนิ้วหรือข้อมือ ฟังก์ชันนี้จะช่วยทำความสะอาดสัญญาณ ค้นหาจุดพีคของคลื่นชีพจร และคำนวณคุณลักษณะสำคัญๆ ที่เกี่ยวข้องกับอัตราการเต้นของหัวใจ (Heart Rate) และที่สำคัญคือ ความแปรปรวนของอัตราการเต้นของหัวใจ (Heart Rate Variability - HRV) เช่น ค่า RMSSD, LF/HF ratio ซึ่งเป็นตัวบ่งชี้ความเครียดได้ดี
  2) eda_process() จัดการกับสัญญาณ EDA (Electrodermal Activity) หรือการเปลี่ยนแปลงการนำไฟฟ้าของผิวหนัง ซึ่งตอบสนองต่อสภาวะอารมณ์และความเครียด ฟังก์ชันนี้จะช่วยทำความสะอาดสัญญาณและสกัดคุณลักษณะ เช่น EDA Tonic (ระดับพื้นฐานของการนำไฟฟ้า), จำนวนพีคของ SCR (Skin Conductance Response), หรือแอมพลิจูดเฉลี่ยของพีค
- ข้อมูลพื้นฐาน นอกจากคุณลักษณะที่สกัดจากสัญญาณชีวภาพแล้ว ยังนำข้อมูลพื้นฐานของผู้เข้าร่วมทดลองที่เข้ารหัสเป็นตัวเลขแล้ว (Label Encoded) เข้ามาร่วมด้วย ได้แก่
  - gender (เพศ)
  - type (ประเภทสีผิว)
  - sleep (จำนวนชั่วโมงการนอนในคืนก่อนการทดลอง)
  - bmi (มวลน้ำหนักร่างกาย)
- ปรับความถี่ข้อมูล (Resampling) สัญญาณดิบจากเซ็นเซอร์มักจะมีความถี่สูง เช่น PPG 100 Hz, EDA 15 Hz เพื่อให้ข้อมูลกระชับและง่ายต่อการวิเคราะห์ในระดับวินาที จึงทำการ Resample คุณลักษณะที่สกัดได้ทั้งหมดให้มีอัตราอยู่ที่ 1 Hz หรือ 1 ชุดข้อมูลต่อวินาที โดยใช้วิธีการหาค่าเฉลี่ยของข้อมูลภายในแต่ละวินาที
- จำนวนคุณลักษณะ Features ผลลัพธ์หลังจากการสกัดคุณลักษณะจาก neurokit2 และการรวมคุณลักษณะพื้นฐานก่อนการแยกคอลัมน์ 'id' และ 'stress' สำหรับการสร้างโมเดล

- columns_EDA ชุดคุณลักษณะของ EDA มี 10 รายการได้แก่ EDA_Phasic, SCR_Amplitude, EDA_Tonic, SCR_Onsets, gender, bmi, sleep, type, stress, id
- columns_HRV ชุดคุณลักษณะที่ของ HRV มี 11 รายการได้แก่ HRV_RMSSD, HRV_LFHF, HRV_SDNN, HRV_LF, HRV_HF, gender, bmi, sleep, type, stress, id

เมื่อนำชุดคอลัมน์เหล่านี้มาสร้างเป็นข้อมูลนำเข้า (X) สำหรับโมเดล โดยคอลัมน์ 'stress' จะถูกใช้เป็นตัวแปรตาม (y) และคอลัมน์ 'id' จะถูกใช้สำหรับการจัดกลุ่มข้อมูลหรือแบ่งชุดข้อมูล แต่จะไม่นำมาเป็นคุณลักษณะในการฝึกสอนโดยตรงจะได้จำนวนชุดคุณลักษณะดังนี้

- ชุดคุณลักษณะ EDA สำหรับป้อนเข้าโมเดล จะมีจำนวน 8 คุณลักษณะ
- ชุดคุณลักษณะ HRV สำหรับป้อนเข้าโมเดล จะมีจำนวน 9 คุณลักษณะ

ทั้งนี้ จำนวนคุณลักษณะที่แน่นอนที่ใช้ในการทดลองจริง อาจมีการปรับเปลี่ยนเพิ่มเติมได้ ขึ้นอยู่กับการตัดสินใจในขั้นตอนการคัดเลือกคุณลักษณะ (Feature Selection) สุดท้ายที่คณะผู้วิจัยพิจารณาว่าสำคัญและเหมาะสมที่สุดสำหรับแต่ละชุดข้อมูลและการวิเคราะห์

- โครงสร้างข้อมูลสำหรับ Train/Test เมื่อสร้างลำดับข้อมูล (sequences) ที่มีความยาว 30 วินาที (30 time steps) ชุดข้อมูลนำเข้า X_train และ X_test จะมีรูปร่างเป็น 3 มิติ คือ (จำนวนลำดับ, 30, จำนวน_features_ของชุดนั้นๆ)

2.2) การแบ่งพื้นที่ค้นหา (Search Space) และ Search Algorithm

เพื่อค้นหาชุดไฮเปอร์พารามิเตอร์ (Hyperparameters) ที่ดีที่สุดสำหรับแต่ละสถาปัตยกรรม (RNN, LSTM, GRU) และสำหรับแต่ละชุดคุณลักษณะ (HRV, EDA) ทางคณะผู้วิจัยเลือกใช้เครื่องมือ Keras Tuner

1. **Search Algorithm** (อัลกอริทึมการค้นหา)
    - เราเลือกใช้ Bayesian Optimization อัลกอริทึมนี้ทำงานโดยการสร้างแบบจำลองทางสถิติ (Surrogate Model) เพื่อประมาณความสัมพันธ์ระหว่างชุดไฮเปอร์

พารามิเตอร์กับประสิทธิภาพของโมเดล (วัดจาก val_accuracy) และจากนั้นใช้ Acquisition Function เพื่อตัดสินใจว่าจะทดลองชุดไฮเปอร์พารามิเตอร์ใดต่อไป โดยพยายามสร้างสมดุลระหว่างการสำรวจ (Exploration) ในพื้นที่ใหม่ๆ และการใช้ประโยชน์ (Exploitation) จากพื้นที่ที่เคยให้ผลดีมาแล้ว

- การตั้งค่า Keras Tuner
  - **objective** val_accuracy พยายามทำให้ค่า accuracy บน validation set สูงสุด
  - **max_trials** กำหนดจำนวนครั้งสูงสุดที่จะทดลองชุดไฮเปอร์พารามิเตอร์ เช่น 30-50 trials ต่อการปรับจูนแต่ละชุด
  - **executions_per_trial** จำนวนครั้งที่จะฝึกโมเดลซ้ำสำหรับชุดไฮเปอร์พารามิเตอร์เดียวกัน ปกติคือ 1

2. Search Space (พื้นที่การค้นหาสำหรับไฮเปอร์พารามิเตอร์)

กำหนดขอบเขต (Search Space) ให้ Keras Tuner สำรวจค่าต่างๆ ของไฮเปอร์พารามิเตอร์ที่สำคัญสำหรับโมเดลตระกูล RNN ตามตารางที่ 16

ตาราง 16 Search Space ไฮเปอร์พารามิเตอร์ของแบบจำลองตระกูล Recurrent Neural Network

Algorithm	Parameter	Values / Range
RNN	units	32-256 (step 32)
	dropout	0.05-0.2 (step 0.1)
	num_layers	1-5
	optimizer	adam, sgd
	learning_rate	1e-4 to 1e-2 (log scale)
	batch_size	8-64 (step 8)
	epochs	10-100
	return_sequences	True (hidden layers), False (last layer)

Algorithm	Parameter	Values / Range
	output_activation	softmax
	loss_function	sparse_categorical_crossentropy
	n_splits	5 (K-Fold CV)
	early_stopping_patience	20
LSTM	units	32-256 (step 32)
	dropout	0.05-0.2 (step 0.01)
	num_layers	1-5
	optimizer	adam, sgd
	learning_rate	1e-2, 1e-3, 1e-4
	batch_size	32, 64, 128, 256
	epochs	10-150
	return_sequences	Auto (True for hidden layers, False for last layer)
	output_activation	softmax
	loss_function	categorical_crossentropy
	n_splits	5
	early_stopping_patience	15
GRU	units	32-256 (step 32)
	dropout	0.05-0.2 (step 0.1)
	num_layers	1-5
	optimizer	adam, sgd
	learning_rate	1e-4 to 1e-2 (log scale)
	batch_size	8-64 (step 8)
	epochs	10-100

Algorithm	Parameter	Values / Range
	return_sequences	True (hidden layers), False (last layer)
	output_activation	softmax
	loss_function	sparse_categorical_crossentropy
	n_splits	5 (K-Fold CV)
	early_stopping_patience	20

กระบวนการค้นหาไฮเปอร์พารามิเตอร์เหล่านี้จะดำเนินการแยกกันสำหรับแต่ละสถาปัตยกรรม (RNN, LSTM, GRU) และสำหรับแต่ละชุดคุณลักษณะ (HRV, EDA) เพื่อให้ได้การตั้งค่า (Configuration) ที่ดีที่สุดสำหรับแต่ละเงื่อนไขการทดลอง

3) เกณฑ์ที่ใช้ในการวัดผล (Evaluation Metrics)

ในการประเมินผลการเรียนรู้ของโมเดลสำหรับจำแนกระดับความเครียดในโครงงานนี้ ได้เลือกใช้ตัวชี้วัดหลัก 4 รายการ ได้แก่ Accuracy, Precision, Recall และ F1-score ซึ่งเป็นมาตรวัดที่นิยมใช้ในปัญหาการจำแนกประเภท (Classification) โดยเฉพาะในกรณีที่ข้อมูลมีความไม่สมดุล (Imbalanced Data) ตัวชี้วัดเหล่านี้จะช่วยสะท้อนความสามารถของโมเดลในมิติต่าง ๆ ดังนี้

1. Accuracy (ความแม่นยำโดยรวม)

Accuracy คือสัดส่วนของจำนวนตัวอย่างที่โมเดลสามารถทำนายได้ถูกต้องจากจำนวนตัวอย่างทั้งหมด

สมการ

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

ความหมายของตัวแปร

- TP (True Positive) จำแนกตัวอย่างเป็น "เครียด" ได้ถูกต้อง
- TN (True Negative) จำแนกตัวอย่างเป็น "ไม่เครียด" ได้ถูกต้อง
- FP (False Positive) จำแนกตัวอย่างเป็น "เครียด" ผิดพลาด
- FN (False Negative) จำแนกตัวอย่างเป็น "ไม่เครียด" ผิดพลาด

2. Precision (ความแม่นยำเฉพาะกลุ่มที่โมเดลทำนายว่า "เครียด")

Precision คือวัดความถูกต้องของการทำนายคลาสบวก (เช่น เครียด) ว่าตัวอย่างที่โมเดลทำนายว่าเป็น "เครียด" นั้น จริง ๆ แล้วเป็นเครียดมากน้อยเพียงใด

สมการ

$$Precision = \frac{TP}{TP + FP}$$

ความสำคัญ

- Precision สูง หมายถึง โมเดลไม่ทำนาย "เครียด" แบบผิด ๆ มาก
- เหมาะกับกรณีที่ ผลกระทบจากการทำนายผิดเป็นบวก มีความสำคัญ เช่น ไม่ควรแจ้งเตือนผู้ใช้ว่าเครียด ถ้าจริง ๆ แล้วไม่ใช่

3. Recall (ความครอบคลุมของการตรวจจับ "เครียด")

Recall คือวัดความสามารถของโมเดลในการค้นหาตัวอย่างที่เป็น "เครียด" ทั้งหมดจากในข้อมูลจริง

สมการ

$$Recall = \frac{TP}{TP + FN}$$

ความสำคัญ

- Recall สูง หมายถึง โมเดลสามารถดึงตัวอย่าง "เครียด" ออกมาได้ครบถ้วน
- เหมาะกับกรณีที่ การพลาดไม่แจ้งเตือนเมื่อผู้ใช้เครียด เป็นสิ่งที่ต้องหลีกเลี่ยง เช่น ในระบบเฝ้าระวังภาวะทางจิตใจ

4. F1-score (ค่าเฉลี่ยฮาร์มอนิกของ Precision และ Recall)

F1-score คือค่าที่รวมทั้ง Precision และ Recall เข้าไว้ด้วยกัน เพื่อสะท้อนความสมดุลระหว่างความแม่นยำและความครอบคลุม

สมการ

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

ความสำคัญ

- F1-score เป็นตัวชี้วัดที่เหมาะสมในกรณีที่ต้องการสมดุลระหว่าง Precision และ Recall โดยเฉพาะในข้อมูลที่ไม่สมดุล
- ค่า F1-score ใกล้ 1 หมายถึงโมเดลมีทั้งความแม่นยำและความครอบคลุมสูง

4) ผลลัพธ์

ตาราง 17 ประสิทธิภาพการทดลองจากแบบจำลอง Recurrent Neural Network ของ EDA

Hyperparameter							Accuracy (%)	Precision (%)	Recall (%)	F1 Score (%)
Neural Unit No	dropout	Hidden Layer No	optimizer	Learning rate	Batch size	epochs				
96	0.05	2	adam	0.0003	56	65	93.14	93.44	93.11	93.15
128	0.05	4	adam	0.0001	64	83	92.85	93.21	92.82	92.86
128	0.05	2	adam	0.0005	64	100	92.83	93.20	92.79	92.84
128	0.15	3	adam	0.0008	56	57	92.65	93.23	92.61	92.69
128	0.05	1	sgd	0.01	8	100	92.61	92.80	92.58	92.61

ตาราง 18 ประสิทธิภาพการทดลองจากแบบจำลอง Recurrent Neural Network ของ HRV

Hyperparameter							Accuracy (%)	Precision (%)	Recall (%)	F1 Score (%)
Neural Unit No	dropout	Hidden Layer No	optimizer	Learning rate	Batch size	epochs				
128	0.05	5	adam	0.0001	64	100	99.50	99.50	99.50	99.50

Hyperparameter							Accuracy (%)	Precision (%)	Recall (%)	F1 Score (%)
Neural Unit No	dropout	Hidden Layer No	optimizer	Learning rate	Batch size	epochs				
128	0.05	3	adam	0.0001	48	62	99.48	99.48	99.48	99.48
128	0.05	3	adam	0.0001	64	100	99.46	99.46	99.46	99.46
128	0.05	3	sgd	0.0024	8	59	99.43	99.43	99.43	99.43
96	0.05	4	sgd	0.0025	8	100	99.37	99.37	99.36	99.37

ตาราง 19 ประสิทธิภาพการทดลองจากแบบจำลอง Recurrent Neural Network ของ EDA และ HRV

Hyperparameter							Accuracy (%)	Precision (%)	Recall (%)	F1 Score (%)
Neural Unit No	dropout	Hidden Layer No	optimizer	Learning rate	Batch size	epochs				
224	0.15	2	adam	0.00017	56	57	99.40	99.40	99.40	99.40
256	0.05	2	adam	0.00010	8	100	99.30	99.30	99.30	99.30
256	0.15	3	sgd	0.01000	64	65	99.20	99.30	99.30	99.30
128	0.05	3	sgd	0.00400	8	45	99.20	99.20	99.20	99.20
256	0.05	5	sgd	0.01000	8	67	99.20	99.20	99.20	99.20

จากผลการทดลองแบบจำลอง Recurrent Neural Network (RNN) ที่แสดงในตารางที่ 17 และ 18 ทั้งข้อมูลสรีรวิทยาประเภท EDA (การนำไฟฟ้าของผิวหนัง) และ HRV (ความแปรปรวนของอัตราการเต้นหัวใจ) พบว่าแบบจำลองสามารถจำแนกข้อมูลออกเป็นกลุ่มได้อย่างมีประสิทธิภาพ โดยข้อมูล EDA มีค่า Accuracy และ F1-Score อยู่ในช่วงประมาณ 92-93% ส่วนข้อมูล HRV แสดงประสิทธิภาพที่โดดเด่นกว่า โดยมีค่า Accuracy และ F1-Score สูงถึง 99% อย่างไรก็ตาม ผลลัพธ์ที่สูงมากของ HRV อาจเป็นสัญญาณของปัญหา Overfitting ซึ่งหมายความว่าแบบจำลองอาจเรียนรู้ข้อมูลฝึกฝนได้ดีเกินไปจนไม่สามารถนำไปใช้กับข้อมูลใหม่ได้อย่างมีประสิทธิภาพ ความแตกต่างของประสิทธิภาพในแต่ละชุดข้อมูลอาจเกิดจากลักษณะเฉพาะของข้อมูลและการตั้งค่าพารามิเตอร์ต่างๆ เช่น จำนวนหน่วยประสาท จำนวนชั้นของโครงข่าย อัตราการลดทอน (dropout) และตัวปรับค่าเวต (optimizer) ที่มีผลต่อการเรียนรู้ของแบบจำลอง โดยรวมแสดงให้เห็นว่า RNN เป็นโครงข่ายประสาทเทียมที่มีศักยภาพสูงและสามารถนำไปประยุกต์ใช้กับข้อมูลสรีรวิทยาเพื่อตรวจจับสภาวะต่างๆ ได้อย่างมีประสิทธิภาพ แต่จำเป็นต้องมีการตรวจสอบและแก้ไขปัญหา Overfitting อย่างระมัดระวัง เพื่อให้โมเดลสามารถทำงานได้ดีกับข้อมูลใหม่ที่ไม่เคยเห็นมาก่อน

ตาราง 20 ประสิทธิภาพการทดลองจากแบบจำลอง Long Short-Term Memory ของ EDA

Hyperparameter							Accuracy (%)	Precision (%)	Recall (%)	F1 Score (%)
Neural Unit No	dropout	Hidden Layer No	optimizer	Learning rate	Batch size	epochs				
256	0.20	2	adam	0.001	64	50	94.98	95.00	95.00	95.01
224	0.03	2	adam	0.001	32	100	94.90	99.00	99.00	94.42
256	0.055	2	adam	0.001	64	30	94.65	94.00	93.00	93.31
160	0.05	1	adam	0.01	64	50	92.25	93.00	92.00	92.44
96	0.005	2	adam	0.001	64	50	91.81	93.00	92.00	92.05

ตาราง 21 ประสิทธิภาพการทดลองจากแบบจำลอง Long Short-Term Memory ของ HRV

Hyperparameter							Accuracy (%)	Precision (%)	Recall (%)	F1 Score (%)
Neural Unit No	dropout	Hidden Layer No	optimizer	Learning rate	Batch size	epochs				
32	0.005	3	adam	0.001	256	100	92.55	93.00	93.00	92.59
192	0.15	4	adam	0.001	256	90	90.83	91.00	90.00	91.02
96	0.2	1	adam	0.001	128	130	89.69	92.00	90.00	90.10
32	0.1	5	adam	0.001	64	100	91.99	92.00	92.00	92.17
128	0.2	2	adam	0.001	32	10	89.12	90.00	89.00	89.46

ตาราง 22 ประสิทธิภาพการทดลองจากแบบจำลอง Long Short-Term Memory ของ EDA และ HRV

Hyperparameter							Accuracy (%)	Precision (%)	Recall (%)	F1 Score (%)
Neural Unit No	dropout	Hidden Layer No	optimizer	Learning rate	Batch size	epochs				
64	0.05	4	adam	0.001	32	70	99.42	97.00	97.00	97.27
32	0.05	5	adam	0.0001	32	110	99.52	95.00	95.00	94.91
192	0.15	3	adam	0.001	64	90	43.67	94.00	93.00	93.26
128	0.05	4	adam	0.001	128	120	99.81	99.00	99.00	99.10
160	0.05	4	adam	0.001	256	110	44.2	98.00	98.00	98.40

จากผลการทดลองแบบจำลอง Long Short-Term Memory (LSTM) ตาราง 20 และ 21 ทั้งข้อมูลสรีรวิทยาประเภท EDA และ HRV พบว่าผลการทดลอง LSTM เป็นทางเลือกที่เหมาะสม

และมีประสิทธิภาพสำหรับการวิเคราะห์สัญญาณทางสรีรวิทยาทั้งสองประเภท เนื่องจากทั้ง EDA และ HRV ต่างมีลักษณะของข้อมูลที่มีความสัมพันธ์ทางเวลาและมีความต่อเนื่องสองค่านี้สะท้อนให้เห็นความเหมาะสมของ LSTM ในการจัดการกับข้อมูลที่มีลักษณะเป็นอนุกรมเวลา (Time series) ซึ่งเป็นการจัดเก็บข้อมูลตามลำดับเวลาอย่างต่อเนื่อง จากตารางที่ 20 ในส่วนของ EDA เป็นสัญญาณที่มีลักษณะการเปลี่ยนแปลงแบบค่อยเป็นค่อยไป (gradual changes) และมีความต่อเนื่องทางเวลา LSTM ที่ออกแบบมาเพื่อจดจำรูปแบบระยะยาวจึงสามารถจับการเปลี่ยนแปลงของการนำไฟฟ้าผิวหนังที่เกิดจากการตอบสนองทางอารมณ์ได้อย่างมีประสิทธิภาพ ความแม่นยำที่สูงถึง 94.98% สะท้อนให้เห็นว่า LSTM สามารถเรียนรู้รูปแบบการตอบสนองทางสรีรวิทยาที่ซับซ้อนและมีความหน่วงเวลา (temporal lag) ได้ดี การที่ใช้ Neural units จำนวน 256 units และ Dropout rate สูง 0.20 บ่งชี้ว่าข้อมุล EDA มีความซับซ้อนและต้องการความสามารถในการจำสูงของแบบจำลอง และตารางที่ 21 ในส่วนของ HRV ซึ่งเป็นการวัดความแปรปรวนของช่วงเวลาระหว่างการเต้นของหัวใจมีลักษณะเป็นสัญญาณที่มีการเปลี่ยนแปลงแบบไม่เชิงเส้นและมีความซับซ้อนน้อยกว่า จึงทำงานได้ดีกับโครงข่ายที่เรียบง่ายกว่า 32 units และ Dropout rate ต่ำมาก 0.005 และใช้การเรียนรู้มากกว่า 100 epochs ซึ่งให้ความแม่นยำ 92.55% และ F1 Score 92.59% อย่างไรก็ตามการที่ต้องใช้จำนวน Epochs มากกว่า 100 epochs บ่งชี้ว่าการเรียนรู้ของ HRV ต้องการเวลาในการเรียนรู้มากเนื่องจากสัญญาณมีความละเอียดมากว่า และความแปรปรวนที่ต้องการปรับแต่งอย่างค่อยเป็นค่อยไปซึ่งต่างจากสัญญาณ EDA และจากผลทดสอบทั้งสองตารางจะเห็นได้ชัดเลยว่าค่าที่ดีที่สุดจะเป็นการปรับค่าเวต (Optimizer) เป็น Adam แสดงให้เห็นว่า optimizer นี้ให้ผลลัพธ์ที่ดีที่สุดในทุกการทดลอง ซึ่งสอดคล้องกับลักษณะของ LSTM และข้อมูลสัญญาณทางสรีระวิทยาที่เหมาะสม ได้แก่ การปรับ Learning rate แบบอัตโนมัติ (adaptive learning rate) ที่ช่วยให้การเรียนรู้มีประสิทธิภาพมากขึ้น โดยเฉพาะกับพารามิเตอร์ที่มีความไวต่างกัน เช่น Weight และ Bias ของ Gate ต่างๆ ใน LSTM นอกจากนี้ Adam ยังมีกลไก Momentum ที่ช่วยให้การอัปเดต Weight มีความเสถียรและสามารถผ่านจุด Local minima ได้ดีกว่า ซึ่งเป็นปัญหาที่มักพบในการฝึกสอนโครงข่ายประสาท Deep Learning การที่ Adam ใช้ทั้ง First moment (mean) และ Second moment (variance) ของ Gradient ทำให้สามารถจัดการกับ Gradient ที่มีความแปรปรวนสูงได้ดี ซึ่งเหมาะสมกับลักษณะของข้อมูลสัญญาณทางสรีรวิทยาที่มักมี Noise และความไม่แน่นอน โดยจากผลทดลองจึงสรุปผลได้ว่า LSTM มีประสิทธิภาพสูงสำหรับการประยุกต์ใช้งานและเป็นหนึ่งในทางเลือกที่เหมาะสมสำหรับการวิเคราะห์สัญญาณทางสรีรวิทยาทั้งสองประเภท ซึ่งตรงความสามารถของ LSTM ที่สามารถจดจำข้อมูลในอดีตและใช้การทำนายอนาคต สะท้อนให้เห็นว่าทั้งสองสัญญาณมีความยืดหยุ่น (flexibility) ของ LSTM ที่สามารถปรับตัวให้เข้ากับลักษณะของข้อมูลนั้นที่แตกต่างกันได้

ตาราง 23 ประสิทธิภาพการทดลองจากแบบจำลอง Gated Recurrent Unit ของ EDA

Hyperparameter							Accuracy (%)	Precision (%)	Recall (%)	F1 Score (%)
Neural Unit No	dropout	Hidden Layer No	optimizer	Learning rate	Batch size	epochs				
256	0.05	1	adam	0.000139	56	57	93.45	93.64	93.45	93.45
32	0.05	1	adam	0.0011	24	60	93.07	93.30	93.07	93.09
160	0.15	3	sgd	0.002876	8	73	92.84	93.01	92.84	92.85
224	0.15	1	adam	0.000708	16	80	92.83	93.18	92.83	92.85
160	0.15	4	adam	0.00033	16	100	92.73	93.12	92.73	92.75

ตาราง 24 ประสิทธิภาพการทดลองจากแบบจำลอง Gated Recurrent Unit ของ HRV

Hyperparameter							Accuracy (%)	Precision (%)	Recall (%)	F1 Score (%)
Neural Unit No	dropout	Hidden Layer No	optimizer	Learning rate	Batch size	epochs				
96	0.15	2	adam	0.000379	24	77	99.25	99.25	99.25	99.25
32	0.05	1	adam	0.000762	48	89	99.23	99.23	99.23	99.23
32	0.05	1	adam	0.000956	40	43	99.20	99.21	99.20	99.20

Hyperparameter							Accuracy (%)	Precision (%)	Recall (%)	F1 Score (%)
Neural Unit No	dropout	Hidden Layer No	optimizer	Learning rate	Batch size	epochs				
192	0.05	1	adam	0.000532	48	90	99.11	99.12	99.11	99.11
128	0.05	1	adam	0.001784	48	38	99.10	99.10	99.10	99.10

ตาราง 25 ประสิทธิภาพการทดลองจากแบบจำลอง Gated Recurrent Unit ของ EDA และ HRV

Hyperparameter							Accuracy (%)	Precision (%)	Recall (%)	F1 Score (%)
Neural Unit No	dropout	Hidden Layer No	optimizer	Learning rate	Batch size	epochs				
192	0.15	3	adam	0.000451	64	37	99.42	99.42	99.42	99.42
96	0.05	2	adam	0.000132	16	67	99.34	99.35	99.34	99.34
160	0.05	3	adam	0.00035	24	97	99.34	99.35	99.34	99.34
160	0.05	2	adam	0.000266	64	61	99.32	99.32	99.32	99.32
160	0.15	3	adam	0.00014	64	57	99.28	99.28	99.28	99.28

จากผลการทดลองแบบจำลอง Gated Recurrent Unit (GRU) ตารางที่ 23-25 พบว่าแบบจำลองที่ใช้สัญญาณ EDA ซึ่งพบว่าการกำหนดค่าไฮเปอร์พารามิเตอร์ที่แตกต่างกันส่งผลต่อ

ประสิทธิภาพของแบบจำลอง โดยค่า accuracy, precision, recall, และ F1-score อยู่ในช่วงประมาณ 92% ถึง 93% แบบจำลองที่ใช้สัญญาณ HRV ซึ่งผลลัพธ์ที่ได้มีประสิทธิภาพดีขึ้นเล็กน้อย โดยค่า accuracy, precision, recall, และ F1-score อยู่ในช่วงประมาณ 94% ถึง 97% แบบจำลองที่ใช้ทั้งสัญญาณ EDA และ HRV ร่วมกัน ซึ่งแสดงให้เห็นถึงประสิทธิภาพของแบบจำลองที่สูงขึ้นอย่างเห็นได้ชัดเจน โดยค่า accuracy, precision, recall, และ F1-score อยู่ในระดับที่สูงมาก โดยส่วนใหญ่อยู่ที่ 99.3% ขึ้นไป ซึ่งแสดงให้เห็นว่าการใช้ข้อมูลทั้งสองส่วนช่วยเพิ่มความแม่นยำในการจำแนกได้เป็นอย่างดีที่สุด

5.2.2 การทดลองความเสถียรของโมเดล

การประเมินความเสถียรของโมเดล (Model Stability) เพื่อวัดระดับความคงที่ของประสิทธิภาพเมื่อโมเดลถูกนำไปใช้งานในสภาวะที่เปลี่ยนแปลงไป อาทิ การเปลี่ยนแปลงสัดส่วนของข้อมูลฝึกสอนและทดสอบ หรือการสุ่มแบ่งข้อมูลที่แตกต่างกันในการเทรนแต่ละครั้ง

1) วัตถุประสงค์ของการทดลอง คือ เพื่อพิสูจน์ความเสถียรของโมเดลภายใต้เงื่อนไขที่เปลี่ยนแปลง ทั้งในแง่ของชุดข้อมูลและการฝึกสอนที่แตกต่างกัน โดยเฉพาะในกรณีที่ระบบจะถูกนำไปใช้งานจริง ซึ่งอาจพบกับข้อมูลใหม่หรือข้อมูลที่มีโครงสร้างต่างจากชุดฝึกสอนในเบื้องต้น
2) ข้อมูลและวิธีการทดลอง

   1. การแบ่งข้อมูลในสัดส่วนที่แตกต่างกัน

      ในการประเมินความสามารถของโมเดลภายใต้ข้อจำกัดด้านปริมาณข้อมูล การแบ่งข้อมูลออกเป็นชุดฝึกสอน (Training Set) และชุดทดสอบ (Test Set) ในสัดส่วนที่หลากหลายจึงมีความสำคัญ เพื่อวัดผลกระทบของสัดส่วนข้อมูลต่อประสิทธิภาพของโมเดล โดยในโครงงานนี้ได้กำหนดสัดส่วนการแบ่งข้อมูลไว้ 4 รูปแบบ ได้แก่ 80:20, 70:30, 60:40 และ 50:50 การทดสอบภายใต้สัดส่วนที่หลากหลายเช่นนี้จะช่วยให้เข้าใจถึงขอบเขตและข้อจำกัดของโมเดล และสามารถวางแผนการใช้งานจริงได้อย่างเหมาะสม

   2. การเทรนโมเดลซ้ำหลายรอบ (Repeated Trials)

      เพื่อให้การประเมินผลลัพธ์มีความน่าเชื่อถือและเป็นกลางมากยิ่งขึ้น ได้มีการกำหนดให้ดำเนินการฝึกสอนและทดสอบโมเดลในแต่ละสัดส่วนจำนวน 10 รอบ โดยในแต่ละรอบจะมีการสุ่มแบ่งข้อมูลฝึกสอนและทดสอบใหม่ทั้งหมด ซึ่งวิธีการนี้เรียกว่า Repeated Hold-out Validation ซึ่งเป็นเทคนิคที่ได้รับการยอมรับในงานวิจัยด้านการ

เรียนรู้ของเครื่อง (Machine Learning) ว่าเป็นวิธีที่สามารถลดอคติจากการสุ่มชุดข้อมูลเพียงครั้งเดียวได้อย่างมีประสิทธิภาพ

3) เกณฑ์ที่ใช้ในการวัดผล (Evaluation Metrics)

การเปรียบเทียบค่าประสิทธิภาพของโมเดลในแต่ละรอบ ทั้งในแง่ของค่าเฉลี่ย (Mean) และส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation) ของตัวชี้วัดประสิทธิภาพ เช่น Accuracy, Precision, Recall และ F1-score ซึ่งจะเป็นข้อมูลสำคัญในการประเมินว่าโมเดลมีความเสถียรและเชื่อถือได้หรือไม่

1. ค่าเฉลี่ย (Mean)

ค่าเฉลี่ยเป็นตัวแทนของผลการทำงานของโมเดลในภาพรวม โดยคำนวณจากผลลัพธ์ของแต่ละรอบทดลอง เช่น ความแม่นยำในแต่ละรอบ แล้วนำมาหาค่าเฉลี่ยเพื่อดูแนวโน้มของประสิทธิภาพของโมเดลภายใต้เงื่อนไขที่กำหนด หากค่าเฉลี่ยของตัวชี้วัดสูง แสดงว่าโมเดลสามารถเรียนรู้และทำนายได้อย่างมีประสิทธิภาพในภาพรวม

สมการ ในการคำนวณค่าเฉลี่ยของตัวชี้วัด เช่น Accuracy

$$\mu = \frac{1}{n}\sum_{i=1}^{n} x_i$$

ความหมายของตัวแปร

- μ คือค่าเฉลี่ย (Mean)
- X_i คือค่าความแม่นยำ (หรือค่าตัวชี้วัดอื่น) ในรอบที่ i
- n คือจำนวนรอบของการทดลอง

2. ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation)

ส่วนเบี่ยงเบนมาตรฐานเป็นค่าที่บ่งชี้ถึงความแปรปรวนของผลการทดลอง หากค่าดังกล่าวมีค่าต่ำ แสดงว่าผลลัพธ์ในแต่ละรอบมีความใกล้เคียงกัน ซึ่งสะท้อนถึงความเสถียรและความคงที่ของโมเดล แต่หากมีค่าสูง แสดงว่าโมเดลอาจมีพฤติกรรมที่ไม่

คงที่เมื่อเผชิญกับข้อมูลชุดที่แตกต่างกัน โดยเฉพาะในกรณีที่ข้อมูลฝึกสอนมีความแตกต่างจากกันในแต่ละรอบ

สมการ ในการคำนวณส่วนเบี่ยงเบนมาตรฐาน

$$\sigma = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^2}$$

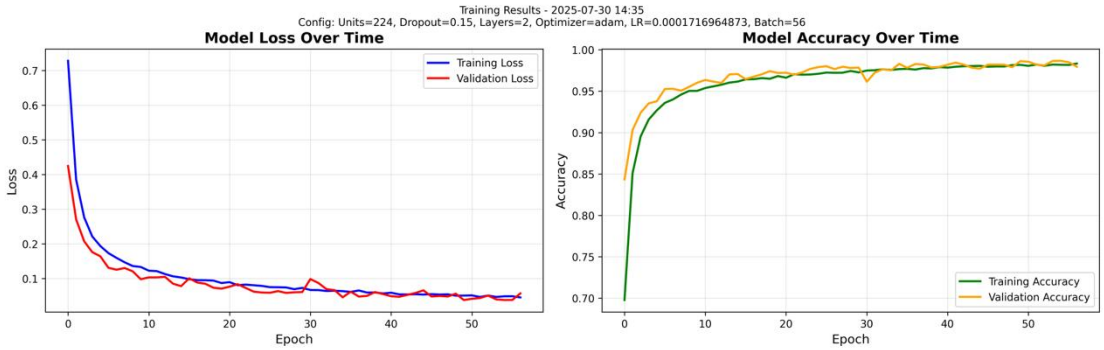
ความหมายของตัวแปร

- σ คือส่วนเบี่ยงเบนมาตรฐาน
- X_i คือค่าความแม่นยำ ในรอบที่ i
- μ คือค่าเฉลี่ยของผลลัพธ์ทั้งหมด
- n คือจำนวนรอบของการทดลอง

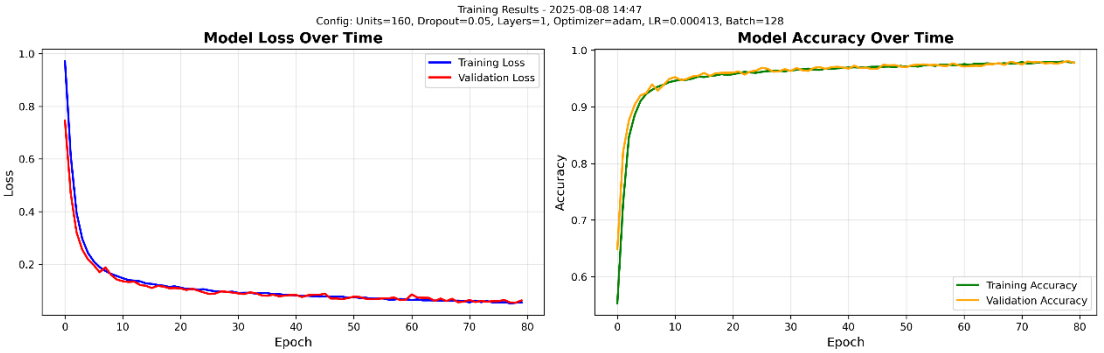
4) ผลลัพธ์

ผลการทดลองด้วยอัลกอริทึม Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM) และ Gated Recurrent Unit (GRU) ใช้ค่า F1 Score เป็นตัวชี้วัดหลักในการประเมินผล ซึ่งเหมาะสมกับปัญหาการจำแนกหลายคลาส เนื่องจากให้ผลลัพธ์ที่สมดุลระหว่าง Precision และ Recall จากการเปรียบเทียบพบว่าโมเดล GRU มีค่า F1 Score สูงที่สุดเมื่อใช้คุณลักษณะจากสัญญาณ EDA และ HRV ร่วมกัน สะท้อนถึงประสิทธิภาพในการจำแนกข้อมูลได้ดีกว่าอัลกอริทึมอื่น

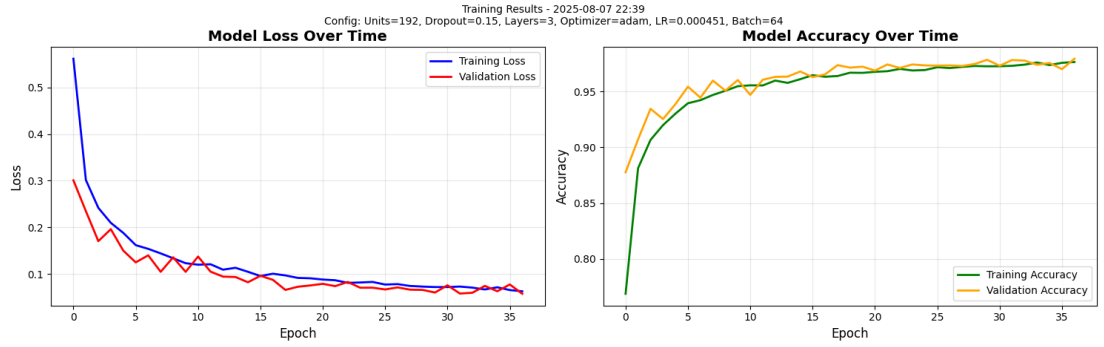
นอกจากนี้ ยังได้พิจารณาผลการฝึกโมเดลในด้านค่าความสูญเสีย (Loss) และความแม่นยำ (Accuracy) ของชุดข้อมูลฝึกและทดสอบตลอดกระบวนการฝึก แสดงใน**ภาพที่ 16–18** ซึ่งแสดงให้เห็นว่า GRU มีความเสถียรในการเรียนรู้ ค่าความแม่นยำสูง และค่า Loss ลดลงอย่างต่อเนื่องโดยไม่มีสัญญาณของ Overfitting เมื่อเปรียบเทียบกับ RNN และ LSTM ที่มีความผันผวนมากกว่า ส่งผลให้ GRU เป็นแบบจำลองที่มีประสิทธิภาพสูงสุดในการศึกษานี้ รายละเอียดผลการประเมินสรุปไว้ใน**ตารางที่ 26**



ภาพ 11 ผลการฝึกโมเดลในด้านค่าความสูญเสีย (Loss) และความแม่นยำ (Accuracy) ของชุดข้อมูลฝึกและทดสอบ แบบจำลอง RNN



ภาพ 12 ผลการฝึกโมเดลในด้านค่าความสูญเสีย (Loss) และความแม่นยำ (Accuracy) ของชุดข้อมูลฝึกและทดสอบ แบบจำลอง LSTM



ภาพ 13 ผลการฝึกโมเดลในด้านค่าความสูญเสีย (Loss) และความแม่นยำ (Accuracy) ของชุดข้อมูลฝึกและทดสอบ แบบจำลอง GRU

ตาราง 26 ตารางเปรียบเทียบประสิทธิภาพของโมเดลทั้ง 3 โมเดล

Model	Feature	Model Evaluation			
		Precision	Recall	F1-score	Accuracy
Recurrent Neural Network (RNN)	EDA	93.44	93.11	93.15	93.14
	HRV	99.50	99.50	99.50	99.50
	EDA + HRV	99.40	99.40	99.40	99.40
Long Short-Term Memory (LSTM)	EDA	95.00	95.00	95.01	94.98
	HRV	93.00	93.00	92.59	92.55
	EDA + HRV	97.00	97.00	97.27	97.24
Gated Recurrent Unit (GRU)	EDA	89.49	96.34	92.91	92.89
	HRV	95.73	98.54	97.14	97.15
	EDA + HRV	99.42	99.42	99.42	99.42

การศึกษานี้ได้ทำการเปรียบเทียบประสิทธิภาพของแบบจำลองการเรียนรู้เชิงลำดับสามประเภท ได้แก่ RNN, LSTM และ GRU โดยใช้ข้อมูลคุณสมบัติทางสรีรวิทยาสองประเภท คือ EDA และ HRV รวมทั้งการผสมผสานข้อมูลทั้งสองชนิด เพื่อวิเคราะห์ความสามารถในการจำแนกระดับความเครียด

ผลการทดลองพบว่า แบบจำลอง RNN มีประสิทธิภาพที่ดีเมื่อใช้ข้อมูล EDA เพียงอย่างเดียว โดยค่าเมตริก Precision, Recall, F1-score และ Accuracy อยู่ในช่วง 93.1-93.4% อย่างไรก็ตาม เมื่อใช้ข้อมูล HRV เพียงอย่างเดียว ประสิทธิภาพเพิ่มขึ้นอย่างมีนัยสำคัญ โดยค่าเมตริกทั้งหมดสูงถึง 99.5% และเมื่อรวมข้อมูล EDA กับ HRV เข้าด้วยกัน ประสิทธิภาพยังคงอยู่ในระดับสูงที่ 99.4% แสดงให้เห็นว่าการผสมผสานข้อมูลหลายแหล่งช่วยเสริมความแม่นยำของโมเดลได้อย่างมีประสิทธิผล

สำหรับแบบจำลอง LSTM เมื่อใช้ข้อมูล EDA เพียงอย่างเดียว พบว่ามีประสิทธิภาพในระดับดี โดยค่าเมตริกอยู่ที่ประมาณ 95% ในขณะที่การใช้ข้อมูล HRV เพียงอย่างเดียว ประสิทธิภาพลดลงเล็กน้อย อยู่ที่ประมาณ 92.6% อย่างไรก็ตาม การรวมข้อมูลทั้งสองชนิดช่วยให้ LSTM สามารถฟื้นฟูประสิทธิภาพขึ้นมาอยู่ในช่วง 97.0-97.3% ซึ่งสะท้อนถึงความสามารถของ LSTM ในการจับความสัมพันธ์ที่ซับซ้อนของข้อมูลหลายมิติ

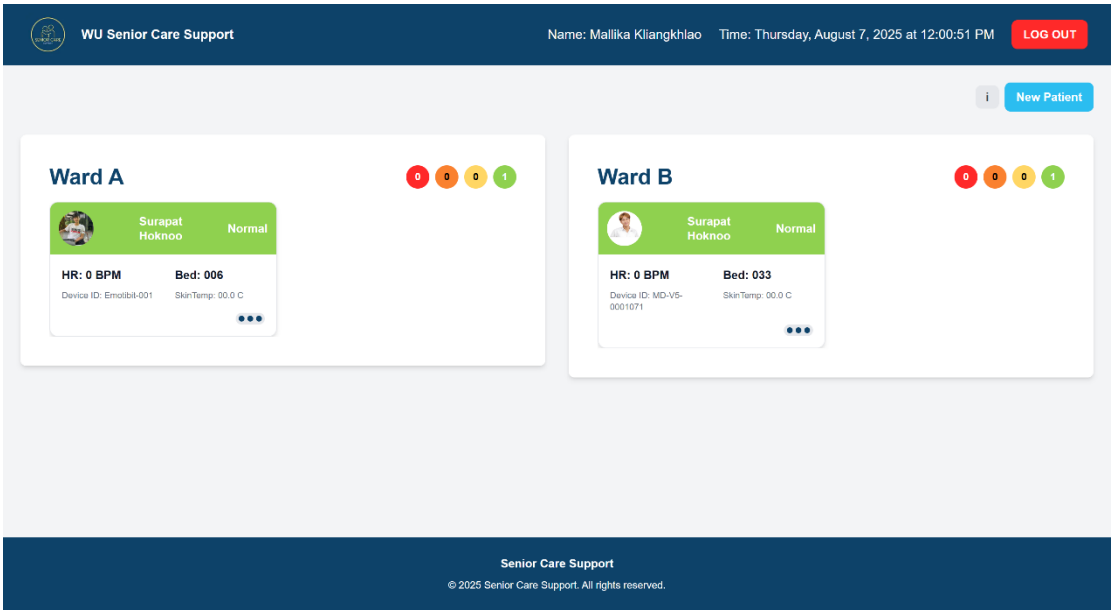
แบบจำลอง GRU มีผลการทำงานที่น่าสนใจ เมื่อใช้ข้อมูล EDA เพียงอย่างเดียว ค่า Recall สูงถึง 96.34% แต่ค่า Precision อยู่ที่ 89.49% ซึ่งบ่งชี้ถึงความสามารถในการตรวจจับคลาสเป้าหมายได้ดีแม้จะมีข้อผิดพลาดบางส่วน เมื่อใช้ข้อมูล HRV เพียงอย่างเดียว GRU ทำงานได้ดีขึ้น โดยค่าเมตริกต่าง ๆ อยู่ในช่วง 95.73-98.54% และเมื่อรวมข้อมูล EDA กับ HRV เข้าด้วยกัน GRU

แสดงประสิทธิภาพที่ยอดเยี่ยม โดยค่าเมตริกทั้งหมดเกือบถึง 99.42% ซึ่งใกล้เคียงกับผลลัพธ์ของ RNN ในการใช้ข้อมูลชุดเดียวกัน

โดยสรุป การใช้ข้อมูลผสมผสานระหว่าง EDA และ HRV มีผลอย่างชัดเจนต่อการเพิ่มประสิทธิภาพของแบบจำลองทั้งสามชนิด โดย GRU แสดงศักยภาพที่โดดเด่นที่สุดในการจำแนกระดับความเครียดตามด้วย RNN และ LSTM ตามลำดับ ผลการศึกษานี้ชี้ให้เห็นว่าการเลือกแบบจำลองควรพิจารณาลักษณะข้อมูลและบริบทการใช้งาน เพื่อให้เหมาะสมกับการประยุกต์ใช้จริงในอนาคต

5.3 การพัฒนาระบบแสดงผลผ่านเว็บแอปพลิเคชัน (Web Application)

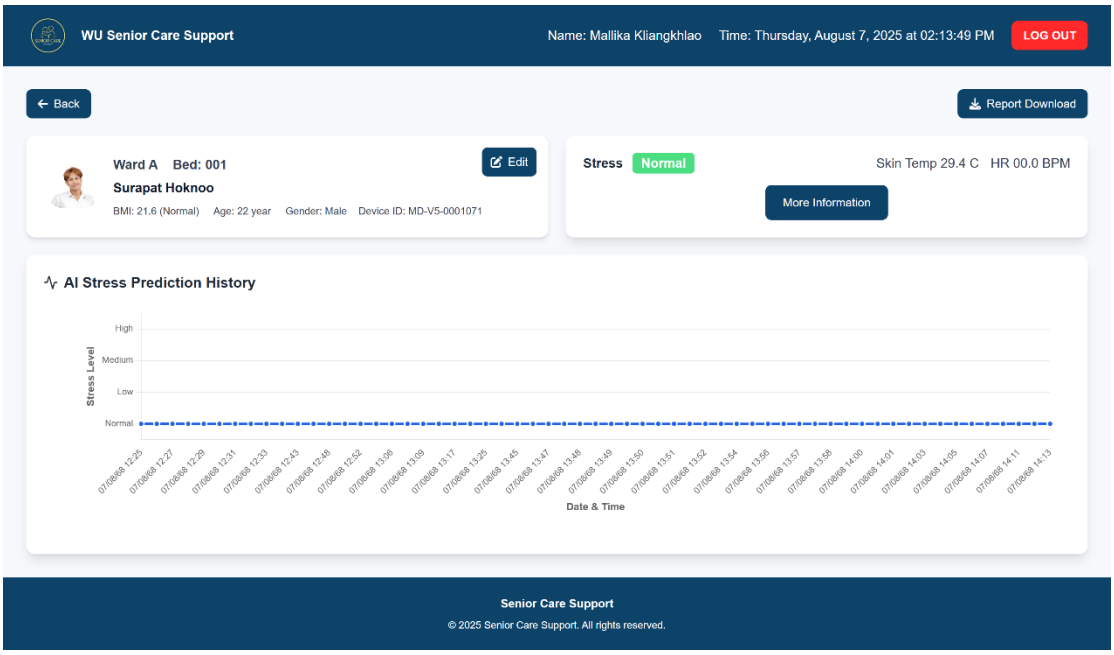
จากการฝึกฝนอัลกอริทึมในการเรียนรู้และทำนาย ผลการทำนายที่ได้จะแสดงผลในรูปแบบของ Web Application เพื่อให้ผู้ดูแลสามารถติดตามสถานะของสภาวะต่าง ๆ ได้อย่างสะดวกโดยการออกแบบระบบแสดงผลที่ดังภาพที่ 14-17

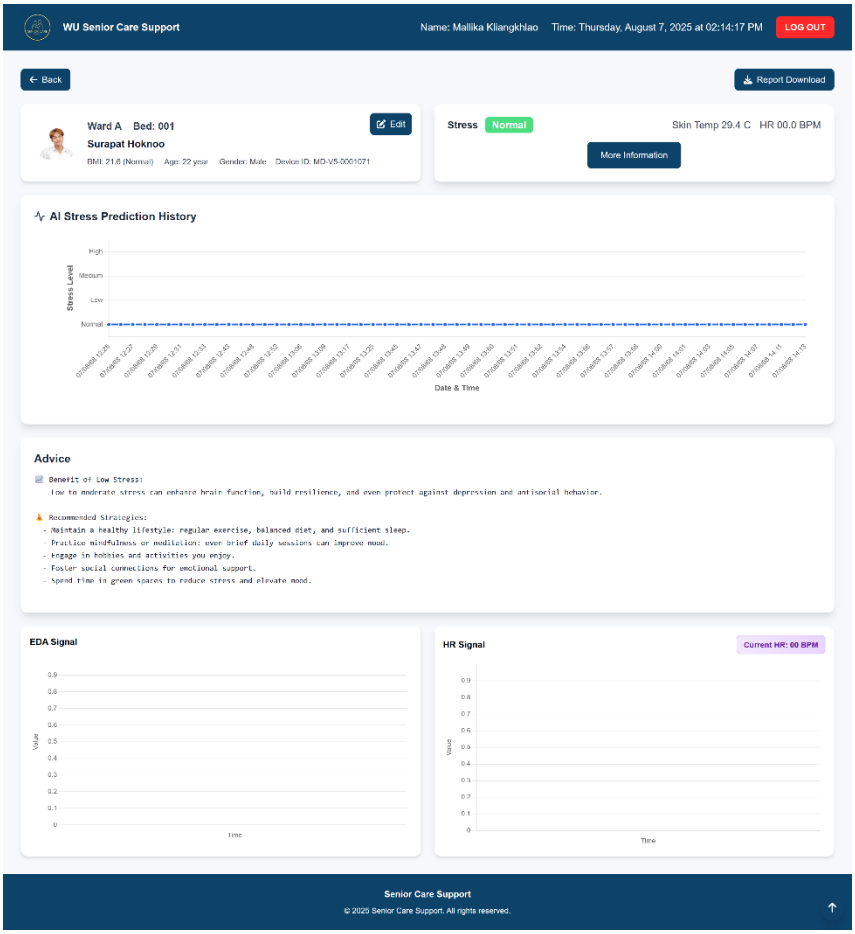


ภาพ 14 รูปแบบการแสดงผลหน้าจอ Web Application (Dashboard Page)

จาก**ภาพที่ 14** คือภาพหน้าจอแสดงแดชบอร์ดของระบบ "WU Senior Care Support" ซึ่งเป็นระบบสนับสนุนการดูแลผู้สูงอายุ โดยในภาพแสดงข้อมูลของผู้ป่วยสองรายในวอร์ด A และวอร์ด B หน้าจอนำเสนอข้อมูลที่จำเป็นอย่างกระชับและเข้าใจง่าย ประกอบด้วยชื่อผู้ป่วย (Surapat Hoknoo ทั้งสองวอร์ด) ค่าอัตราการเต้นของหัวใจ (HR) ข้อมูลเตียง หมายเลขอุปกรณ์ (Device ID) และอุณหภูมิผิว (SkinTemp) นอกจากนี้ยังมีการแสดงสถานะด้วยวงกลมสีแดง ส้ม และเขียว ซึ่งน่าจะหมายถึงสถานะความปกติหรือความผิดปกติของผู้ป่วย ระบบยังมีปุ่มสำหรับเพิ่มผู้ป่วยรายใหม่

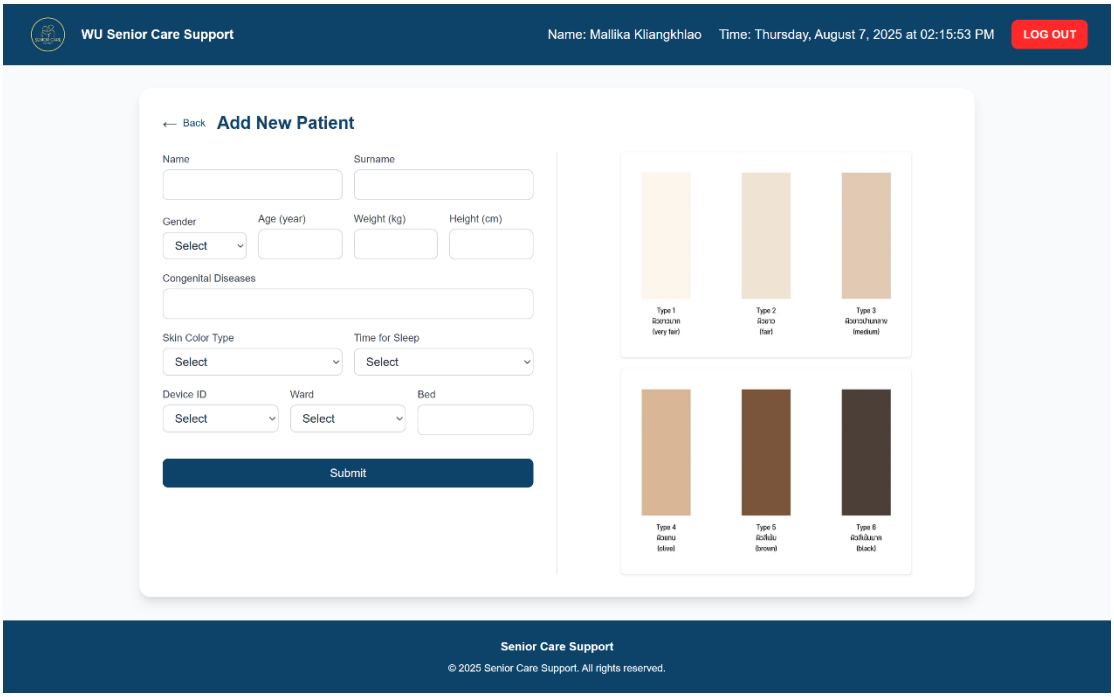
(New Patient) และออกจากระบบ (Log Out) แสดงให้เห็นถึงการออกแบบที่เน้นความสะดวกในการใช้งานสำหรับบุคลากรทางการแพทย์หรือผู้ดูแล





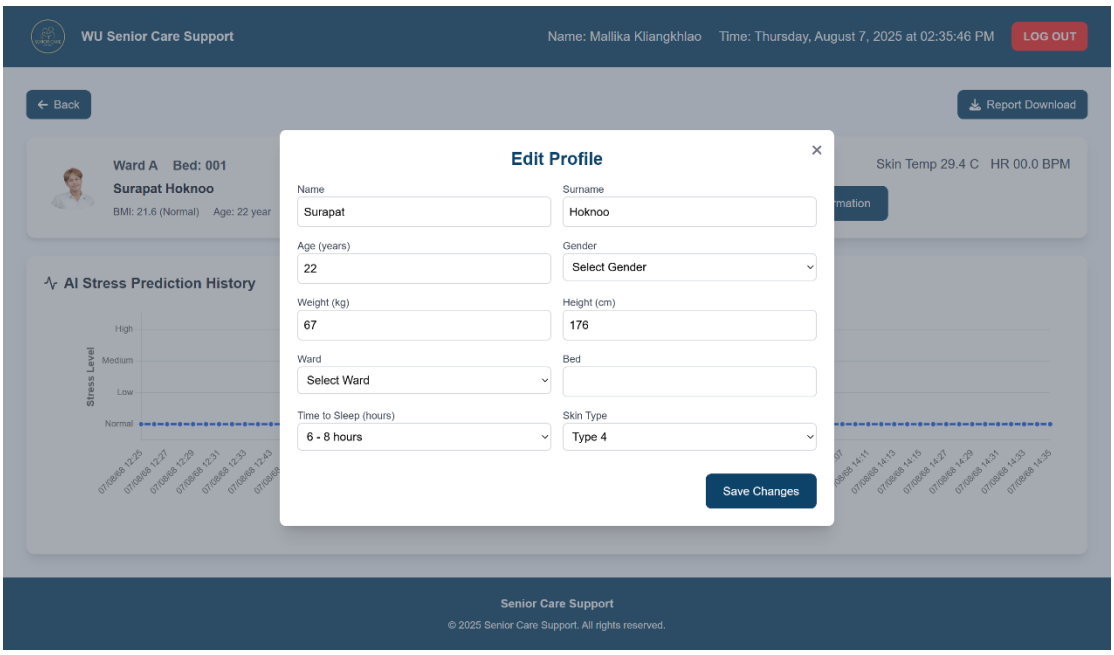
ภาพ 15 รูปแบบการแสดงผลหน้าจอ Web Application (Detail Page)

จาก**ภาพที่ 15** คือการแสดงตัวอย่างของการออกแบบหน้าจอแสดงผลเพื่อให้ผู้ดูแล สามารถเลือกรูปแบบที่ต้องการ เพื่อดูข้อมูลทั้งหมดของผู้ป่วย โดยจะแสดง ประวัติเบื้องต้นของผู้ป่วย (ชื่อ, อายุ, ส่วนสูง, โรคประจำตัว) ประวัติการตรวจจับความเครียดที่เกิดขึ้นโดยสามารถเลือกดูตามวันและเวลาที่เกิดระดับความเครียดต่าง ๆ กราฟคลื่นกิจกรรมไฟฟ้าบนผิวหนัง (EDA) และอัตราการเต้นของหัวใจ (HR) แบบเรียลไทม์ และแสดงการตรวจจับความเครียดแบบเรียลไทม์พร้อมทั้งแสดงคำแนะนำเบื้องต้น



ภาพ 16 รูปแบบการแสดงผลหน้าจอ Web Application (New Patient Page)

จาก**ภาพที่ 16** แสดงหน้าจอสำหรับเพิ่มข้อมูลผู้ป่วยใหม่ในระบบ WU Senior Care Support โดยหน้าจอนี้ออกแบบมาเพื่อให้ผู้ดูแลสามารถกรอกข้อมูลเบื้องต้นของผู้ป่วยได้อย่างครบถ้วน และเป็นระบบ โดยจะมีข้อมูลที่จำเป็นต้องกรอก ดังนี้ ชื่อ (Name), นามสกุล (Surname), อายุ (Age), น้ำหนัก (Weight), ส่วนสูง (Height), โรคประจำตัว (Congenital Diseases) ถ้ามี, สีผิว (Skin Type), เวลาในการนอน (Time to Sleep), เลขประจำอุปกรณ์ (Device ID), Ward และเตียง (Bed)



ภาพ 17 รูปแบบการแสดงผลหน้าจอ Web Application การแก้ไขข้อมูลส่วนตัวของผู้ป่วย

จาก**ภาพที่ 17** แสดงตัวอย่างหน้าจอสำหรับแก้ไขข้อมูลของผู้ป่วยในระบบ WU Senior Care Support โดยหน้าจอนี้ออกแบบมาเพื่อให้ผู้ดูแลสามารถแก้ไขข้อมูลเบื้องต้นของผู้ป่วยได้อย่างครบถ้วน และเป็นระบบ โดยจะมีข้อมูลที่สามารถแก้ไขได้ ดังนี้ ชื่อ (Name), นามสกุล (Surname), อายุ (Age), น้ำหนัก (Weight), ส่วนสูง (Height), โรคประจำตัว (Congenital Diseases) ถ้ามี, สีผิว (Skin Type), เวลาในการนอน (Time to Sleep), เลขประจำอุปกรณ์ (Device ID), Ward และเตียง (Bed)

บทที่ 6
สรุปผลและข้อเสนอแนะ

6.1 สรุปผลการดำเนินงาน

การดำเนินงานวิจัยในครั้งนี้มีวัตถุประสงค์หลักเพื่อพัฒนาระบบต้นแบบสำหรับตรวจจับระดับความเครียดของมนุษย์แบบเรียลไทม์ โดยได้ดำเนินการตามกรอบวัตถุประสงค์ที่กำหนดไว้ และสามารถสรุปผลการดำเนินงานในแต่ละส่วนได้ดังนี้

1. ศึกษากรอบแนวคิดการนำเทคโนโลยีปัญญาประดิษฐ์และสัญญาณ EDA และ HRV มาใช้ในการตรวจจับความเครียด

จากการศึกษางานวิจัยที่เกี่ยวข้องพบว่า สัญญาณ EDA และ HRV เป็นตัวชี้วัดทางชีวภาพที่มีความสัมพันธ์กับภาวะความเครียดในมนุษย์อย่างชัดเจน โดยสัญญาณ EDA สะท้อนถึงการทำงานของระบบประสาทซิมพาเทติก ซึ่งเกี่ยวข้องกับปฏิกิริยาตอบสนองต่อความเครียดเฉียบพลัน ในขณะที่ HRV เป็นตัวชี้วัดความสมดุลของระบบประสาทอัตโนมัติ ซึ่งมีความสัมพันธ์กับความเครียดในระดับเรื้อรัง

สำหรับเทคโนโลยีปัญญาประดิษฐ์ (AI) ที่นำมาใช้ในโครงการนี้คือ สถาปัตยกรรม (RNN, LSTM, GRU) ซึ่งมีคุณสมบัติในการเรียนรู้ข้อมูลตามลำดับเวลา (Sequential Data) ได้อย่างมีประสิทธิภาพ เหมาะสมกับลักษณะของข้อมูลสัญญาณชีวภาพที่มีการเปลี่ยนแปลงต่อเนื่อง

ผลการศึกษาสามารถยืนยันได้ว่า การผสานสัญญาณทางสรีรวิทยา EDA และ HRV กับเทคโนโลยีปัญญาประดิษฐ์ มีศักยภาพสูงในการตรวจจับภาวะความเครียดเชิงปริมาณ และสามารถลดข้อจำกัดของการประเมินด้วยแบบสอบถามซึ่งมีความคลาดเคลื่อนจากอคติทางความคิดหรือความไม่เข้าใจของผู้ตอบได้อย่างมีนัยสำคัญ

2. พัฒนาแบบจำลองการเรียนรู้สำหรับการจำแนกระดับความเครียด

ในการพัฒนาแบบจำลองการเรียนรู้สำหรับการจำแนกระดับความเครียด งานวิจัยนี้ได้ใช้ข้อมูลที่เก็บรวบรวมจากกลุ่มอาสาสมัครโดยใช้อุปกรณ์สวมใส่ที่สามารถตรวจวัดสัญญาณทางสรีรวิทยา ได้แก่ สัญญาณ EDA และสัญญาณ PPG เพื่อนำไปคำนวณ HRV ข้อมูลที่ได้รับผ่านกระบวนการเตรียมข้อมูลอย่างเป็นระบบ ซึ่งประกอบด้วยการกรองสัญญาณเพื่อขจัดความผิดปกติ (Signal Filtering), การลดสัญญาณรบกวนที่เกิดจากการเคลื่อนไหวหรือปัจจัยภายนอก (Denoising), การสกัดคุณลักษณะสำคัญ (Feature Extraction) เช่น SCR Amplitude, จำนวนจุดยอด (Number of Peaks), ค่า RMSSD, ค่า

SDNN และอัตราส่วน LF/HF รวมถึงการเข้ารหัสระดับความเครียดตามเกณฑ์มาตรฐาน เพื่อใช้เป็นข้อมูลนำเข้าสำหรับการฝึกสอนโมเดล

จากการทดลองเปรียบเทียบแบบจำลองได้แก่ RNN, LSTM และ GRU พบว่าแบบจำลอง GRU มีประสิทธิภาพสูงสุดในการจำแนกระดับความเครียด โดยสามารถให้ค่าความแม่นยำสูงสุดเมื่อเทียบกับแบบจำลองอื่น ทั้งในกรณีใช้สัญญาณ EDA และ HRV เป็นข้อมูลนำเข้า ทั้งนี้ แบบจำลอง LSTM มีความสามารถในการเรียนรู้ลำดับข้อมูลระยะยาวได้ดีเช่นกัน แต่ใช้เวลาในการฝึกสอนมากกว่าและมีความซับซ้อนของโครงสร้างสูงกว่า ขณะที่แบบจำลอง RNN ซึ่งมีโครงสร้างพื้นฐานที่สุดในบรรดาแบบจำลองทั้งสามนั้น แสดงให้เห็นถึงข้อจำกัดในการเรียนรู้ข้อมูลที่มีลักษณะเป็นลำดับยาว เนื่องจากประสบปัญหา vanishing gradient

จากผลการวิเคราะห์เชิงเปรียบเทียบสามารถสรุปได้ว่าแบบจำลอง GRU มีความเหมาะสมที่สุดสำหรับนำไปประยุกต์ใช้ในระบบต้นแบบ เนื่องจากมีความสมดุลทั้งในด้านประสิทธิภาพ ความแม่นยำ และความเร็วในการประมวลผล นอกจากนี้ยังพบว่าสัญญาณ HRV มีความสามารถในการแยกแยะระดับความเครียดได้ดีกว่าสัญญาณ EDA ซึ่งอาจเป็นผลมาจากความไวของสัญญาณ HRV ที่สะท้อนการตอบสนองของระบบประสาทซิมพาเทติกได้ชัดเจนยิ่งกว่า

แบบจำลองที่ได้รับการฝึกสอนจากข้อมูลจริงในงานวิจัยนี้สามารถจำแนกระดับความเครียดได้อย่างแม่นยำในระดับสูง และสามารถประยุกต์ใช้ในบริบทของการดูแลสุขภาพจิตในชีวิตประจำวันหรือในหน่วยงานบริการสุขภาพได้อย่างมีศักยภาพ

3. เพื่อพัฒนาระบบต้นแบบการตรวจจับความเครียดแบบเรียลไทม์

ระบบต้นแบบที่พัฒนาขึ้นประกอบด้วยส่วนฮาร์ดแวร์และซอฟต์แวร์ โดยในส่วนของฮาร์ดแวร์ใช้อุปกรณ์ EmotiBit ซึ่งสามารถวัดสัญญาณทางสรีรวิทยาได้แบบหลายช่องสัญญาณ (Multichannel) และส่งข้อมูลผ่าน ESP32 เข้าสู่ระบบแบบไร้สาย โดยข้อมูลที่รับมาจะถูกส่งเข้าสู่เซิร์ฟเวอร์กลางเพื่อผ่านกระบวนการวิเคราะห์จากโมเดล AI ที่พัฒนาขึ้น

ในส่วนของซอฟต์แวร์ ได้มีการพัฒนา Web Application โดยใช้ Next.js ซึ่งสามารถแสดงผลค่าความเครียดแบบเรียลไทม์ รวมถึงให้ผู้ดูแลสามารถเข้าถึงประวัติย้อนหลัง สถิติภาพรวม และรายงานแบบ PDF ได้อย่างสะดวก อีกทั้งยังสามารถแจ้งเตือนเมื่อระบบตรวจพบภาวะความเครียดสูงในผู้ใช้งาน

จากการทดสอบระบบจริง พบว่าสามารถตรวจจับและแสดงผลระดับความเครียดได้อย่างถูกต้องและต่อเนื่อง ตอบสนองต่อการเปลี่ยนแปลงของสัญญาณชีวภาพได้ทันที และสามารถนำไปประยุกต์ใช้ในบริบทของการดูแลสุขภาพจิต เช่น ศูนย์ดูแลผู้สูงอายุ โรงพยาบาล หรือคลินิกจิตเวชได้อย่างเหมาะสม

6.2 ข้อเสนอแนะ

เพื่อการพัฒนาและต่อยอดงานวิจัยในอนาคต จะนำไปสู่ระบบที่มีความเสถียรและแม่นยำยิ่งขึ้น ผู้วิจัยขอเสนอข้อเสนอแนะดังต่อไปนี้

1. **การเพิ่มขนาดและความหลากหลายของกลุ่มตัวอย่าง**

ข้อมูลที่ใช้ในโครงการยังอยู่ในระดับต้นแบบ การเพิ่มจำนวนอาสาสมัครในกลุ่มอายุ เพศ อาชีพ และสถานภาพสุขภาพจิตที่หลากหลาย จะช่วยให้แบบจำลองมีความสามารถในการ generalize ได้ดียิ่งขึ้น

2. **การใช้งานในสถานการณ์จริง (Field Testing)**

ควรมีการทดสอบระบบในสภาพแวดล้อมจริง เช่น โรงเรียน โรงพยาบาล หรือสถานที่ทำงาน เพื่อตรวจสอบความแม่นยำ ความเสถียร และการตอบสนองของระบบเมื่อใช้งานอย่างต่อเนื่องในชีวิตประจำวัน

3. **การเพิ่มฟังก์ชันแนะนำการดูแลสุขภาพจิตด้วย AI**

ระบบในอนาคตอาจผสานโมดูล AI สำหรับแนะนำกิจกรรมลดเครียด เช่น การฝึกหายใจ การทำสมาธิ หรือการปรึกษาจิตแพทย์แบบออนไลน์ เพื่อเพิ่มมิติด้านการฟื้นฟูและป้องกัน (Preventive Healthcare)

บรรณานุกรม

สถาบันวิจัยระบบสาธารณสุข. (2563). *รายงานสถานการณ์สุขภาพจิตผู้สูงอายุไทย ปี 2563*.

เหล่าแค, ส., & บุญสูง, พ. (2023). เสียง: ผลกระทบต่อสุขภาพ การตรวจวัด ค่ามาตรฐาน และมาตรการป้องกันเสียงดัง. *วารสารวิทยาศาสตร์และเทคโนโลยี ม.ราชภัฏศรีสะเกษ*, *3*(2), 14–21.

Critchley, H. D. (2002). Electrodermal responses: What happens in the brain. *The Neuroscientist*, *8*(2), 132–142.

Dhama, K., Latheef, S. K., Dadar, M., Samad, H. A., Munjal, A., Khandia, R., Karthik, K., & Tiwari, R. (2019). Biomarkers in stress related diseases/disorders: Diagnostic, prognostic, and therapeutic values. *Frontiers in Molecular Biosciences*, *6*, 91. https://doi.org/10.3389/fmolb.2019.00091

Ding, Y., Tan, K., Sheng, L., Ren, H., Su, Z., Yang, H., Zhang, X., Li, J., & Hu, P. (2024). Integrated mental stress smartwatch based on sweat cortisol and HRV sensors. *Biosensors and Bioelectronics*, *265*, 116691. https://doi.org/10.1016/j.bios.2024.116691

Ghiasi, S., Greco, A., Barbieri, R., Scilingo, E. P., & Valenza, G. (2020). Assessing autonomic function from electrodermal activity and heart rate variability during cold-pressor test and emotional challenge. *Scientific Reports*, *10*(1), 5406.

Goumopoulos, C., & Menti, E. (2019). Stress detection in seniors using biosensors and psychometric tests. *2019 International Conference on Pervasive Computing Advances and Applications – PerCAA*, 18–27.

Haque, Y., Zawad, R. S., Rony, C. S. A., Banna, H. A., Ghosh, T., Kaiser, M. S., & Mahmud, M. (2024). State-of-the-Art of Stress Prediction from Heart Rate Variability Using Artificial Intelligence. *Cognitive Computation*, *16*(3), 455–481. https://doi.org/10.1007/s12559-023-10200-0

Lebedev, G., Meshcheryakova, A., Pestova, N., Kachkovskiy, S., Taksikov, A., Kasimovskaya, N., Poleshuk, I., Radzievskiy, G., & Klimenko, H. (2020). Artificial Neural Networks to Monitor Bedridden Patients. *Procedia Computer Science*, *176*, 1923–1929.

Lu, L., Zhu, T., Morelli, D., Creagh, A., Liu, Z., Yang, J., Liu, F., Zhang, Y.-T., & Clifton, D. (2023). Uncertainties in the Analysis of Heart Rate Variability: A Systematic Review. *IEEE Reviews in Biomedical Engineering*. https://doi.org/10.1109/RBME.2023.3271595

NeuroKit. (2024). *Electrodermal Activity (EDA)*. https://neuropsychology.github.io/NeuroKit/functions/eda.html

Sahoh, B., Chaithong, P., Heembu, F., Yeranee, K., & Punsawad, Y. (2023). Physiological Signals-Driven Personal Thermal Comfort System Based on Environmental Intervention. *IEEE Access*.

Shah, S., & Tidy, C. (2024). *Acute stress reaction*. https://patient.info/mental-health/stress-management/acute-stress-reaction

Task Force of the European Society of Cardiology. (1996). Heart rate variability: Standards of measurement, physiological interpretation and clinical use. *Circulation*, *93*(5), 1043–1065.

World Health Organization. (2013). *Guidelines for the management of conditions that are specifically related to stress*. https://www.who.int/publications/i/item/guidelines-for-the-management-of-conditions-that-are-specifically-related-to-stress

Yu, X., Lu, J., Liu, W., & others. (2024). Exploring physiological stress response evoked by passive translational acceleration in healthy adults: A pilot study utilizing electrodermal activity and heart rate variability measurements. *Scientific Reports*, *14*, 11349. https://doi.org/10.1038/s41598-024-61656-5

Aliyari, H., Sahraei, H., Daliri, M. R., Minaei-Bidgoli, B., Kazemi, M., Agaei, H., ... & Daliri, M. (2018). The effects of playing violent video games on the levels of cortical and physiological stress hormones in male adolescents. *Basic and Clinical*

Neuroscience, 9(2), 157–164. https://doi.org/10.29252/nirp.bcn.9.2.157

Ooms, M. (2018). *Serious gaming as a measure for stress: Combining self-report, log data and sensor data* (Master's thesis). Tilburg University, Netherlands. https://arno.uvt.nl/show.cgi?fid=148688

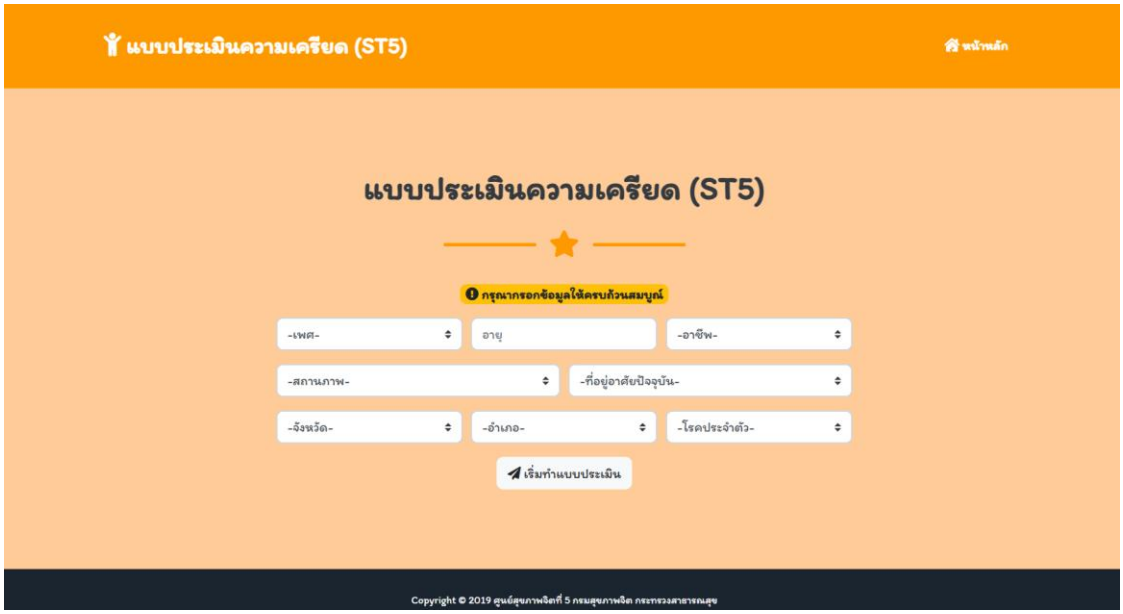
Vatsal, R., Mishra, S., Thareja, R., Chakrabarty, M., Sharma, O., & Shukla, J. (2023). An analysis of physiological and psychological responses in virtual reality and flat screen gaming. *arXiv preprint arXiv:2306.09690*. https://arxiv.org/abs/2306.09690

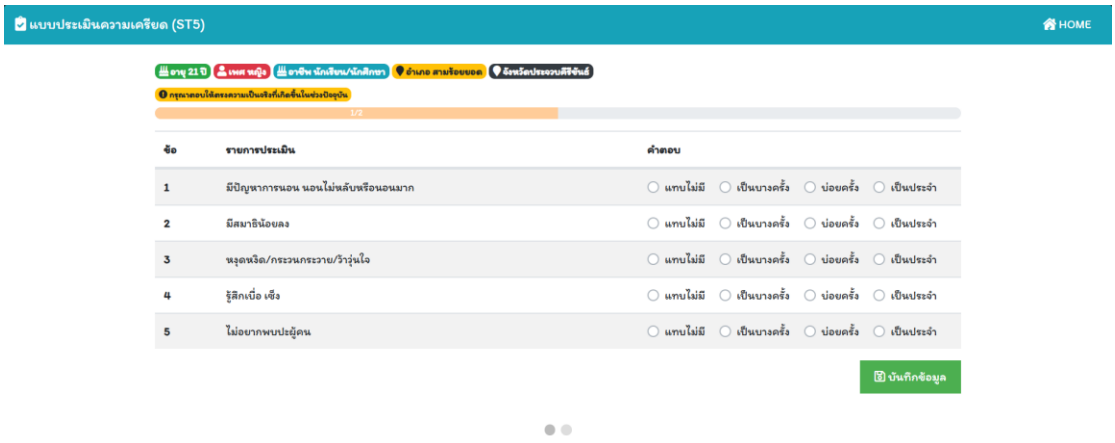
ภาคผนวก

ภาคผนวก ก
แบบสอบถามประเมินความเครียดก่อนเข้าร่วมทดลอง

ภาคผนวก ก แบบประเมินความเครียดก่อนเข้าร่วมการทดลอง

แบบสอบถามประเมินความเครียดของผู้เข้าร่วมทดสอบก่อนเข้าร่วมการทดลอง โดยใช้แบบทดสอบของกรมสุขภาพจิต กระทรวงสาธารณสุข

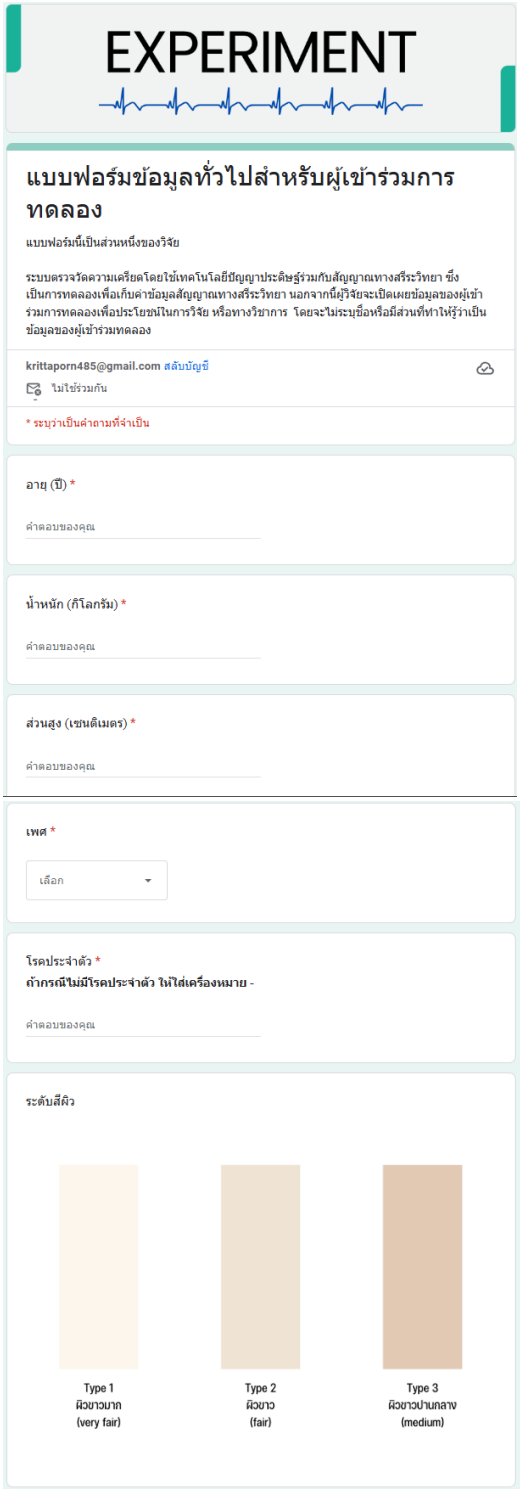




ภาคผนวก ข
แบบสอบถามข้อมูลทั่วไป

ภาคผนวก ข แบบสอบถามข้อมูลทั่วไป

แบบสอบถามข้อมูลของผู้เข้าร่วมการวิจัย



EXPERIMENT

แบบฟอร์มข้อมูลทั่วไปสำหรับผู้เข้าร่วมการทดลอง

แบบฟอร์มนี้เป็นส่วนหนึ่งของวิจัย

ระบบตรวจวัดความเครียดโดยใช้เทคโนโลยีปัญญาประดิษฐ์ร่วมกับสัญญาณทางสรีระวิทยา ซึ่งเป็นการทดลองเพื่อเก็บค่าข้อมูลสัญญาณทางสรีระวิทยา นอกจากนี้ผู้วิจัยจะเปิดเผยข้อมูลของผู้เข้าร่วมการทดลองเพื่อประโยชน์ในการวิจัย หรือทางวิชาการ โดยจะไม่ระบุชื่อหรือมีส่วนที่ทำให้รู้ว่าเป็นข้อมูลของผู้เข้าร่วมทดลอง

krittaporn485@gmail.com สลับบัญชี

ไม่ใช้ร่วมกัน

* ระบุว่าเป็นคำถามที่จำเป็น

อายุ (ปี) *

คำตอบของคุณ

น้ำหนัก (กิโลกรัม) *

คำตอบของคุณ

ส่วนสูง (เซนติเมตร) *

คำตอบของคุณ

เพศ *

เลือก

โรคประจำตัว *

ถ้ากรณีไม่มีโรคประจำตัว ให้ใส่เครื่องหมาย -

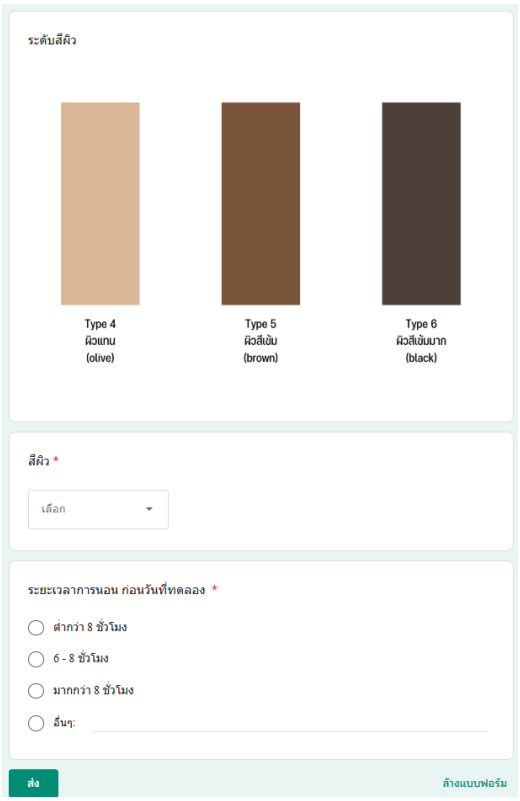
คำตอบของคุณ

ระดับสีผิว

Type 1
ผิวขาวมาก
(very fair)

Type 2
ผิวขาว
(fair)

Type 3
ผิวขาวปานกลาง
(medium)



ระดับสีผิว

Type 4
ผิวแทน
(olive)

Type 5
ผิวสีเข้ม
(brown)

Type 6
ผิวสีเข้มมาก
(black)

สีผิว *

เลือก

ระยะเวลาการนอน ก่อนวันที่ทดลอง *

- ต่ำกว่า 8 ชั่วโมง
- 6 - 8 ชั่วโมง
- มากกว่า 8 ชั่วโมง
- อื่นๆ:

ส่ง

ล้างแบบฟอร์ม

ภาคผนวก ค
เอกสารขอความยินยอมการเข้าร่วมโครงการวิจัย

ภาคผนวก ค เอกสารขอความยินยอมเข้าร่วมโครงการวิจัย

เอกสารชี้แจงการทดลอง และขอความยินยอมการเข้าร่วมโครงการวิจัย

เอกสารยินยอมการเข้าร่วมโครงการวิจัย
(Informed Consent Form)

ข้าพเจ้า นาย/นาง/นางสาว .....
บัตรประชาชนเลขที่.....อายุ.....ปี ที่อยู่.....
.....โทรศัพท์.....
ได้ทราบรายละเอียดของโครงการวิจัย เรื่อง ระบบตรวจสอบและติดตามภาวะวิตกกังวลโดยใช้เทคโนโลยีปัญญาประดิษฐ์ร่วมกับ สัญญาณทางสรีระวิทยาเพื่อสนับสนุนการดูแลผู้สูงอายุ ตลอดจนประโยชน์และข้อเสี่ยงที่จะเกิดขึ้นต่อข้าพเจ้าจากผู้วิจัยแล้วอย่างชัดเจน ไม่มีสิ่งใดปิดบังซ่อนเร้น และยินยอมให้ทำการวิจัยในโครงการที่กล่าวข้างต้น และข้าพเจ้ารู้ว่าถ้ามีปัญหาหรือข้อสงสัยเกิดขึ้น ข้าพเจ้าสามารถสอบถามผู้วิจัยได้ และสามารถถอนตัวออกจากการวิจัยนี้เมื่อใดก็ได้โดยไม่มีผลกระทบใดๆ ต่อข้าพเจ้า นอกจากนี้ผู้วิจัยจะเปิดเผยข้อมูลของข้าพเจ้าเพื่อประโยชน์ในการวิจัยหรือทางวิชาการ โดยไม่ระบุชื่อหรือส่วนที่ทำให้รู้ว่าเป็นข้อมูลข่าวสารของข้าพเจ้า

ลงชื่อ.....ผู้เข้าร่วมโครงการวิจัย
(.....)

ลงชื่อ.....พยาน
(.....)

ลงชื่อ.....พยาน
(.....)

วันที่.....เดือน.....พ.ศ.....

หมายเหตุ : สำหรับผู้ที่อ่านเขียนหนังสือไม่ได้เมื่อรับฟังเข้าใจแล้วให้พิมพ์ลายนิ้วหัวแม่มือแทนการลงนาม

คำอธิบายของผู้วิจัย

ข้าพเจ้าได้อธิบายรายละเอียดของโครงการวิจัยตลอดจนประโยชน์ของการวิจัย รวมทั้งข้อเสี่ยงที่อาจจะเกิดขึ้นแก่ผู้เข้าร่วมโครงการวิจัยทราบแล้วอย่างชัดเจน โดยไม่มีสิ่งใดปิดบังซ่อนเร้น

ลงชื่อ.....ผู้วิจัย
(.....)
วันที่.....เดือน.....พ.ศ.....

ภาคผนวก ง
แบบทดสอบประเมินความเครียดระหว่างการทดลอง

ภาคผนวก ง แบบทดสอบประเมิณความเครียดระหว่างการทดลอง

แบบประเมินวัดความเครียดระหว่างการทดลอง

แบบฟอร์มการกำกับระดับความเครียด
งานวิจัยระบบตรวจวัดความเครียดโดยใช้เทคโนโลยีปัญญาประดิษฐ์ร่วมกับสัญญาณทางสรีระวิทยา

ขอให้ผู้เข้าร่วมวิจัยติกเครื่องหมาย ✓ ในช่องระดับความเครียดที่ตนเองรู้สึกในแต่ละการทดลอง โดยในแต่ละระดับความเครียดมีรายละเอียดดังนี้

1. ความเครียดระดับต่ำ เป็นภาวะที่ร่างกายสามารถจัดการได้อย่างมีประสิทธิภาพ อาจก่อให้เกิดการตื่นตัวและเพิ่มประสิทธิภาพการทำงานในระยะสั้น
2. ความเครียดระดับปานกลาง ร่างกายเริ่มแสดงอาการตอบสนองต่อความเครียดที่ชัดเจนขึ้น แต่ยังสามารถปรับตัวได้ หากเรื้อรังอาจนำไปสู่ปัญหาสุขภาพ
3. ความเครียดระดับสูง เป็นภาวะที่ร่างกายไม่สามารถจัดการกับความเครียดได้อย่างมีประสิทธิภาพ ส่งผลให้เกิดการตอบสนองทางสรีรวิทยาที่รุนแรง เช่น การหลั่งฮอร์โมนคอร์ติซอล (Cortisol) ในปริมาณมาก

การทดลอง	**ความเครียดระดับต่ำ**	**ความเครียดระดับปานกลาง**	**ความเครียดระดับสูง**
การทดลองที่ 1: เกมทายสี			
การทดลองที่ 2: เกมจับผิดภาพ			
การทดลองที่ 3: เกมซูโดกุ			

ภาคผนวก จ
เอกสารรับรองโครงการวิจัยในมนุษย์

ภาคผนวก จ เอกสารรับรองโครงการวิจัยในมนุษย์

WUF06-09/1.0 May, 2021

เอกสารรับรองโครงการวิจัยในมนุษย์
คณะกรรมการจริยธรรมการวิจัยในมนุษย์ มหาวิทยาลัยวลัยลักษณ์
222 ตำบลไทยบุรี อำเภอท่าศาลา จังหวัดนครศรีธรรมราช 80160

รหัสโครงการ WU-EC-EN-2-110-67

ชื่อโครงการ

การศึกษาการตอบสนองทางสัญญาณสรีรวิทยาต่ออารมณ์และความรู้สึกโดยอาศัยเทคโนโลยีปัญญาประดิษฐ์และอินเทอร์เน็ตของสรรพสิ่ง

เลขที่เอกสารรับรอง

WUEC-24-136-02

ชื่อหัวหน้าโครงการ

อาจารย์ ดร.มัลลิกา เกลี้ยงเคล้า

สังกัด หน่วยงาน

สำนักวิชาวิศวกรรมศาสตร์และเทคโนโลยี มหาวิทยาลัยวลัยลักษณ์

ระยะเวลาที่รับรอง 1 ปี

ตั้งแต่วันเดือนปี 9 เมษายน 2568 **ถึงวันเดือนปี** 8 เมษายน 2569

เอกสารที่ได้รับการรับรอง

1. เอกสารโครงร่างการวิจัย
2. เอกสารชี้แจงผู้เข้าร่วมโครงการวิจัย
3. เอกสารยินยอมการเข้าร่วมโครงการวิจัย
4. เอกสารเครื่องมือวิจัย

ขอรับรองว่าโครงการวิจัยดังกล่าวข้างต้นได้ผ่านการพิจารณาเห็นชอบโดยสอดคล้องกับคำปฏิญญาเฮลซิงกิ จากคณะกรรมการจริยธรรมการวิจัยในมนุษย์ มหาวิทยาลัยวลัยลักษณ์

ลงนาม.....
(รองศาสตราจารย์ ดร.ชูชาติ พันธ์สวัสดิ์)
ประธานคณะกรรมการจริยธรรมการวิจัยในมนุษย์

ลงนาม.....
(ศาสตราจารย์ ดร.สมบัติ ธำรงธัญวงศ์)
อธิการบดีมหาวิทยาลัยวลัยลักษณ์
รับรอง ณ วันที่ 22 เมษายน 2568

รหัสโครงการ WU-EC-EN-2-110-67

เลขที่เอกสารรับรอง WUEC-24-136-02

ประวัติผู้เขียน คนที่ 1

ชื่อ นางสาว กฤตพร รักนุ้ย

วัน เดือน ปีที่เกิด 6 ตุลาคม พ.ศ. 2546

สถานที่เกิด อำเภอเขาชัยสน จังหวัดพัทลุง

วุฒิ	ชื่อสถาบัน	ปีที่สำเร็จการศึกษา
ระดับปริญญาตรี	มหาวิทยาลัยวลัยลักษณ์	กำลังศึกษา
ระดับมัธยมศึกษาตอนปลาย	โรงเรียนจอมสุรางค์อุปถัมภ์	2565
ระดับมัธยมศึกษาตอนต้น	โรงเรียนจอมสุรางค์อุปถัมภ์	2563

ตำแหน่งและสถานที่ทำงานปัจจุบัน

นักศึกษาระดับปริญญาตรี ชั้นปีที่ 4 สาขาวิศวกรรมคอมพิวเตอร์และปัญญาประดิษฐ์ สำนักวิชาวิศวกรรมศาสตร์และเทคโนโลยี มหาวิทยาลัยวลัยลักษณ์

ผลงานดีเด่นและรางวัลทางวิชาการ

1. รางวัลเหรียญเงิน การประกวดผลงานนวัตกรรมสายอุดมศึกษา ประจำปี 2568 ในงานมหกรรมงานวิจัยแห่งชาติ 2568 (Thailand Research Expo 2025)
2. รางวัลเหรียญเงิน โครงการประกวดสิ่งประดิษฐ์และนวัตกรรม Thailand New Gen Inventors Award 2025 (I – New Gen 2025)
3. ได้รับทุนสนับสนุนรอบข้อเสนอโครงการการแข่งขันพัฒนาโปรแกรมคอมพิวเตอร์แห่งประเทศไทย ครั้งที่ 26 (The 26th National Software Contest: NSC 2024) รอบข้อเสนอโครงการ ศูนย์ประสานงานภูมิภาค ภาคใต้

ประวัติผู้เขียน คนที่ 2

ชื่อ นาย สุรพัศ แซ่ตั้น

วัน เดือน ปีที่เกิด 3 กุมภาพันธ์ พ.ศ. 2547

สถานที่เกิด อำเภอหัวไทร จังหวัดนครศรีธรรมราช

วุฒิ	ชื่อสถาบัน	ปีที่สำเร็จการศึกษา
ระดับปริญญาตรี	มหาวิทยาลัยวลัยลักษณ์	กำลังศึกษา
ระดับมัธยมศึกษาตอนปลาย	โรงเรียนเบญจมราชูทิศ	2565
ระดับมัธยมศึกษาตอนต้น	โรงเรียนเบญจมราชูทิศ	2563

ตำแหน่งและสถานที่ทำงานปัจจุบัน

นักศึกษาระดับปริญญาตรี ชั้นปีที่ 4 สาขาวิศวกรรมคอมพิวเตอร์และปัญญาประดิษฐ์ สำนักวิชาวิศวกรรมศาสตร์และเทคโนโลยี มหาวิทยาลัยวลัยลักษณ์

ผลงานดีเด่นและรางวัลทางวิชาการ

1. รางวัลเหรียญเงิน การประกวดผลงานนวัตกรรมสายอุดมศึกษา ประจำปี 2568 ในงานมหกรรมงานวิจัยแห่งชาติ 2568 (Thailand Research Expo 2025)
2. รางวัลเหรียญเงิน โครงการประกวดสิ่งประดิษฐ์และนวัตกรรม Thailand New Gen Inventors Award 2025 (I – New Gen 2025)
3. ได้รับทุนสนับสนุนรอบข้อเสนอโครงการการแข่งขันพัฒนาโปรแกรมคอมพิวเตอร์แห่งประเทศไทย ครั้งที่ 26 (The 26th National Software Contest: NSC 2024) รอบข้อเสนอโครงการ ศูนย์ประสานงานภูมิภาค ภาคใต้

ประวัติผู้เขียน คนที่ 3

ชื่อ นาย สุรพัศ หกหนู

วัน เดือน ปีที่เกิด 2 ตุลาคม พ.ศ. 2545

สถานที่เกิด อำเภอหนองจิก จังหวัดปัตตานี

วุฒิ	ชื่อสถาบัน	ปีที่สำเร็จการศึกษา
ระดับปริญญาตรี	มหาวิทยาลัยวลัยลักษณ์	กำลังศึกษา
ระดับมัธยมศึกษาตอนปลาย	โรงเรียนอุบลรัตนราชกัญญา ราชวิทยาลัย กรุงเทพมหานคร	2565
ระดับมัธยมศึกษาตอนต้น	โรงเรียนดาวนายร้อย สงขลา	2561

ตำแหน่งและสถานที่ทำงานปัจจุบัน

นักศึกษาระดับปริญญาตรี ชั้นปีที่ 4 สาขาวิศวกรรมคอมพิวเตอร์และปัญญาประดิษฐ์ สำนักวิชาวิศวกรรมศาสตร์และเทคโนโลยี มหาวิทยาลัยวลัยลักษณ์

ผลงานดีเด่นและรางวัลทางวิชาการ

1. รางวัลเหรียญเงิน การประกวดผลงานนวัตกรรมสายอุดมศึกษา ประจำปี 2568 ในงานมหกรรมงานวิจัยแห่งชาติ 2568 (Thailand Research Expo 2025)
2. รางวัลเหรียญเงิน โครงการประกวดสิ่งประดิษฐ์และนวัตกรรม Thailand New Gen Inventors Award 2025 (I – New Gen 2025)